



FUNDAÇÃO UNIVERSIDADE FEDERAL DE RONDÔNIA
NÚCLEO DE CIÊNCIAS EXATAS E DA TERRA
PROGRAMA DE PÓS-GRADUAÇÃO EM DESENVOLVIMENTO
REGIONAL E MEIO AMBIENTE

MODELAGEM HÍBRIDA: INTELIGÊNCIA ARTIFICIAL APLICADA NA
DETERMINAÇÃO DO FLUXO DE CO₂ EM CULTIVARES DE SOJA NA
AMAZÔNIA LEGAL

DAVID LOPES MACIEL

PORTO VELHO – RO

2026

FUNDAÇÃO UNIVERSIDADE FEDERAL DE RONDÔNIA
NÚCLEO DE CIÊNCIAS EXATAS E DA TERRA
PROGRAMA DE PÓS-GRADUAÇÃO EM DESENVOLVIMENTO
REGIONAL E MEIO AMBIENTE

MODELAGEM HÍBRIDA: INTELIGÊNCIA ARTIFICIAL APLICADA NA
DETERMINAÇÃO DO FLUXO DE CO₂ EM CULTIVARES DE SOJA NA
AMAZÔNIA LEGAL

DAVID LOPES MACIEL

Orientador: Fabrício Moraes de Almeida

Tese de Doutorado apresentada ao Programa de Pós-Graduação em Desenvolvimento Regional e Meio Ambiente, Área de Concentração em Desenvolvimento Sustentável & Diagnóstico Ambiental, Linha de Pesquisa em Políticas Públicas & Desenvolvimento Sustentável, para a obtenção do título de Doutor em Desenvolvimento Regional e Meio Ambiente.

Porto Velho (RO)

2026

FICHA-CATALOGRÁFICA

Consultar o(a) Bibliotecário(a)

Dados Internacionais de Catalogação na Publicação

Fundação Universidade Federal de Rondônia

Gerada automaticamente mediante informações fornecidas pelo(a) autor(a)

DAVID LOPES MACIEL

**MODELAGEM HÍBRIDA: INTELIGÊNCIA ARTIFICIAL APLICADA NA
DETERMINAÇÃO DO FLUXO DE CO₂ EM CULTIVARES DE SOJA NA
AMAZÔNIA LEGAL**

Comissão Examinadora

Porto Velho, ____ de _____ de 2026.

Resultado: _____

DEDICATÓRIA

Dedico este trabalho, primeiramente, a Deus, fonte de sabedoria, força e propósito, cuja presença constante sustentou cada etapa desta jornada acadêmica e pessoal; à minha esposa, Natiele Vieira de Oliveira Maciel, pelo amor, paciência, apoio incondicional e pela compreensão nos momentos de ausência, incerteza e intenso esforço, sendo alicerce fundamental para a concretização deste sonho; à minha filha, Lara Gabriely França Maciel, razão maior de perseverança, inspiração diária e motivação para seguir em busca do conhecimento, com o desejo de construir um futuro pautado em valores, dedicação e exemplo; aos meus familiares, que, de diferentes formas, contribuíram com apoio, incentivo e confiança ao longo de toda a trajetória que culminou neste trabalho; e aos meus amigos mais próximos, Aline, Wander, Rafael e Natália, que estiveram presentes nos momentos decisivos, compartilhando apoio, palavras de encorajamento e companheirismo ao longo desta caminhada.

AGRADECIMENTOS

Agradeço, de forma especial, ao meu orientador, Dr. Fabrício Moraes de Almeida, pela orientação criteriosa, disponibilidade constante, rigor científico e contribuições fundamentais ao longo de todas as etapas deste trabalho. Sua experiência acadêmica e postura ética foram decisivas para o amadurecimento teórico, metodológico e crítico desta pesquisa.

Registro também meus agradecimentos à Coordenação do Curso, pelo suporte institucional, pelas orientações acadêmicas e pela condução responsável do programa, criando condições adequadas para o desenvolvimento desta tese.

“Os que se encantam com a prática sem a ciência são como os timoneiros que entram no navio sem timão nem bússola, nunca tendo certeza do seu destino”.

(Leonardo da Vinci)

RESUMO

Esta tese desenvolveu e avaliou uma abordagem computacional híbrida para estimar o fluxo de CO₂ em áreas cultivadas com soja na Amazônia Legal, integrando sensoriamento remoto hiperespectral, modelagem biofísica inspirada em esquemas SVAT/ISBA e aprendizado de máquina. A pesquisa foi estruturada a partir da hipótese de que a integração entre inteligência artificial, sensoriamento remoto hiperespectral orbital e modelagem biofísica poderia ampliar a capacidade de estimar o fluxo de CO₂ em sistemas agrícolas tropicais, especialmente em áreas onde medições diretas de campo são escassas ou operacionalmente limitadas. O estudo utilizou imagens do sensor EO-1 Hyperion, máscara de soja derivada do MapBiomass, variáveis meteorológicas da estação convencional do INMET em Canarana (MT), código 83270, e rotinas computacionais em Python para organização do pipeline analítico. Foram calculados índices espectrais e variáveis biofísicas relacionados à condição do dossel, posteriormente integrados a uma formulação física simplificada para estimativa da troca líquida de CO₂ do ecossistema. Em seguida, aplicou-se o algoritmo XGBoost como componente de correção residual, buscando ajustar padrões não representados pela parametrização física reduzida. Os resultados indicaram que o modelo físico simplificado apresentou RMSE = 1,30 gCO₂ m⁻² h⁻¹, MAE = 1,11 gCO₂ m⁻² h⁻¹ e R² = -0,04, evidenciando limitações para representar a referência biofísica adotada. A abordagem híbrida apresentou RMSE = 0,013 gCO₂ m⁻² h⁻¹, MAE = 0,008 gCO₂ m⁻² h⁻¹ e R² = 0,9999 no escopo da validação temporal adotada. Esses valores indicam maior aderência estatística à referência modelada, porém devem ser interpretados como evidências internas de consistência metodológica, sem caracterizar validação observacional independente. A contribuição da tese está na formulação de um pipeline reproduzível e rastreável para o estudo de fluxos de carbono em sistemas agrícolas tropicais, articulando observação hiperespectral, interpretação biofísica e inteligência artificial. A abordagem proposta pode subsidiar futuras estratégias de monitoramento ambiental e agricultura de baixo carbono, desde que acompanhada de validações externas progressivas com dados observacionais independentes.

Palavras-chave: Fluxo de CO₂; Sensoriamento remoto hiperespectral; Inteligência artificial.

ABSTRACT

This thesis developed and evaluated a hybrid computational approach for estimating CO₂ flux in soybean cultivation areas in the Legal Amazon, integrating hyperspectral remote sensing, biophysical modeling inspired by SVAT/ISBA schemes, and machine learning. The research was structured around the hypothesis that the integration of artificial intelligence, orbital hyperspectral remote sensing, and biophysical modeling could improve estimates of CO₂ flux in tropical agricultural systems, especially in areas where direct field measurements are scarce or operationally limited. The study used EO-1 Hyperion imagery, a soybean mask derived from MapBiomass, meteorological variables from the conventional INMET station in Canarana, Mato Grosso, code 83270, and Python-based computational routines to organize the analytical pipeline. Spectral indices and biophysical variables related to canopy condition were calculated and then integrated into a simplified physical formulation for estimating net ecosystem CO₂ exchange. The XGBoost algorithm was subsequently applied as a residual correction component, aiming to adjust patterns not represented by the reduced physical parameterization. The results indicated that the simplified physical model presented RMSE = 1.30 gCO₂ m⁻² h⁻¹, MAE = 1.11 gCO₂ m⁻² h⁻¹, and R² = -0.04, revealing limitations in representing the adopted biophysical reference. The hybrid approach presented RMSE = 0.013 gCO₂ m⁻² h⁻¹, MAE = 0.008 gCO₂ m⁻² h⁻¹, and R² = 0.9999 within the adopted temporal validation framework. These values indicate greater statistical agreement with the modeled reference, but they must be interpreted as internal evidence of methodological consistency rather than direct experimental field validation. The contribution of this thesis lies in the formulation of a reproducible and traceable pipeline for studying carbon fluxes in tropical agricultural systems, combining hyperspectral observation, biophysical interpretation, and artificial intelligence. The proposed approach may support future environmental monitoring strategies and low-carbon agriculture, provided that progressive external validations with independent observational data are incorporated.

Key words: CO₂ flux; Hyperspectral remote sensing; Artificial intelligence.

LISTA DE ILUSTRAÇÕES

1. Figura 01 – Fluxo operacional de processamento dos dados e modelagem computacional híbrida para estimativa do fluxo de CO₂.
2. Figura 02 – Máscara de soja na área da cena HSI Hyperion (2015).
3. Figura 03 – Ciclo diurno médio da troca líquida de CO₂ (NEE) no período de 01/10/2015 a 30/12/2015.
4. Figura 04 – Série temporal diária do NEE estimado (tCO₂ ha⁻¹ dia⁻¹) no período de 01/10/2015 a 30/12/2015.
5. Figura 05 – Acúmulo progressivo do NEE (tCO₂ ha⁻¹) no período de 01/10/2015 a 30/12/2015.

LISTA DE TABELAS

1. Tabela 01 – Caracterização do dataframe meteorológico-base utilizado no estudo.
2. Tabela 02 – Índices e bandas Hyperion (selecionadas pelo λ mais próximo no arquivo .hdr, 242 bandas).
3. Tabela 03 – Estatísticas descritivas dos índices espectrais calculados para a cultura da soja a partir da imagem Hyperion (29/12/2015).
4. Tabela 04 – Integração entre índices espectrais e variáveis meteorológicas para a cultura da soja (29/12/2015).
5. Tabela 05 – Estatísticas descritivas horárias das variáveis biofísicas do fluxo de CO₂.
6. Tabela 06 – Comparação estatística do NEE nos períodos diurno e noturno.
7. Tabela 07 – Estatísticas do balanço diário e do saldo acumulado de CO₂.

LISTA DE ABREVIATURAS E SIGLAS

AOI Area of Interest (Área de Interesse)

APAR Absorbed Photosynthetically Active Radiation (Radiação Fotossinteticamente Ativa Absorvida)

CO₂ Dióxido de Carbono

EO-1 Earth Observing-1

ET Evapotranspiração

FCOVER Fractional Vegetation Cover

fPAR Fração da Radiação Fotossinteticamente Ativa Absorvida

GEE Gases de Efeito Estufa

GNDVI Green Normalized Difference Vegetation Index

GPP Gross Primary Production (Produtividade Primária Bruta)

HSI Hyperspectral Imaging

IA Inteligência Artificial

INMET Instituto Nacional de Meteorologia

ISBA Interactions between Soil, Biosphere and Atmosphere

LAI Leaf Area Index (Índice de Área Foliar)

LSWI Land Surface Water Index

LUE Light Use Efficiency (Eficiência do Uso da Luz)

MAE Mean Absolute Error

MSAVI2 Modified Soil Adjusted Vegetation Index 2

NBR Normalized Burn Ratio

NEE Net Ecosystem Exchange (Troca Líquida de Ecossistema)

NDMI Normalized Difference Moisture Index

NDVI Normalized Difference Vegetation Index

NDWI Normalized Difference Water Index

NIR Near Infrared (Infravermelho Próximo)

NIR_v Near Infrared Reflectance of Vegetation

PAR Photosynthetically Active Radiation (Radiação Fotossinteticamente Ativa)

PRI Photochemical Reflectance Index

Q10 Fator de sensibilidade térmica da respiração

Reco Respiração do Ecossistema

RED Banda do vermelho

RG Radiação Global

RH Umidade relativa do ar

RMSE Root Mean Square Error

SAVI Soil Adjusted Vegetation Index

SR Sensoriamento Remoto

SVAT Soil–Vegetation–Atmosphere Transfer

SWDOWN Radiação Solar de Onda Curta Incidente

SWIR1 Short-Wave Infrared 1 (Infravermelho de Ondas Curtas 1)

SWIR2 Short-Wave Infrared 2 (Infravermelho de Ondas Curtas 2)

VPD Vapor Pressure Deficit (Déficit de Pressão de Vapor)

XGBoost Extreme Gradient Boosting

LISTA DE SÍMBOLOS

α Albedo da superfície

f_1, f_2, f_3, f_4 Funções de resposta ambiental da condutância/resistência estomática

$f_{ML}(\cdot)$ Função de regressão do modelo de aprendizado de máquina

f_{VPD} Função de limitação por déficit de pressão de vapor

f_W Função de limitação hídrica

f_T Função de limitação térmica

$g_{\max}$ Condutância estomática máxima

G Fluxo de calor no solo

H Fluxo de calor sensível

i Unidade imaginária (números complexos, transformada de Fourier)

K Número total de árvores no modelo XGBoost

k Coeficiente de extinção do dossel (Beer–Lambert)

k_{auto} Coeficiente da respiração autotrófica

LE Fluxo de calor latente

L Fator de ajuste do solo no SAVI

$L_{\downarrow}$ Radiação de onda longa incidente

$\mathcal{L}$ Função objetivo total (perda + regularização) no XGBoost

$\ell(\cdot)$ Função de perda elementar

λ Parâmetro de regularização L2 no XGBoost

μ_X Média amostral da variável de entrada X

N Número de observações/amostras (métricas e transformada discreta de Fourier)

n Número de amostras no conjunto de treinamento

NEE_{ref} NEE de referência (observacional ou de modelo de maior fidelidade)

NEE_{fis0} NEE estimado pelo modelo físico simplificado

NEE_{hib} NEE estimado pelo modelo híbrido

$\Omega(f)$ Termo de regularização estrutural do XGBoost

P Precipitação

R^2 Coeficiente de determinação

R_g Radiação global de onda curta incidente

R_n Saldo de radiação na superfície

R_{auto} Respiração autotrófica

R_{het} Respiração heterotrófica

$R_{\text{het,ref}}$ Taxa de referência da respiração heterotrófica

R_{ref} Taxa de referência da respiração do ecossistema

r_{st} Resistência estomática

SI_i i -ésimo índice espectral

σ Constante de Stefan–Boltzmann

σ_X Desvio-padrão da variável de entrada X

T Número de folhas da árvore no termo de regularização do XGBoost

T_a Temperatura do ar

T_{air} Temperatura do ar

T_{ref} Temperatura de referência da respiração

T_s Temperatura da superfície

t Índice temporal discreto

τ Constante de tempo do esquema force–restore

w_j Peso associado à folha j da árvore no XGBoost

$X(t)$ Vetor de variáveis explicativas no instante t

X_{amb} Subvetor de variáveis ambientais

X_{bio} Subvetor de variáveis biofísicas

X_{esp} Subvetor de variáveis espectrais

X_{met} Subvetor de variáveis meteorológicas/hidrológicas

X_{norm} Variável (ou vetor) normalizada(o) por z-score

X_{temp} Subvetor de descritores temporais

$X_f(k)$ Coeficiente espectral da transformada discreta de Fourier na frequência k

y_i Valor observado no instante/amostra i

$\hat{y}_i$ Valor estimado no instante/amostra i

$\bar{y}$ Média dos valores observados

Z_s Profundidade efetiva da camada de solo

ΔNEE Resíduo da troca líquida do ecossistema

$\widehat{\Delta NEE}$ Resíduo estimado pelo modelo de aprendizado de máquina

$\theta(t)$ Umidade volumétrica do solo no instante t

θ_{eq} Umidade de equilíbrio do solo

θ Vetor de parâmetros do modelo de aprendizado de máquina

ϵ Emissividade da superfície (balanço radiativo)

ϵ_{max} Eficiência máxima de uso da luz

γ Penalização por complexidade estrutural no XGBoost

SUMÁRIO

1	Introdução	21
1.1	Importância da cultura da soja na Amazônia Legal	23
1.2	Limitações dos métodos tradicionais	24
1.3	Justificativa.....	26
1.4	Hipótese	27
1.5	Objetivo Geral	28
1.6	Objetivos Específicos.....	28
1.7	Fundamentação teórica e revisão da literatura	29
1.8	Sensoriamento Remoto Hiperespectral na Agricultura	30
1.8.1	Faixas espectrais relevantes para a vegetação	32
1.8.2	Índices espectrais aplicáveis à cultura da soja	33
1.8.3	Satélites e sensores utilizados.....	34
1.9	Índices de Vegetação e Relação com Biomassa e Fluxo de CO ₂	35
1.10	Machine Learning aplicado à modelagem ambiental	36
1.11	Random Forest.....	36
1.12	Modelos de referência comparativa: Regressão Logística e KNN	37
1.13	XGBoost	39
1.14	Revisão integrativa	42
1.15	Resultados da Revisão	43
1.16	Desafios e Potencial para a Amazônia.....	45
2	Metodologia.....	47
2.1	Visão Geral do Modelo Híbrido	47
2.2	Área de Estudo e Fontes de Dados.....	49
2.2.1	Delimitação das áreas de soja (MapBiomass).....	51
2.3	Módulo Físico: Formulação SVAT/ISBA Reduzida	51
2.3.1	Balanço de Energia.....	52
2.3.2	Resistência estomática	52
2.3.3	Balanço Hídrico – Esquema Force–Restore.....	54
2.3.4	Fotossíntese (APAR–Monteith).....	55

2.3.5	Respiração autotrófica e heterotrófica	56
2.3.6	Cálculo da Troca Líquida de Ecossistema (NEE)	57
2.4	Módulo de Aprendizado de Máquina: Correção Residual do Fluxo de CO ₂ ..	58
2.4.1	Seleção de variáveis de entrada (features ambientais, espectrais e temporais)	59
2.4.2	Pré-processamento e normalização dos dados	61
2.4.3	Transformada de Fourier como Feature Engineering	62
2.4.4	Arquitetura e treinamento do modelo de aprendizado de máquina.....	63
2.4.5	Integração do modelo físico e do modelo de aprendizado de máquina	64
2.5	Estratégia de validação e avaliação do modelo	65
2.6	Pipeline operacional do modelo híbrido	67
2.7	Visão Geral do Fluxo Metodológico	68
2.8	Extração de Índices Espectrais e Variáveis Derivadas	70
2.8.1	Índice de Vegetação por Diferença Normalizada (NDVI)	71
2.9	Construção do Dataframe Meteorológico-Base	71
2.10	Seleção e Caracterização da Cena Hiperspectral	72
2.11	Delimitação e Mascaramento das Áreas de Soja.....	72
2.12	Extração dos Metadados Temporais das Cenas Hiperspectrais	73
2.13	Estratégia de Alinhamento Temporal (t).....	74
2.14	Construção do Dataframe Unificado Meteo–Hiperspectral	75
2.15	Validação Estrutural do Dataframe Unificado	76
2.16	Análise de Qualidade dos Dados.....	77
2.17	Integração com Modelos Biofísicos (SVAT / ISBA).....	77
2.18	Execução do Modelo Biofísico para Estimativa do Fluxo de CO ₂	78
2.18.1	Variáveis de entrada do modelo.....	79
2.18.2	Formulação do modelo biofísico reduzido	80
2.18.3	Produtos gerados e conexão com as etapas subsequentes	81
2.18.4	Determinação da troca líquida do ecossistema (NEE).....	82
2.18.5	Produtos gerados e articulação com as etapas subsequentes	82
2.19	Modelagem Híbrida Baseada em Inteligência Artificial	82
2.19.1	Conjunto de variáveis de entrada	83
2.19.2	Arquitetura e estratégia de modelagem	83
2.19.3	Avaliação do ganho em relação ao modelo físico	84

2.19.4	Papel da modelagem híbrida na estrutura da tese	84
2.20	Avaliação e Validação dos Resultados	85
2.21	Definição do modelo de Inteligência Artificial.....	86
2.22	Integração das variáveis espectrais, ambientais e biofísicas	87
2.23	Treinamento do Modelo de Aprendizado de Máquina	89
3	Resultados	91
3.1	Resultados dos Índices Espectrais	91
3.2	Índices espectrais calculados para áreas de soja	96
3.2.1	Cálculo dos índices a partir das bandas Hyperion e máscara de soja	96
3.2.2	Integração espectral e meteorológica	103
3.2.3	Relação dos índices com as variáveis biofísicas	105
3.3	Resultados da Modelagem do Fluxo de CO₂	107
3.4	Comparação com a literatura e métodos de referência	109
3.5	Validação estatística e avaliação prática	111
3.5.1	Validação física do modelo biofísico	111
3.5.2	Resultados numéricos consolidados	114
3.5.3	Avaliação estatística e controle de qualidade	116
3.6	Validação estatística do modelo híbrido	119
3.7	Ganho do modelo híbrido em relação ao modelo biofísico simplificado	119
3.8	Síntese dos resultados da modelagem híbrida	120
4	Discussão Científica	121
4.1	Potencial do HSI para monitoramento agrícola	121
4.2	Limitações dos modelos físicos clássicos	123
4.3	Discussão integrada: ISBA x IA	126
4.4	Implicações para monitoramento de carbono na Amazônia	129
4.5	Limitações da validação e interpretação dos resultados	132
4.5.1	Ausência de medições in situ de fluxo de CO ₂	133
4.5.2	Alcance da validação indireta e incertezas do modelo.....	134
5	Conclusão	136
5.1	Síntese dos achados	136
5.2	Validação da hipótese	137

5.3	Propostas futuras	138
	Referências	141
	APÊNDICE A — Repositório computacional, rastreabilidade e reprodu- tibilidade da pesquisa	150
	APÊNDICE B — Publicações da Tese	152
B.1	Artigos em periódicos	152
B.2	Capítulos de livros	153

1 INTRODUÇÃO

A intensificação das atividades humanas nas últimas décadas tem promovido alterações significativas nos ecossistemas naturais, evidenciando a urgência de compreender e mitigar os efeitos das mudanças climáticas em escala global. Entre os gases de efeito estufa (GEE), o dióxido de carbono (CO_2) destaca-se por sua centralidade nos processos biofísicos e climáticos, bem como por sua estreita associação com atividades antrópicas, tais como a agricultura intensiva, o desmatamento e a queima de combustíveis fósseis. A dinâmica do fluxo de CO_2 na atmosfera, resultante da interação entre processos naturais e ações humanas, constitui um desafio científico de elevada complexidade, em função da multiplicidade de variáveis envolvidas e da expressiva variabilidade temporal e espacial dos ecossistemas terrestres (STOLBOVOY, 2006; STOLBOVOY, 2015).

Segundo a Organização para a Cooperação e Desenvolvimento Econômico (OECD, 2020), a ausência de séries históricas consolidadas, aliada à limitação no acesso a dados ambientais confiáveis, constitui um dos principais entraves à formulação de políticas públicas eficazes voltadas à mitigação das emissões de dióxido de carbono (CO_2). Essa lacuna evidencia a necessidade de abordagens metodológicas e tecnológicas mais integradas, rastreáveis e adequadas ao monitoramento ambiental, capazes de quantificar e monitorar os fluxos de carbono com maior precisão e consistência. Tal demanda torna-se ainda mais crítica em regiões estratégicas como a Amazônia Legal, onde o avanço do agronegócio intensifica as pressões sobre os sistemas naturais e amplia a complexidade das interações entre uso da terra, clima e ciclos biogeoquímicos.

Nesse contexto, o sensoriamento remoto desponta como uma ferramenta promissora, permitindo análises espectrais detalhadas da vegetação e estimativas indiretas de trocas gasosas, como o fluxo de vapor d'água, calor sensível e CO_2 (BAPTISTA, 2019).

No entanto, a eficácia dessas abordagens ainda é limitada pela complexidade dos modelos físico-matemáticos utilizados, como os modelos de transferência solo-vegetação-atmosfera (SVAT), que exigem um alto grau de parametrização e calibração para condições específicas de cultivo. Modelos como o ISBA e suas variantes (TEB, TRIP) oferecem potencial significativo para a modelagem de processos como fotossíntese, respiração vegetal e ciclagem do carbono no solo (BRAUD et al., 1993; BRAUD et al., 1994; MAHFOUF; NOILHAN, 1996a; NOILHAN

et al., 1989; DELIRE et al., 2020a), mas enfrentam limitações em sua aplicação prática, sobretudo quando associados a grandes volumes de dados espectrais que demandam capacidade computacional elevada e técnicas sofisticadas de análise.

A superação das limitações associadas aos modelos físico-matemáticos tradicionais e ao tratamento de grandes volumes de dados ambientais tem impulsionado a integração entre modelagem ambiental e inteligência artificial. Técnicas como redes neurais artificiais e algoritmos de aprendizado profundo (deep learning) apresentam elevada capacidade de aprendizado de padrões não lineares e complexos, mostrando-se particularmente adequadas para sistemas ambientais caracterizados por elevada variabilidade espacial e temporal (JEAN et al., 1998b). A articulação entre modelos físicos e algoritmos de inteligência artificial possibilita a construção de sistemas híbridos, capazes de combinar o rigor teórico da modelagem biofísica com maior flexibilidade, capacidade de generalização e potencial de aplicação em contextos operacionais.

Esta tese propõe o desenvolvimento de um modelo computacional híbrido para a simulação dos fluxos de dióxido de carbono (CO_2) em áreas cultivadas com soja na Amazônia Legal, integrando o rigor da modelagem biofísica, representada por esquemas como o ISBA, com a flexibilidade e a capacidade adaptativa da inteligência artificial. A utilização de dados hiperspectrais obtidos por sensores orbitais possibilitou a captura de variações fenológicas e de respostas espectrais da vegetação com elevado nível de detalhe, enquanto os algoritmos de inteligência artificial favoreceram a extração automatizada de padrões e a predição do comportamento ambiental em diferentes escalas temporais e espaciais.

A relevância desta tese manifesta-se tanto na inovação metodológica quanto em sua aplicabilidade prática, ao contribuir para o aprimoramento de sistemas de monitoramento de emissões de dióxido de carbono (CO_2) em tempo quase real, ao subsidiar a formulação de políticas públicas voltadas à sustentabilidade e ao fortalecer estratégias de mitigação das mudanças climáticas. Ao avançar o estado da arte da modelagem de fluxos de CO_2 em sistemas agrícolas tropicais, o trabalho oferece subsídios técnicos para a agricultura de precisão, a gestão ambiental e o desenvolvimento de abordagens integradas no campo da ciência climática.

No plano institucional e normativo, a discussão proposta está alinhada a referenciais internacionais e nacionais sobre mudanças climáticas, inventários de emissões e uso da terra, incluindo relatórios do IPCC, estudos de síntese sobre o papel da Amazônia no ciclo do carbono e painéis públicos de monitoramento de emissões (IPCC, 2021; ARTAXO et al., 2022; MCTI,

2020; MCTI, 2022; SEEG, 2022; IBGE, 2022).

Do ponto de vista metodológico, a integração entre modelagem física, mineração de dados espaço-temporais, aprendizado de máquina e ciência aberta é consistente com recomendações da literatura especializada em modelagem ambiental e governança de dados científicos (ATLURI et al., 2017; HUANG et al., 2018; DENG, 2018; SMITH et al., 2019; WILKINSON et al., 2016; FERREIRA et al., 2024).

1.1 Importância da cultura da soja na Amazônia Legal

A cultura da soja consolidou-se como um dos principais pilares do agronegócio brasileiro, exercendo papel estratégico tanto na balança comercial quanto na organização socioeconômica das regiões produtoras. Na Amazônia Legal, região que abrange nove estados e aproximadamente 59% do território nacional, a expansão do cultivo da soja configura-se como um fenômeno relativamente recente, porém de ampla repercussão territorial e ambiental. Impulsionado por políticas de desenvolvimento regional, pela ampliação da infraestrutura logística e por incentivos ao cultivo mecanizado, esse avanço tem promovido transformações significativas nas paisagens, na organização dos territórios produtivos e nas dinâmicas socioambientais locais (MEDEIROS et al., 2023).

Nas últimas duas décadas, a expansão do cultivo da soja na Amazônia Legal tem ocorrido de forma acelerada, com destaque para o estado de Mato Grosso, onde se concentra uma parcela significativa da produção regional. De acordo com levantamento do Instituto de Pesquisa Ambiental da Amazônia, mais de 17% da produção nacional de soja já se localiza em municípios amazônicos, evidenciando a consolidação dessa região como uma fronteira agrícola estratégica (IPAM, 2021). No contexto mato-grossense, áreas como Sapezal, Campo Novo do Parecis, Campos de Júlio e Tangará da Serra exemplificam esse processo de expansão, refletindo transformações no uso da terra, no sistema produtivo agrícola e nas interações entre a atividade agrícola e os componentes ambientais (EMBRAPA, 2022).

A relevância da soja para a Amazônia Legal transcende o campo estritamente econômico, uma vez que essa cultura influencia cadeias logísticas, dinâmicas fundiárias, relações trabalhistas e políticas públicas de uso do solo. Em regiões produtoras do estado de Mato Grosso, a soja consolidou-se como elemento estruturante do espaço agrário, associada a práticas de

monocultura, uso intensivo de insumos e crescente mecanização, aspectos que promovem ganhos de produtividade, mas também impõem desafios ambientais e climáticos relevantes, como o aumento das emissões de gases de efeito estufa (FERREIRA et al., 2020).

Do ponto de vista científico, o cultivo da soja na Amazônia Legal configura-se como um laboratório natural para a investigação das interações entre agricultura intensiva e ecossistemas sensíveis. A complexidade biofísica da região, associada à dinâmica de expansão da fronteira agrícola, torna essa cultura um marcador estratégico para estudos que envolvem monitoramento climático, modelagem do ciclo do carbono, sensoriamento remoto e a aplicação de técnicas de inteligência artificial na análise e gestão do território (BATISTA et al., 2023).

Diante desse contexto, compreender o papel da soja na Amazônia Legal ultrapassa um exercício meramente descritivo e torna-se condição fundamental para o desenvolvimento de abordagens que conciliem produtividade agrícola, sustentabilidade ambiental e responsabilidade climática. A escolha dessa cultura como objeto de estudo nesta tese fundamenta-se em sua centralidade econômica, em seus impactos ambientais mensuráveis e em seu potencial para subsidiar a geração de indicadores estratégicos voltados à mitigação de emissões e ao planejamento de políticas públicas integradas.

1.2 Limitações dos métodos tradicionais

Os métodos tradicionais utilizados na quantificação dos fluxos de dióxido de carbono (CO_2) em ambientes agrícolas, especialmente aqueles baseados em abordagens diretas de coleta de dados *in situ*, apresentam limitações de natureza técnica, operacional e espacial. Embora amplamente empregados em estações meteorológicas, torres de fluxo e câmaras de assimilação, esses métodos demonstram restrições quanto à escalabilidade e à capacidade de representar, com precisão, a heterogeneidade dos agroecossistemas, particularmente em regiões extensas e ambientalmente complexas como a Amazônia Legal (BALDOCCHI et al., 2001).

Uma das principais restrições desses métodos reside na dependência de equipamentos de alto custo e elevada especialização técnica, como os sistemas de covariância de vórtices turbulentos (*eddy covariance*), os quais exigem manutenção contínua, calibração rigorosa e infraestrutura operacional estável. Adicionalmente, tais sistemas apresentam alcance espacial restrito, o que limita a extrapolação dos resultados para grandes áreas de cultivo (BALDOCCHI,

2003). Em regiões tropicais, a escassez de séries temporais contínuas e representativas, decorrente de interrupções operacionais ou falhas de energia e comunicação, compromete a consistência das análises de longo prazo (CHAPIN et al., 2006).

Outra limitação relevante dos métodos convencionais está associada à dificuldade de integrar dados multivariados provenientes de diferentes fontes, como atributos edáficos, condições meteorológicas, informações fenológicas e respostas fisiológicas das culturas. Modelos puramente determinísticos, a exemplo do ISBA em sua forma não otimizada, dependem de um conjunto amplo de variáveis de entrada e de parametrizações que, em muitos casos, não representam adequadamente a dinâmica das lavouras tropicais (MAHFOUF; NOILHAN, 1996a). Esses modelos requerem calibração localizada e atualização frequente de parâmetros físicos para manter consistência em diferentes contextos ambientais, o que frequentemente limita sua aplicabilidade operacional (DELIRE et al., 2020a).

A abordagem manual e pontual adotada por métodos convencionais impõe dificuldades na identificação de eventos extremos ou anomalias, como secas prolongadas, surtos de pragas ou mudanças abruptas no uso do solo, os quais afetam de forma significativa o balanço de carbono. Nesses contextos, a baixa resolução temporal dessas metodologias pode mascarar variações críticas nos processos de emissão e absorção de dióxido de carbono (CO_2) ao longo do ciclo agrícola (LAW et al., 2002). Ademais, o tratamento estatístico dos dados coletados localmente, em geral, apresenta limitações para representar relações não lineares e padrões complexos característicos dos sistemas ambientais.

Dessa forma, as limitações dos métodos tradicionais extrapolam aspectos meramente operacionais e abrangem questões conceituais e epistêmicas. A rigidez metodológica dificulta a adaptação às especificidades amazônicas, a limitada integração com dados de sensoriamento remoto compromete a eficiência espacial e a baixa capacidade preditiva restringe sua aplicação no suporte a políticas públicas de gestão ambiental. Esses fatores fundamentam a adoção de abordagens híbridas, apoiadas em inteligência artificial, capazes de superar tais restrições e de promover avanços na modelagem dos fluxos de dióxido de carbono (CO_2) com maior resolução, abrangência e aplicabilidade.

1.3 Justificativa

A presente tese justifica-se pela necessidade de desenvolver métodos inovadores e confiáveis para o monitoramento do fluxo de dióxido de carbono (CO_2) em ambientes agrícolas tropicais, com ênfase na cultura da soja na Amazônia Legal. Considerando as limitações operacionais, espaciais e analíticas dos métodos tradicionais, torna-se essencial a integração de tecnologias emergentes, como o sensoriamento remoto hiperespectral e a inteligência artificial, a fim de obter estimativas mais precisas, consistentes e replicáveis dos fluxos de carbono.

Ao propor um modelo híbrido fundamentado na integração entre dados espectrais e algoritmos de aprendizado profundo, esta pesquisa busca suprir lacunas metodológicas ainda existentes na modelagem ambiental, oferecendo uma abordagem metodologicamente consistente, escalável e cientificamente fundamentada. A relevância da proposta manifesta-se tanto em sua aplicabilidade prática, no contexto de políticas públicas climáticas e da gestão sustentável da agricultura, quanto em sua contribuição teórica para o avanço do conhecimento interdisciplinar nas áreas de ciência ambiental, engenharia agrícola e tecnologias geoespaciais.

A crescente complexidade dos sistemas ambientais, aliada à intensificação da agricultura em regiões tropicais como a Amazônia Legal, impõe a necessidade de ferramentas analíticas capazes de lidar com grandes volumes de dados, múltiplas variáveis e elevada variabilidade espacial e temporal. Nesse contexto, o sensoriamento remoto (SR) e a inteligência artificial (IA) configuram-se como tecnologias complementares e estratégicas para o monitoramento e a modelagem de fluxos ambientais, especialmente aqueles associados ao dióxido de carbono (CO_2).

O sensoriamento remoto tem apresentado avanços expressivos nas últimas décadas, possibilitando a aquisição sistemática de dados multiespectrais e hiperespectrais com elevada resolução temporal e espacial. Esses dados fornecem informações relevantes sobre o estado fisiológico da vegetação, a estrutura do dossel, índices espectrais de biomassa, umidade e outros parâmetros biofísicos essenciais para a estimativa de fluxos de dióxido de carbono (CO_2) (THENKABAIL et al., 2012). No contexto agrícola, sensores orbitais e plataformas aéreas não tripuladas têm demonstrado aplicabilidade na detecção precoce de estresses, na estimativa de produtividade e na avaliação de impactos ambientais (TONG et al., 2020).

Contudo, o aproveitamento pleno dessas informações demanda técnicas analíticas avan-

çadas capazes de superar as limitações dos métodos estatísticos clássicos. Nesse contexto, a inteligência artificial assume papel central, uma vez que algoritmos de aprendizado de máquina (machine learning) e aprendizado profundo (deep learning) mostram-se particularmente adequados para a análise de dados complexos e não lineares, como aqueles oriundos do sensoriamento remoto. Essas abordagens possibilitam a identificação de padrões latentes, a realização de classificações consistentes e a geração de previsões com maior acurácia quando comparadas aos modelos tradicionais (ZHANG et al., 2019).

Além de sua capacidade técnica, a adoção do sensoriamento remoto e da inteligência artificial alinha-se a princípios contemporâneos da ciência aberta, da automação analítica e da ampliação do acesso a dados ambientais. Esses aspectos são fundamentais para subsidiar políticas públicas mais eficazes de mitigação das mudanças climáticas e para promover práticas agrícolas sustentáveis baseadas em evidências científicas. Na Amazônia Legal, onde a extensão territorial e os desafios logísticos limitam o monitoramento convencional, tais tecnologias configuram-se como uma oportunidade concreta de inovação e transformação no acompanhamento dos fluxos ambientais.

Dessa forma, a abordagem adotada nesta tese consolida-se como uma alternativa metodológica consistente para o enfrentamento dos desafios associados ao monitoramento do fluxo de dióxido de carbono em sistemas agrícolas tropicais. Ao articular diferentes dimensões analíticas em uma estrutura integrada, o estudo estabelece bases metodológicas para investigações futuras e para o aprimoramento de estratégias de monitoramento ambiental aplicadas ao contexto da Amazônia Legal.

1.4 Hipótese

Parte-se da hipótese de que a utilização de um modelo computacional híbrido, que integre técnicas de Inteligência Artificial com dados provenientes do sensoriamento remoto hiperespectral orbital, possibilita a obtenção de estimativas mais precisas, replicáveis e espacialmente explícitas do fluxo de dióxido de carbono (CO_2) em áreas cultivadas com soja na Amazônia Legal, quando comparadas àquelas geradas por métodos tradicionais ou por modelos físicos isolados.

Com base nessa hipótese, os objetivos apresentados a seguir estruturam a estratégia de investigação desta tese e asseguram alinhamento entre fundamentação teórica, desenho

metodológico, processamento de dados e avaliação dos resultados.

1.5 Objetivo Geral

Desenvolver e estruturar um modelo computacional híbrido para a simulação do fluxo de dióxido de carbono (CO_2) em áreas cultivadas com soja na Amazônia Legal, integrando técnicas de inteligência artificial a dados provenientes do sensoriamento remoto hiperespectral orbital. O modelo tem como finalidade representar, de forma espacialmente explícita, a dinâmica dos fluxos de CO_2 em sistemas agrícolas tropicais, a partir da incorporação de variáveis biofísicas e espectrais, constituindo uma base metodológica consistente para o monitoramento ambiental e para análises avançadas do ciclo do carbono no contexto da agricultura tropical.

1.6 Objetivos Específicos

Delimitar a área de estudo e as áreas cultivadas com soja na Amazônia Legal a partir de dados temáticos (MapBiomass) e do recorte espacial da cena hiperespectral utilizada na pesquisa.

Pré-processar e organizar os dados hiperespectrais orbitais, garantindo consistência radiométrica e espacial, e alinhar os produtos ao mesmo sistema de referência e resolução do grid de análise.

Selecionar e calcular índices espectrais e variáveis derivadas com potencial relação com parâmetros biofísicos da cultura, estruturando um conjunto inicial de atributos para modelagem do fluxo de CO_2 .

Integrar variáveis meteorológicas da estação adotada ao conjunto espectral, com padronização temporal e compatibilização com o período de interesse do ciclo da cultura.

Construir a base integrada de atributos (espectrais, biofísicos e meteorológicos), com controle de qualidade, rastreabilidade e documentação dos procedimentos de geração e validação.

Parametrizar os elementos essenciais do modelo de superfície-vegetação-atmosfera, com ênfase no esquema ISBA, definindo entradas, hipóteses operacionais e condições iniciais coerentes com o sistema agrícola tropical analisado.

Treinar e avaliar modelos de aprendizado supervisionado para estimar o fluxo de CO_2 a

partir da base integrada, comparando desempenho por métricas quantitativas apropriadas (por exemplo, RMSE, MAE e R^2).

Analisar a consistência, as incertezas e as limitações do modelo híbrido, identificando sensibilidade a variáveis de entrada, incertezas e condições de generalização no contexto estudado.

1.7 Fundamentação teórica e revisão da literatura

Este capítulo apresenta os fundamentos teóricos e científicos que sustentam o desenvolvimento do modelo computacional híbrido proposto nesta tese, estabelecendo a base conceitual necessária para as escolhas metodológicas adotadas nos Capítulos 2 e 3. A revisão da literatura é organizada de forma funcional e progressiva, com foco nas tecnologias e abordagens diretamente relacionadas à estimativa do fluxo de dióxido de carbono (CO_2) em sistemas agrícolas tropicais, a partir da integração entre sensoriamento remoto hiperespectral, modelagem biofísica e técnicas de inteligência artificial.

A estrutura do capítulo reflete o encadeamento lógico do modelo desenvolvido. Inicialmente, são apresentados os fundamentos do sensoriamento remoto aplicado à agricultura, com ênfase no sensoriamento remoto hiperespectral orbital e em suas potencialidades para a caracterização biofísica da vegetação. Em seguida, são discutidos os principais índices e variáveis espectrais associados à biomassa, ao vigor vegetativo e às trocas de carbono, estabelecendo sua relevância para a modelagem do fluxo de CO_2 em lavouras de soja.

Na sequência, o capítulo aborda os modelos de simulação do ciclo do carbono, com destaque para as abordagens físico-determinísticas de superfície–vegetação–atmosfera, em especial o esquema ISBA, que fundamenta a representação dos processos biofísicos utilizados no modelo híbrido. Esses modelos são discutidos a partir de suas hipóteses, potencialidades e limitações, preparando o terreno para a incorporação de técnicas de aprendizado supervisionado.

Os fundamentos da inteligência artificial aplicados à modelagem ambiental são apresentados com foco nos algoritmos efetivamente empregados ou comparados nesta pesquisa, destacando seu papel na captura de relações não lineares entre variáveis espectrais, meteorológicas e biofísicas. A discussão privilegia abordagens de aprendizado supervisionado utilizadas na estimativa de variáveis contínuas, em consonância com a natureza do problema investigado.

Complementarmente, é desenvolvida uma revisão integrativa da literatura científica recente, direcionada à identificação de estratégias consolidadas e lacunas metodológicas na integração entre dados hiperespectrais, modelos biofísicos e algoritmos de inteligência artificial para a estimativa de fluxos de CO₂ em ambientes agrícolas. Essa revisão é conduzida de forma orientada ao problema, servindo como suporte à definição do arcabouço metodológico adotado nos capítulos subsequentes.

Por fim, o capítulo apresenta uma análise crítica dos desafios técnicos e operacionais associados à aplicação dessas tecnologias em ambientes tropicais, com ênfase na Amazônia Legal. São discutidas limitações relacionadas à variabilidade atmosférica, aos efeitos de ruído em dados hiperespectrais e à necessidade de calibração regional, bem como as potencialidades específicas de sensores hiperespectrais orbitais, como o EO-1 Hyperion, para a análise espacialmente explícita dos processos de troca de carbono em sistemas agrícolas.

Dessa forma, a fundamentação teórica apresentada neste capítulo estabelece um núcleo conceitual consistente e coerente, diretamente alinhado ao desenvolvimento do modelo computacional híbrido descrito nos Capítulos 2, 3 e 4, assegurando consistência científica entre a revisão da literatura, a metodologia adotada, os resultados e a análise desenvolvida na discussão.

1.8 Sensoriamento Remoto Hiperespectral na Agricultura

No campo do sensoriamento remoto, a distinção entre sensores multiespectrais e hiperespectrais é fundamental para compreender as possibilidades tecnológicas disponíveis no monitoramento agrícola e ambiental. Sensores multiespectrais capturam imagens em um número reduzido de bandas espectrais discretas e relativamente largas, geralmente entre três e dez faixas, como ocorre nos satélites Sentinel-2 e Landsat-8. Em contraste, sensores hiperespectrais realizam medições contínuas ao longo do espectro eletromagnético, com centenas de bandas adjacentes e estreitas, permitindo uma caracterização mais detalhada da resposta espectral dos alvos observados (THENKABAIL et al., 2012).

No contexto agrícola, essa distinção implica diferenças diretas na profundidade das análises biofísicas. Sensores multiespectrais são amplamente empregados no mapeamento do uso e cobertura do solo, no cálculo de índices de vegetação clássicos, como o NDVI, e na avaliação geral do vigor da vegetação. Contudo, a largura das bandas e o espaçamento espectral limitam a

detecção de variações sutis relacionadas à composição química da vegetação e a sinais precoces de estresse fisiológico. Por sua vez, sensores hiperespectrais oferecem maior resolução espectral, possibilitando a identificação de pequenas variações nos pigmentos foliares, na estrutura celular, no teor de água e no conteúdo de nitrogênio, características diretamente associadas à dinâmica fisiológica das plantas (USCUPLIC et al., 2021).

A elevada resolução espectral também influencia a aplicação de algoritmos de aprendizado de máquina. Dados hiperespectrais fornecem assinaturas espectrais contínuas, ampliando o potencial para regressão de variáveis biofísicas e classificação precisa de alvos, desde que submetidos a técnicas adequadas de redução de dimensionalidade e controle de multicolinearidade. Em comparação, imagens multiespectrais, embora mais acessíveis e menos exigentes em termos computacionais, apresentam limitações para a modelagem de processos dinâmicos, como a assimilação e a emissão de CO₂, especialmente em sistemas agrícolas tropicais complexos (HUNT et al., 2013).

Do ponto de vista operacional, sensores multiespectrais são amplamente disponibilizados por programas abertos de observação da Terra, como Landsat, MODIS e Sentinel, sendo largamente utilizados por instituições de pesquisa e órgãos públicos. Sensores hiperespectrais orbitais, por outro lado, ainda apresentam disponibilidade mais restrita, estando associados a missões específicas, como o EO-1 Hyperion, o EnMAP e o PRISMA. Apesar dessas limitações, estudos recentes demonstram a viabilidade do uso de dados hiperespectrais em regiões tropicais, inclusive na Amazônia, para análises agrícolas e ambientais de maior precisão (MARELLO et al., 2022).

De modo geral, enquanto sensores multiespectrais permanecem adequados para análises operacionais e de larga escala, sensores hiperespectrais representam um avanço metodológico essencial para investigações que exigem elevada sensibilidade espectral. No contexto desta tese, a adoção de dados hiperespectrais permite atender a necessidade de captar variações espectrais associadas à fisiologia da soja e aos processos relacionados ao fluxo de CO₂, especialmente em uma região caracterizada por elevada heterogeneidade ambiental, como a Amazônia Legal (WANG et al., 2021).

1.8.1 Faixas espectrais relevantes para a vegetação

A resposta espectral da vegetação varia ao longo do espectro eletromagnético, sendo mais pronunciada em faixas associadas a processos bioquímicos e estruturais das plantas. As regiões de maior interesse concentram-se no espectro visível (400–700 nm), no infravermelho próximo (NIR, aproximadamente 700–1300 nm) e no infravermelho de ondas curtas (SWIR, entre 1300–2500 nm). Essas faixas são sensíveis a pigmentos fotossintéticos, à estrutura do dossel vegetal, ao teor de água foliar e à composição celular, fornecendo subsídios para a modelagem de variáveis como biomassa, produtividade e trocas de carbono (THENKABAIL et al., 2011).

No espectro visível, a faixa do azul (450–495 nm) relaciona-se à absorção por carotenoides e antocianinas, enquanto a faixa do vermelho (620–680 nm) é fortemente absorvida pela clorofila-a, sendo amplamente utilizada em índices de vegetação. A região do verde (500–570 nm) apresenta maior reflectância em vegetação saudável, permitindo a identificação de estresses visuais. Entretanto, essas faixas apresentam limitações na detecção precoce de alterações fisiológicas mais sutis (ZHANG et al., 2020).

O infravermelho próximo é particularmente relevante para a avaliação da estrutura interna das folhas e da densidade do dossel. Vegetações com maior integridade celular e maior cobertura tendem a apresentar elevada reflectância nessa região. A combinação do NIR com bandas do vermelho ou do azul origina índices amplamente utilizados em estudos agrícolas, como NDVI e EVI, empregados em análises fenológicas e estimativas indiretas da assimilação de carbono (HUETE et al., 2002).

Já o infravermelho de ondas curtas fornece informações relacionadas ao conteúdo de água e à composição bioquímica da vegetação. Faixas próximas a 1400–1500 nm e 1900–2000 nm são sensíveis à umidade foliar, enquanto regiões entre 2100–2300 nm têm sido associadas à estimativa de compostos como lignina, celulose e nitrogênio. Esses parâmetros influenciam diretamente os processos de fotossíntese e respiração, sendo relevantes para a análise do fluxo de CO₂ em sistemas agrícolas (CHEN et al., 2019).

A seleção criteriosa dessas faixas espectrais é determinante para o desempenho de modelos preditivos baseados em inteligência artificial. A identificação prévia das bandas mais informativas permite reduzir redundâncias, otimizar o processamento dos dados e aumentar a eficiência computacional, aspectos essenciais para a aplicação de modelos híbridos em estudos

ambientais de larga escala (JIA et al., 2021).

1.8.2 Índices espectrais aplicáveis à cultura da soja

A cultura da soja apresenta comportamento espectral característico, o que possibilita sua análise por meio de índices derivados do sensoriamento remoto. Esses índices, obtidos a partir de combinações específicas de bandas espectrais, são amplamente utilizados no monitoramento do estado fisiológico das plantas, da biomassa aérea e do potencial produtivo. Entre os índices mais empregados destacam-se o NDVI e o GNDVI, que exploram a alta reflectância no infravermelho próximo e a absorção no vermelho ou no verde para estimar o vigor vegetativo (HUETE et al., 2002).

O NDVI tem sido amplamente aplicado no acompanhamento do crescimento da soja e na identificação de padrões fenológicos e anomalias associadas a estresses hídricos e nutricionais. Contudo, em estágios avançados de desenvolvimento da cultura, sua resposta pode apresentar saturação em áreas de alta densidade de biomassa. Para contornar essa limitação, índices como o EVI e o SAVI incorporam correções relacionadas ao efeito do solo e à atmosfera, apresentando melhor desempenho em condições de cobertura vegetal densa (JIA et al., 2021).

Índices baseados na região do red edge, como o REIP e o NDRE, têm se destacado por sua elevada sensibilidade à concentração de clorofila e ao vigor das plantas. Essas características tornam tais índices particularmente adequados para a soja, pois permitem a detecção de alterações fisiológicas mesmo em fases iniciais do ciclo fenológico. Estudos apontam correlações consistentes entre esses índices e variáveis biofísicas como índice de área foliar e teor de nitrogênio, ambos relacionados aos processos de assimilação de carbono (XU et al., 2019).

Além disso, índices como o PRI têm sido utilizados para avaliar a eficiência do uso da luz e respostas fisiológicas de curto prazo, oferecendo subsídios para análises mais dinâmicas do metabolismo vegetal. A integração desses índices em modelos baseados em inteligência artificial tem ampliado sua capacidade preditiva, tornando-os componentes centrais em abordagens híbridas voltadas à estimativa do fluxo de CO₂ em sistemas agrícolas tropicais (ZHANG et al., 2021).

1.8.3 Satélites e sensores utilizados

A evolução das plataformas orbitais de sensoriamento remoto ampliou significativamente as possibilidades de observação da dinâmica agrícola e da vegetação em escala regional. Entre os sensores hiperespectrais orbitais, destaca-se o EO-1 Hyperion, que opera na faixa espectral de aproximadamente 400 a 2500 nm, com mais de 200 bandas espectrais e resolução espacial de 30 metros. Esse sensor possibilita a análise detalhada de parâmetros biofísicos da vegetação, como teor de clorofila, estrutura foliar e estresse hídrico, sendo particularmente relevante para estudos voltados à modelagem do ciclo do carbono (LOIZZO et al., 2018).

Complementarmente, o sensor MODIS, a bordo dos satélites Terra e Aqua, apresenta resolução espacial moderada, variando de 250 m a 1 km, mas oferece elevada frequência temporal, com imagens diárias. Essa característica o torna adequado para análises fenológicas, construção de séries temporais de índices de vegetação e monitoramento contínuo da cobertura vegetal, especialmente em regiões extensas e de difícil acesso, como a Amazônia Legal (TOOMEY et al., 2013).

A combinação entre sensores de alta resolução espectral, como o Hyperion, e sensores de alta resolução temporal, como o MODIS, constitui uma estratégia relevante para a modelagem ambiental. Enquanto o Hyperion fornece riqueza espectral para análises detalhadas em escala local, o MODIS garante continuidade temporal, permitindo a contextualização sazonal dos processos observados. A integração dessas fontes de dados sustenta abordagens híbridas que associam modelagem biofísica e inteligência artificial, ampliando a consistência interpretativa das estimativas do fluxo de CO₂ em áreas agrícolas (GUZINSKI et al., 2021).

Essa sinergia entre sensores multiescalares é particularmente importante no contexto amazônico, onde a variabilidade atmosférica e as limitações logísticas dificultam a coleta de dados *in situ*. Assim, a seleção dos sensores adotados nesta tese foi orientada pela necessidade de conciliar detalhamento espectral, cobertura espacial e consistência temporal, garantindo coerência com os objetivos metodológicos desenvolvidos nos capítulos subsequentes.

1.9 Índices de Vegetação e Relação com Biomassa e Fluxo de CO₂

Os índices de vegetação são métricas derivadas da combinação de bandas espectrais sensíveis à absorção por pigmentos fotossintéticos e à reflectância associada à estrutura foliar e ao dossel. Em sistemas agrícolas, esses índices atuam como proxies de variáveis biofísicas, como teor de clorofila, índice de área foliar (LAI) e densidade do dossel, e por isso têm sido empregados na estimativa indireta de biomassa e na análise de processos associados às trocas de carbono (XUE et al., 2017).

A relação entre índices espectrais e o fluxo de CO₂ decorre do vínculo fisiológico entre vigor vegetativo e atividade fotossintética. Índices como NDVI, EVI e SAVI apresentam sensibilidade às fases fenológicas e a condições de estresse, permitindo representar variações associadas à assimilação de carbono, particularmente em culturas como a soja, cuja dinâmica fotossintética é altamente responsiva a condições hídricas e meteorológicas (SILVA et al., 2011; GOMEZ et al., 2019; LI et al., 2021; ZHANG et al., 2020; ZHANG et al., 2021).

Em dados hiperespectrais, o uso de bandas estreitas possibilita índices mais sensíveis a mudanças bioquímicas e fisiológicas. Nesse contexto, destacam-se métricas baseadas no red edge, como NDRE e REIP, associadas à concentração de clorofila e à estrutura foliar, bem como índices fisiológicos como o PRI, relacionado à eficiência do uso da radiação e a respostas rápidas do aparato fotossintético (GITELSON et al., 2003; CLEVERS; GITELSON, 2013; GAMON et al., 2016). Adicionalmente, índices que incorporam SWIR podem contribuir para representar estresse hídrico e variações no teor de água, condição que afeta diretamente os fluxos de carbono por impactar fotossíntese e respiração (CHEN et al., 2019).

No contexto desta tese, esses índices e variáveis derivadas compõem o conjunto de atributos gerados e utilizados no Capítulo 2, além de sustentarem a etapa de modelagem híbrida e a avaliação preditiva descritas nos Capítulos 2 e 3. Assim, a seleção de índices privilegia métricas com fundamentação biofísica e potencial de generalização para sistemas agrícolas tropicais, mantendo coerência entre revisão, processamento, modelagem e análise dos resultados.

1.10 Machine Learning aplicado à modelagem ambiental

O avanço das tecnologias de sensoriamento remoto, aliado ao crescimento da capacidade de processamento de dados, tem impulsionado o uso de algoritmos de Machine Learning (ML) em aplicações ambientais e agrícolas. Machine Learning refere-se a um subconjunto da inteligência artificial que permite a construção de modelos preditivos a partir de dados, sem a necessidade de regras explícitas programadas, sendo particularmente útil em sistemas complexos nos quais múltiplas variáveis interagem de forma não linear (MITCHELL, 1997).

No contexto da agricultura tropical, algoritmos de ML têm sido utilizados para classificar coberturas do solo, estimar rendimento de cultivos e prever variáveis biofísicas, como biomassa e indicadores associados ao fluxo de CO₂. Essas aplicações dependem da qualidade dos dados de entrada, que podem incluir índices espectrais, variáveis meteorológicas e informações de solo, de modo que bases representativas da região de estudo são determinantes para a acurácia e a generalização dos modelos (MA et al., 2019).

Entre os algoritmos frequentemente empregados em sensoriamento remoto e agricultura de precisão destacam-se métodos baseados em árvores, como Random Forest e XGBoost, além de modelos mais simples utilizados como referência comparativa. Nesta tese, tais abordagens são discutidas com foco em sua adequação à integração de dados espectrais e variáveis ambientais, conforme o pipeline metodológico apresentado no Capítulo 2, no qual o aprendizado supervisionado é explorado para apoiar a estimativa do fluxo de CO₂ em áreas agrícolas e cujos resultados são apresentados no Capítulo 3.

1.11 Random Forest

O algoritmo Random Forest, proposto por Breiman (2001), é amplamente utilizado em tarefas de regressão e classificação na aprendizagem supervisionada. Seu funcionamento baseia-se na construção de múltiplas árvores de decisão a partir de amostras aleatórias do conjunto de dados (bootstrap) e na seleção aleatória de subconjuntos de variáveis em cada nó. A predição final resulta da média (regressão) ou da votação majoritária (classificação), o que tende a reduzir variância e mitigar sobreajuste (BREIMAN, 2001).

No sensoriamento remoto aplicado à agricultura, Random Forest apresenta desempenho

consistente ao lidar com dados de alta dimensionalidade e colinearidade, características frequentes em imagens hiperespectrais. Além disso, permite estimar a importância relativa das variáveis de entrada, oferecendo suporte interpretativo na identificação de bandas e índices mais associados a variáveis biofísicas como biomassa e LAI, que se relacionam aos processos de assimilação de carbono (BELGIU; DRAGUT, 2016; STENZEL et al., 2020).

No contexto desta tese, o Random Forest é considerado como uma alternativa relevante para modelagem supervisionada com dados espectrais e variáveis ambientais, contribuindo para a etapa de comparação e avaliação de desempenho descrita nos Capítulos 2 e 3.

1.12 Modelos de referência comparativa: Regressão Logística e KNN

Além dos algoritmos baseados em árvores de decisão e dos métodos de ensemble, modelos clássicos de aprendizado supervisionado, como a Regressão Logística e o K-Nearest Neighbors (KNN), ocupam lugar relevante na literatura de sensoriamento remoto, classificação temática e análise ambiental. Embora esses métodos não constituam o núcleo metodológico desta tese, sua discussão permite contextualizar os limites de abordagens mais simples diante de problemas ambientais caracterizados por variáveis contínuas, relações não lineares, dependência temporal e integração de dados espectrais, meteorológicos e biofísicos.

A Regressão Logística é um modelo estatístico empregado principalmente em problemas de classificação. Sua formulação baseia-se na função logística, que transforma uma combinação linear de variáveis explicativas em uma probabilidade associada à ocorrência de determinado evento. Em aplicações de sensoriamento remoto, esse tipo de modelo pode ser utilizado na discriminação de classes de uso e cobertura da terra, na identificação de áreas agrícolas ou na separação de condições ambientais discretas, como presença ou ausência de determinado padrão espectral ou estado fisiológico da vegetação (HOSMER et al., 2013; MORGAN et al., 2010).

Apesar de sua interpretabilidade e de sua simplicidade computacional, a Regressão Logística apresenta limitações importantes quando o problema de pesquisa envolve estimativas contínuas, como a Troca Líquida de Ecossistema (NEE), a Produtividade Primária Bruta (GPP) e a Respiração do Ecossistema (Reco). Essas variáveis não representam classes discretas, mas grandezas numéricas associadas a processos ecofisiológicos, meteorológicos e espectrais que variam continuamente no tempo e no espaço. Por essa razão, a aplicação direta da Regressão

Logística ao problema central desta tese não seria adequada, salvo em formulações auxiliares de classificação, como a categorização de pixels em classes de maior ou menor atividade fotossintética ou a distinção entre condições de emissão e absorção líquida de carbono.

No contexto desta pesquisa, a Regressão Logística é tratada como referência conceitual de modelos lineares probabilísticos. Sua inclusão na fundamentação teórica permite explicitar a diferença entre modelos de alta interpretabilidade, porém mais restritivos, e algoritmos capazes de representar interações não lineares entre variáveis ambientais, espectrais e biofísicas. Essa distinção é necessária porque os fluxos de CO₂ em sistemas agrícolas tropicais resultam da interação simultânea entre radiação solar, temperatura, estrutura do dossel, disponibilidade hídrica, resposta espectral da vegetação e processos de assimilação e respiração, o que exige modelos com maior flexibilidade de representação.

O K-Nearest Neighbors (KNN), por sua vez, é um método não paramétrico baseado na proximidade entre observações no espaço de atributos. Em tarefas de classificação, a classe de uma nova amostra é definida a partir das classes predominantes entre seus vizinhos mais próximos. Em tarefas de regressão, a predição pode ser obtida pela média ou por combinações ponderadas dos valores observados nesses vizinhos. Essa característica torna o KNN um método intuitivo e útil como referência inicial em problemas nos quais a proximidade entre amostras expressa relações relevantes entre as variáveis de entrada e a variável de saída (SHARMA et al., 2020; ALTENBURGER et al., 2021).

Entretanto, o desempenho do KNN depende fortemente da escala das variáveis, da métrica de distância adotada e da escolha do parâmetro k . Em bases hiperespectrais, essas limitações tornam-se mais evidentes, pois o elevado número de bandas e índices pode gerar redundância, multicolinearidade e perda de capacidade discriminativa das distâncias entre amostras. Nesses casos, a aplicação do KNN normalmente exige normalização, seleção de atributos, redução de dimensionalidade ou construção prévia de variáveis mais informativas, de modo a reduzir distorções decorrentes da alta dimensionalidade dos dados.

Para a modelagem de fluxos de CO₂, o KNN também apresenta restrições conceituais. Embora possa ser utilizado em tarefas de regressão, sua lógica de predição baseada em vizinhança local não incorpora explicitamente os mecanismos físicos que controlam a fotossíntese, a respiração e a troca líquida de carbono. Assim, o método tende a reproduzir padrões observados em situações semelhantes, mas apresenta menor capacidade de extrapolação para condições

ambientais pouco representadas no conjunto de treinamento. Essa característica é particularmente relevante em sistemas agrícolas tropicais, nos quais a variabilidade temporal, espectral e meteorológica pode ser elevada.

Dessa forma, Regressão Logística e KNN são considerados nesta tese como modelos de referência comparativa, úteis para delimitar o alcance de métodos clássicos diante da complexidade do problema investigado. A análise desses algoritmos contribui para justificar a adoção de abordagens mais adequadas à regressão não linear, à integração de variáveis espectrais e ambientais e à correção residual de modelos biofísicos. Essa discussão prepara a transição para o XGBoost, algoritmo central da modelagem híbrida proposta nesta tese, cuja capacidade de representar interações entre variáveis heterogêneas será aprofundada na seção seguinte.

1.13 XGBoost

O Extreme Gradient Boosting (XGBoost) constitui um dos algoritmos de aprendizado supervisionado mais relevantes para problemas de regressão e classificação envolvendo dados heterogêneos, relações não lineares e grande número de variáveis explicativas. Sua formulação deriva da família dos métodos de boosting por gradiente, nos quais modelos fracos, geralmente árvores de decisão, são combinados sequencialmente para reduzir erros residuais e melhorar a capacidade preditiva do conjunto. Diferentemente de abordagens baseadas em uma única árvore, o XGBoost constrói um ensemble aditivo, no qual cada árvore posterior é ajustada considerando os erros remanescentes das árvores anteriores, permitindo representar interações complexas entre variáveis ambientais, espectrais e biofísicas (FRIEDMAN, 2001; CHEN; GUESTRIN, 2016).

No contexto da modelagem ambiental, essa característica é particularmente relevante porque os processos associados ao fluxo de CO₂ em sistemas agrícolas não dependem de relações lineares simples entre variáveis isoladas. A Troca Líquida de Ecossistema (NEE), a Produtividade Primária Bruta (GPP) e a Respiração do Ecossistema (Reco) resultam da interação entre radiação incidente, temperatura do ar, umidade, disponibilidade hídrica, estrutura do dossel, atividade fotossintética e resposta espectral da vegetação. Assim, modelos capazes de capturar interações condicionais e padrões não lineares apresentam maior aderência ao problema investigado do que modelos lineares ou métodos baseados exclusivamente em proximidade entre amostras.

O XGBoost diferencia-se de outros algoritmos de árvores por incorporar mecanismos

explícitos de regularização, controle de complexidade e otimização computacional. Durante o treinamento, o algoritmo minimiza uma função objetivo composta por uma função de perda, associada ao erro de predição, e por termos de penalização que limitam a complexidade das árvores. Essa estrutura reduz a tendência ao ajuste excessivo do conjunto de treinamento e favorece a construção de modelos mais parcimoniosos, especialmente em bases com múltiplas variáveis correlacionadas, como é comum em dados hiperespectrais e em séries ambientais (CHEN; GUESTRIN, 2016; HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

A adequação do XGBoost a dados hiperespectrais decorre, em parte, de sua capacidade de lidar com atributos redundantes, interações entre bandas e relações não lineares entre índices espectrais e variáveis biofísicas. Imagens hiperespectrais apresentam elevado número de bandas estreitas e, frequentemente, forte correlação entre regiões espectrais adjacentes. Essa condição pode dificultar o uso de modelos lineares simples e de métodos baseados em distâncias, mas pode ser explorada por algoritmos de árvores, que selecionam divisões informativas ao longo do processo de aprendizagem. No caso desta tese, os atributos espectrais derivados do sensor EO-1 Hyperion, combinados com variáveis meteorológicas e biofísicas, constituem um espaço de entrada no qual o XGBoost pode identificar padrões residuais associados à dinâmica do fluxo de CO₂.

Outro aspecto relevante é a compatibilidade do XGBoost com estratégias de modelagem híbrida físico–dados. Em vez de utilizar o algoritmo como uma caixa-preta destinada a substituir os fundamentos biofísicos do sistema, esta tese adota o XGBoost como componente estatístico de correção residual. Nesse arranjo, o modelo físico reduzido, fundamentado em princípios SVAT/ISBA, fornece uma estimativa inicial da NEE, enquanto o XGBoost aprende a parcela residual associada a simplificações paramétricas, efeitos de escala, interações não explicitamente representadas e variações espectrais ou meteorológicas não totalmente capturadas pela formulação física.

Essa forma de uso do XGBoost é metodologicamente importante porque preserva o vínculo entre a estimativa final e os processos ecofisiológicos do sistema solo–planta–atmosfera. A inteligência artificial, nesse caso, não opera como substituta da modelagem biofísica, mas como mecanismo complementar de ajuste orientado por dados. Tal escolha é coerente com abordagens contemporâneas de integração entre modelos baseados em processos e modelos estatísticos, nas quais o aprendizado de máquina é empregado para reduzir vieses, representar não linearidades e

melhorar o desempenho preditivo sem eliminar a interpretação física do fenômeno modelado.

Em comparação com a Regressão Logística e o KNN, discutidos na seção anterior como modelos de referência comparativa, o XGBoost apresenta maior adequação ao objetivo central desta pesquisa. A Regressão Logística é voltada principalmente à classificação probabilística de eventos discretos, enquanto o KNN depende fortemente da métrica de distância e da representatividade local das amostras. O XGBoost, por sua vez, permite formular diretamente o problema como regressão contínua, lidar com relações não lineares e explorar interações entre variáveis de diferentes naturezas. Essa característica é essencial para estimar variáveis ambientais contínuas, como NEE, GPP e Reco, em sistemas agrícolas tropicais.

Na literatura de sensoriamento remoto e agricultura de precisão, algoritmos baseados em boosting têm sido empregados na estimativa de biomassa, produtividade agrícola, parâmetros biofísicos da vegetação e variáveis ambientais associadas ao ciclo do carbono. Essas aplicações demonstram a pertinência do XGBoost para problemas em que o conjunto de variáveis explicativas combina informações espectrais, meteorológicas e fenológicas, como ocorre na presente tese. Ainda assim, sua aplicação requer controle metodológico, especialmente quanto à separação temporal entre treinamento e validação, à prevenção de vazamento de informação, à interpretação cuidadosa de métricas elevadas de desempenho e à análise das limitações decorrentes da ausência de medições diretas em campo.

No desenho metodológico desta tese, o XGBoost assume, portanto, papel central na etapa de modelagem híbrida residual. Sua função é aprender o erro sistemático do modelo biofísico simplificado em relação à referência adotada, permitindo obter uma estimativa híbrida do fluxo de CO₂. Essa estratégia combina a estrutura explicativa do modelo físico com a capacidade do algoritmo de identificar padrões complexos presentes nos dados, contribuindo para uma representação mais ajustada da dinâmica do carbono em áreas cultivadas com soja na Amazônia Legal.

A escolha do XGBoost também se justifica pela possibilidade de analisar a contribuição relativa das variáveis de entrada, aspecto relevante em estudos ambientais nos quais a interpretabilidade não pode ser negligenciada. Embora a importância de variáveis em modelos de árvore deva ser interpretada com cautela, especialmente em bases com atributos correlacionados, esse recurso permite examinar quais grupos de variáveis, espectrais, meteorológicas ou biofísicas, exercem maior influência na correção residual do modelo. Essa análise contribui para aproximar

o desempenho estatístico da interpretação ambiental, favorecendo a discussão integrada entre sensoriamento remoto, modelagem biofísica e inteligência artificial.

Dessa forma, o XGBoost é incorporado nesta tese não apenas como um algoritmo de regressão eficiente, mas como componente estruturante da modelagem híbrida proposta. Sua adoção decorre da natureza contínua da variável-alvo, da heterogeneidade das fontes de dados, da presença de relações não lineares e da necessidade de corrigir resíduos do modelo físico sem abandonar a coerência ecofisiológica do sistema analisado. Essa fundamentação sustenta as escolhas metodológicas detalhadas no Capítulo 2 e fornece base teórica para a interpretação dos resultados apresentados no Capítulo 3.

1.14 Revisão integrativa

A revisão integrativa é uma metodologia consolidada para sistematização do conhecimento científico, permitindo a síntese crítica de estudos empíricos e teóricos sobre determinado tema. Diferentemente de revisões sistemáticas estritas, ela admite múltiplos delineamentos metodológicos (quantitativos, qualitativos e mistos), o que a torna adequada a temas interdisciplinares, como a integração entre sensoriamento remoto e Inteligência Artificial aplicada à modelagem ambiental (TORRACO, 2005; BALDAM, 2021).

No âmbito da estimativa de fluxo de CO₂ em cultivos agrícolas, a revisão integrativa possibilita organizar e comparar abordagens distintas de integração entre sensores, índices espectrais, modelos físicos e algoritmos de IA, contribuindo para identificar tendências, lacunas e condições de aplicabilidade em contextos tropicais, com atenção à Amazônia Legal (DUARTE et al., 2021).

Metodologicamente, a revisão integrativa foi estruturada em etapas: (i) formulação da pergunta norteadora; (ii) definição de critérios de inclusão e exclusão; (iii) busca sistematizada em bases científicas; (iv) triagem e seleção; (v) extração e categorização dos dados; (vi) avaliação crítica da qualidade; e (vii) síntese interpretativa dos achados (WHITTEMORE; KNAFL, 2005). A pergunta norteadora adotada foi: "Quais abordagens científicas têm sido utilizadas para estimar o fluxo de CO₂ em cultivos agrícolas com suporte de sensoriamento remoto e Inteligência Artificial?".

As buscas foram conduzidas em bases internacionais (Scopus, Web of Science, Science-

Direct e IEEE Xplore), utilizando descritores e operadores booleanos relacionados a fluxo de carbono, sensoriamento remoto (multiespectral/hiperespectral), soja e aprendizado de máquina, com recorte temporal entre 2010 e 2024. Os estudos selecionados foram organizados em planilha estruturada contendo autor, ano, objetivo, tipo de dado (multiespectral/hiperespectral), abordagem/modelo, métricas de desempenho e região geográfica, de modo a permitir síntese por eixos temáticos e suporte às escolhas metodológicas discutidas nos capítulos subsequentes (COOPER, 2017).

1.15 Resultados da Revisão

A análise dos 36 artigos selecionados na revisão integrativa evidencia uma tendência consistente de crescimento no uso de sensores hiperespectrais e algoritmos de Inteligência Artificial para a estimativa do fluxo de dióxido de carbono (CO₂) em sistemas agrícolas. Os estudos mais recentes concentram-se, majoritariamente, na aplicação de algoritmos supervisionados, com destaque para Random Forest, XGBoost e redes neurais profundas (DNN), frequentemente associados a índices espectrais derivados de dados orbitais. Esses trabalhos demonstram ganhos expressivos de desempenho quando comparados a abordagens puramente determinísticas, indicando a maturidade crescente das soluções híbridas no campo da modelagem ambiental (ZHANG et al., 2020).

Grande parte dos estudos analisados dedica-se a culturas agrícolas de ampla relevância econômica, como arroz, milho, trigo e soja, sendo esta última particularmente recorrente em regiões tropicais devido à sua expansão territorial e à sua importância no balanço de carbono agrícola. Observou-se que a integração entre dados espectrais e variáveis meteorológicas, como precipitação, temperatura do ar e radiação solar, contribui significativamente para o aumento da acurácia preditiva dos modelos. Ademais, abordagens híbridas que combinam algoritmos de Inteligência Artificial com estruturas físicas inspiradas em modelos SVAT ou ISBA têm sido exploradas como estratégia para ampliar a capacidade de generalização das estimativas em diferentes contextos ambientais (MA et al., 2021).

No que se refere às fontes de dados, os sensores hiperespectrais orbitais foram amplamente utilizados nos estudos analisados, sobretudo aqueles capazes de registrar informações contínuas no intervalo do visível ao infravermelho de ondas curtas. A elevada resolução espectral desses

sensores mostrou-se particularmente adequada para a identificação de variações sutis no estado fisiológico das culturas, diretamente associadas à dinâmica da fotossíntese, respiração vegetal e biomassa. A literatura aponta que faixas espectrais localizadas no infravermelho próximo, entre 700 e 1300 nm, apresentam forte correlação com variáveis biofísicas relacionadas ao fluxo de carbono, reforçando sua relevância para aplicações agrícolas (LI et al., 2021).

Em termos de validação dos modelos, a maioria dos estudos adotou estratégias baseadas em validação cruzada, conjuntos independentes de teste e comparação com séries observacionais secundárias amplamente utilizadas na literatura. As métricas de desempenho mais recorrentes incluíram o coeficiente de determinação (R^2), o erro quadrático médio (RMSE) e o erro absoluto médio (MAE), com valores de R^2 frequentemente superiores a 0,85 nos modelos de melhor desempenho. Esses resultados indicam consistência metodológica entre diferentes estudos e reforçam a viabilidade da utilização de dados orbitais combinados com aprendizado de máquina para a estimativa de fluxos de CO_2 em larga escala (GENG et al., 2022).

Entretanto, a revisão integrativa também evidenciou lacunas relevantes. Destaca-se a escassez de estudos aplicados especificamente à Amazônia Legal, bem como a limitada utilização de dados hiperespectrais de acesso aberto com resolução espacial compatível com sistemas agrícolas tropicais. Além disso, muitos trabalhos dependem de experimentos controlados ou parcelas experimentais, o que restringe a extrapolação dos resultados para contextos operacionais extensivos. Nesse cenário, observa-se uma oportunidade clara para o desenvolvimento de modelos regionais baseados exclusivamente em dados secundários, calibrados e avaliados por meio de comparações com séries observacionais de referência consolidadas na literatura.

Assim, os resultados da revisão integrativa sustentam a proposta metodológica desta tese, ao indicar que a integração entre sensoriamento remoto hiperespectral, variáveis meteorológicas e algoritmos de Inteligência Artificial representa uma abordagem metodologicamente consistente, escalável e cientificamente fundamentada para a estimativa do fluxo de CO_2 em sistemas agrícolas. Ao direcionar essa abordagem para a cultura da soja na Amazônia Legal, utilizando dados secundários e referências observacionais para comparação, a presente pesquisa posiciona-se de forma consistente frente às lacunas identificadas na literatura e contribui para o avanço metodológico da modelagem ambiental em regiões tropicais.

1.16 Desafios e Potencial para a Amazônia

A aplicação de técnicas avançadas de sensoriamento remoto e modelagem computacional para o monitoramento do fluxo de dióxido de carbono (CO₂) em sistemas agrícolas na Amazônia Legal envolve desafios técnicos, ambientais e operacionais específicos, mas também apresenta elevado potencial científico e estratégico. A singularidade ecológica da região, associada à sua dimensão territorial e à dinâmica recente de expansão agrícola, impõe a necessidade de abordagens metodológicas adaptadas à realidade amazônica.

Um dos principais desafios está relacionado às limitações inerentes aos sensores orbitais utilizados no sensoriamento remoto. Embora sensores hiperespectrais ofereçam elevada resolução espectral e grande capacidade de discriminação biofísica, muitos deles apresentam resolução espacial moderada e baixa frequência de revisita. Essa limitação compromete a construção de séries temporais contínuas, especialmente em áreas agrícolas com rápida dinâmica fenológica, como as lavouras de soja. Adicionalmente, a elevada cobertura de nuvens e a presença frequente de aerossóis atmosféricos na Amazônia Legal reduzem significativamente a quantidade de imagens utilizáveis, exigindo procedimentos rigorosos de filtragem e seleção dos dados.

Outro fator crítico refere-se à escassez de séries históricas longas de dados hiperespectrais de acesso aberto. A maioria das missões hiperespectrais orbitais possui tempo de operação relativamente recente, o que limita análises de longo prazo sobre tendências no sequestro ou emissão de carbono agrícola. Essa restrição torna inviável, em muitos casos, a validação direta dos modelos por meio de observações contínuas, exigindo o uso de dados secundários e referências consolidadas na literatura científica para fins comparativos.

A heterogeneidade ambiental da Amazônia Legal constitui um desafio adicional. A variabilidade de microclimas, tipos de solo, regimes hidrológicos e práticas agrícolas influencia diretamente a resposta espectral da vegetação e os processos fisiológicos associados ao ciclo do carbono. Modelos desenvolvidos em contextos extrarregionais, quando aplicados sem calibração adequada, tendem a apresentar vieses sistemáticos, subestimando ou superestimando os fluxos de CO₂. Dessa forma, a calibração regional e a adaptação dos modelos tornam-se etapas indispensáveis para garantir a consistência e a validade das estimativas.

Neste estudo, não são realizadas medições diretas de campo. A validação e a avaliação do desempenho do modelo proposto baseiam-se na comparação com dados secundários amplamente

utilizados na literatura, incluindo séries observacionais de referência, como aquelas provenientes do Observatório de Torre Alta da Amazônia (ATTO). Esses dados são empregados exclusivamente como base comparativa, permitindo avaliar a coerência física e estatística das estimativas geradas, sem caracterizar validação experimental *in situ*.

Apesar desses desafios, a Amazônia Legal apresenta elevado potencial para a aplicação de modelos híbridos baseados em sensoriamento remoto e Inteligência Artificial. A disponibilidade crescente de dados orbitais de acesso aberto, aliada ao avanço das técnicas de aprendizado de máquina e à expansão da capacidade computacional, viabiliza a construção de sistemas escaláveis e replicáveis para o monitoramento ambiental. A integração de dados hiperespectrais com variáveis meteorológicas e algoritmos supervisionados permite capturar padrões complexos e não lineares associados à dinâmica do carbono agrícola, mesmo em ambientes altamente heterogêneos.

Além disso, a utilização de plataformas de processamento em nuvem e ambientes computacionais com suporte a GPU favorece a análise de grandes volumes de dados e a implementação de pipelines reprodutíveis. Essa abordagem é particularmente relevante para a Amazônia Legal, onde limitações logísticas e de infraestrutura dificultam o monitoramento tradicional baseado em medições presenciais. O uso de dados secundários, aliado a protocolos transparentes e documentação rigorosa, contribui para a democratização do acesso às ferramentas de monitoramento ambiental e para o fortalecimento da ciência aberta (WILKINSON et al., 2016; FERREIRA et al., 2024).

Nesse contexto, os desafios identificados não representam impedimentos, mas sim condicionantes metodológicos que orientam a escolha das estratégias adotadas nesta tese. A combinação entre sensoriamento remoto hiperespectral, modelagem física inspirada em esquemas SVAT e técnicas de Inteligência Artificial configura um caminho promissor para a estimativa do fluxo de CO₂ em lavouras de soja na Amazônia Legal. Essa integração possibilita avanços tanto no entendimento científico das interações entre agricultura e atmosfera quanto no suporte à formulação de políticas públicas voltadas à sustentabilidade e à mitigação das mudanças climáticas.

2 METODOLOGIA

O presente capítulo descreve, de forma sistemática, os procedimentos metodológicos adotados para o desenvolvimento do modelo híbrido proposto nesta pesquisa, integrando fundamentos físico-matemáticos, variáveis espectrais obtidas por sensoriamento remoto e técnicas de aprendizado de máquina. Inicialmente, são apresentados os princípios conceituais que orientam a estrutura geral do modelo, seguidos da caracterização dos dados empregados, das etapas de pré-processamento e do detalhamento das equações que compõem o módulo físico. Na sequência, discute-se a formulação do componente estatístico fundamentado em aprendizagem supervisionada, bem como o processo de integração entre os módulos. Por fim, são descritas as estratégias de avaliação e validação do desempenho do modelo, assegurando rigor científico e reprodutibilidade das etapas adotadas.

Na dimensão computacional, a implementação do pipeline analítico foi orientada por princípios clássicos de engenharia de software e de sistemas inteligentes, com ênfase em modularidade, rastreabilidade e reprodutibilidade dos experimentos (PRESSMAN, 2011; SOMMERVILLE, 2011; RUSSELL; NORVIG, 2010; ZOCCA et al., 2017).

Além disso, os procedimentos de avaliação estatística e validação comparativa adotados neste capítulo dialogam com fundamentos consolidados de análise multivariada, séries temporais e estatística aplicada à modelagem ambiental (JOHNSON et al., 2020; BOX et al., 2008; WILKS, 2006).

No que se refere à base físico-operacional do esquema ISBA, também foram considerados os documentos técnicos de implementação e uso do modelo, incluindo guias de execução e documentação do código-fonte (AARON, 2002; ISBA MODEL, 2022).

2.1 Visão Geral do Modelo Híbrido

O modelo desenvolvido nesta tese adota uma arquitetura híbrida que integra uma base físico-biofísica, fundamentada nos esquemas SVAT/ISBA, com técnicas de aprendizado de máquina voltadas à identificação de relações não lineares entre variáveis climáticas, hidrológicas

e espectrais. Essa integração busca combinar a coerência mecanicista dos modelos de superfície terrestre com a flexibilidade analítica dos métodos orientados por dados, com vistas à estimativa do fluxo de CO₂ em áreas agrícolas.

Evidências adicionais indicam que métodos de aprendizado profundo são capazes de extrair informações espectrais complexas associadas ao funcionamento fisiológico da vegetação (FERREIRA et al., 2024; ZHANG et al., 2019), o que reforça sua aplicação na estimativa do fluxo de CO₂ em áreas agrícolas classificadas como lavoura temporária, segundo a tipologia de uso e cobertura da terra adotada pelo projeto MapBiomas (MAPBIOMAS, 2023).

A arquitetura adotada fundamenta-se no princípio da modelagem híbrida físico–dados, no qual um modelo determinístico simplificado, baseado nas equações de troca solo–vegetação–atmosfera presentes nos esquemas SVAT/ISBA, fornece uma estimativa inicial do fluxo de CO₂. Essa estimativa é derivada dos processos de balanço de energia, dinâmica hídrica e estado fisiológico do dossel, sendo posteriormente ajustada por um modelo de aprendizado de máquina, responsável por capturar relações não lineares não explicitamente representadas pelas parametrizações físicas. A adoção dessa abordagem é coerente com práticas contemporâneas de data–model fusion, uma vez que diferentes escolhas de parametrização e simplificação dos processos físicos podem alterar significativamente as estimativas dos fluxos de energia e carbono em modelos de superfície terrestre (LI et al., 2021).

A estrutura metodológica empregada nesta pesquisa organiza-se em três módulos complementares. O Módulo Físico, baseado em uma formulação reduzida dos esquemas SVAT/ISBA, contempla os processos de balanço de energia, dinâmica hídrica do solo, regulação estomática, assimilação fotossintética e respiração da vegetação, resultando na estimativa física inicial dos fluxos de carbono, incluindo NEE, GPP e Reco. A escolha desses componentes fundamenta-se em formulações consolidadas na literatura de modelos de superfície terrestre, conforme discutido por Dickinson (1998) e aprofundado nas avaliações hidrológicas e energéticas do ISBA-TRIP (DECHARME et al., 2019).

O módulo de IA, composto por técnicas de Machine Learning e Deep Learning, tem como função central aplicar uma regressão residual destinada a corrigir a estimativa física da NEE. Para isso, utiliza um conjunto integrado de variáveis de entrada, incluindo atributos espectrais, como NDVI, NIRv e LSWI, variáveis atmosféricas e hidrológicas representativas do estado ambiental, além de atributos temporais derivados da Transformada de Fourier, empregados na

representação de padrões dinâmicos nos dados. A utilização dessas abordagens é coerente com fundamentos matemáticos aplicados à decomposição de sinais e à modelagem de séries temporais (BOX; JENKINS; REINSEL, 2008), conforme detalhado nas subseções metodológicas seguintes. O módulo de Integração consolida os resultados físicos e estatísticos, produzindo a estimativa híbrida do fluxo de CO₂. O modelo final é expresso por:

$$NEE_{\text{híbrido}}(t) = NEE_{\text{físico}}(t) + \Delta NEE_{\text{IA}}(t) \quad (1)$$

Essa formulação representa a combinação entre a estimativa determinística baseada em processos biofísicos e uma correção residual orientada por dados, permitindo incorporar efeitos não linearmente representados pelo modelo físico. Dessa forma, a estimativa híbrida preserva a coerência física do balanço de carbono, ao mesmo tempo em que amplia a capacidade explicativa do modelo frente à complexidade do sistema agrícola analisado.

2.2 Área de Estudo e Fontes de Dados

O estudo é conduzido em áreas agrícolas localizadas no estado de Mato Grosso, inseridas no contexto de expansão da agricultura mecanizada na Amazônia Legal. A delimitação espacial da pesquisa baseia-se na integração de diferentes fontes de informação geoespacial, combinando dados de sensoriamento remoto hiperespectral, mapeamentos temáticos de uso e cobertura da terra e registros meteorológicos. Essa abordagem permite caracterizar de forma consistente o ambiente agrícola analisado e fornece suporte às etapas subsequentes de modelagem do fluxo de CO₂.

As principais informações espectrais desta pesquisa foram obtidas a partir da cena hiperespectral do sensor EO-1 Hyperion, identificada como EO1H2240692015363110PF, adquirida em 29 de dezembro de 2015, correspondente ao path/row 224/069 e processada no nível L1T. O produto é acompanhado de arquivo de metadados (MTL), que fornece informações sobre a geometria solar, o sistema de projeção cartográfica, a resolução espacial de 30 metros e a organização espectral distribuída entre as faixas do visível (VIS, aproximadamente 400–700 nm), do infravermelho próximo (NIR, aproximadamente 700–1000 nm) e do infravermelho de ondas curtas (SWIR, aproximadamente 1000–2500 nm) (NASA, 2017).

Adicionalmente, foram incorporados dados temáticos de uso e cobertura da terra proveni-

entes do MapBiomas Coleção 9, adotando-se o ano de referência 2015 para a delimitação das áreas cultivadas com soja, bem como dados meteorológicos oriundos da estação meteorológica convencional do Instituto Nacional de Meteorologia (INMET) localizada em Canarana–MT (código 83270; latitude -13,4708°, longitude -52,2711°, altitude de 430 m).

A escolha dessa estação fundamentou-se em sua proximidade espacial em relação ao footprint da cena hiperespectral EO-1 Hyperion L1T, ID EO1H2240692015363110PF, adquirida em 29/12/2015, bem como na compatibilidade temporal com a data de aquisição da imagem. Esses dados asseguram a disponibilidade das variáveis atmosféricas e hidrológicas necessárias à parametrização do modelo físico e ao suporte à modelagem dos fluxos de CO₂, tendo como dado meteorológico oficial os registros da estação convencional do INMET em Canarana–MT (código 83270).

A utilização do sensor EO-1 Hyperion justifica-se por sua elevada resolução espectral, composta por 242 bandas distribuídas entre as faixas do visível (VIS), do infravermelho próximo (NIR) e do infravermelho de ondas curtas (SWIR), o que possibilita a extração de variáveis espectrais e biofísicas associadas à caracterização da cultura da soja, incluindo indicadores de vigor vegetativo, teor de pigmentos, conteúdo hídrico e condições de estresse fisiológico. No contexto desta pesquisa, tais propriedades foram exploradas a partir da cena EO1H2240692015363110PF, adquirida em 29 de dezembro de 2015, cuja configuração espectral e parâmetros radiométricos encontram respaldo na documentação técnica da missão EO-1 (NASA, 2017).

O pré-processamento radiométrico e geométrico da cena EO-1 Hyperion L1T, ID EO1H2240692015363110PF, adquirida em 29/12/2015, seguiu as orientações estabelecidas nos documentos técnicos associados ao produto, contemplando a conversão dos níveis digitais em radiância, a preservação da resolução espacial de 30 m, a organização multibanda característica desse nível de processamento e a preparação da base espectral para as etapas posteriores de verificação de integridade, exclusão de bandas ruidosas, normalização espectral e recorte espacial, assegurando consistência espacial e radiométrica para as etapas subsequentes de análise (NASA, 2017).

2.2.1 Delimitação das áreas de soja (MapBiomias)

A identificação das áreas cultivadas com soja foi realizada a partir dos dados de uso e cobertura da terra do projeto MapBiomias – Coleção 9 (Integração), adotando-se o ano de referência 2015 e a classe temática correspondente à cultura da soja. A delimitação espacial foi conduzida no ambiente Google Earth Engine, com base no recorte da área de estudo associada à cena hiperespectral utilizada nesta pesquisa, resultando em um raster temático binário no qual os valores iguais a 1 representam pixels classificados como soja e os valores iguais a 0 correspondem às demais classes de uso e cobertura da terra.

O produto temático resultante foi exportado no formato GeoTIFF, preservando o sistema de referência geográfica original do MapBiomias (EPSG:4326), e posteriormente submetido a procedimentos de validação em ambiente Python. Essa validação incluiu a verificação de consistência espacial, inspeção visual e conferência do alinhamento entre a máscara temática e a cena hiperespectral EO-1 Hyperion L1T, ID EO1H2240692015363110PF, adquirida em 29/12/2015. A máscara final foi então utilizada como base espacial para o recorte e o mascaramento dessa cena nas etapas subsequentes da pesquisa.

2.3 Módulo Físico: Formulação SVAT/ISBA Reduzida

O módulo físico deste estudo fundamenta-se em uma formulação reduzida dos esquemas Soil–Vegetation–Atmosphere Transfer (SVAT/ISBA), estruturada para representar, de forma integrada, os processos de balanço de energia, dinâmica hídrica do solo e trocas de carbono entre a vegetação e a atmosfera. Essa abordagem permite descrever os mecanismos essenciais que regulam a evapotranspiração, a atividade fotossintética e a respiração da cultura da soja sob condições ambientais representativas da área de estudo.

A escolha desse arcabouço está alinhada à literatura que reconhece os modelos de superfície terrestre como ferramentas consolidadas para a simulação de fluxos de energia e carbono em ecossistemas vegetados (DICKINSON et al., 1998; DECHARME et al., 2019). A partir dessa representação determinística, o módulo físico fornece a estimativa inicial dos fluxos de CO₂, a qual é posteriormente ajustada pelo componente de aprendizado de máquina no contexto do modelo híbrido.

2.3.1 Balanço de Energia

No módulo físico, o sistema solo–vegetação–atmosfera é representado, em primeira aproximação, pelo balanço de energia na superfície, expresso por:

Balanço de energia na superfície

$$R_n = H + LE + G \quad (2)$$

Cálculo do saldo de radiação

$$R_n = (1 - \alpha)R_g + L_{\downarrow} - \epsilon\sigma T_s^4 \quad (3)$$

em que R_n representa o saldo de radiação na interface solo–vegetação, H corresponde ao fluxo de calor sensível, LE denota o fluxo de calor latente associado à evapotranspiração e G representa o fluxo de calor conduzido no solo. O saldo de radiação é determinado a partir das componentes radiativas incidentes e das propriedades radiativas da superfície, constituindo a base conceitual dos esquemas de superfície do tipo SVAT/ISBA utilizados na modelagem das trocas de energia entre a superfície terrestre e a atmosfera (DICKINSON et al., 1998).

2.3.2 Resistência estomática

A resistência estomática constitui um dos principais controles fisiológicos das trocas de vapor d'água e de CO_2 entre o dossel vegetal e a atmosfera, exercendo influência direta sobre a evapotranspiração, a fotossíntese e, conseqüentemente, sobre os fluxos de carbono simulados pelo modelo físico. Nos esquemas SVAT/ISBA, esse termo representa a resposta integrada da vegetação às condições ambientais, sendo particularmente sensível às variações de radiação incidente, déficit de pressão de vapor, umidade do solo e temperatura do ar (DICKINSON et al., 1998; DECHARME et al., 2019).

Em culturas agrícolas, como a soja, a adequada representação da resistência estomática é essencial para descrever o acoplamento entre os processos hidrológicos e ecofisiológicos, uma vez que alterações na abertura estomática afetam simultaneamente os fluxos de energia e de carbono. No presente estudo, a resistência estomática é representada por uma formulação do tipo

multiplicativa, amplamente empregada em modelos de superfície terrestre, na qual a condutância máxima do dossel é modulada por funções de resposta às principais variáveis ambientais, sendo expressa por:

$$r_{st}(t) = \frac{1}{g_{\max} f_1(R_g(t)) f_2(VPD(t)) f_3(\theta(t)) f_4(T_a(t))} \quad (4)$$

em que $r_s(t)$ representa a resistência estomática do dossel no instante t , $g_{\max}$ corresponde à condutância máxima estomática, e as funções f_1 , f_2 , f_3 e f_4 , representam, respectivamente, os efeitos da radiação global incidente, do déficit de pressão de vapor, da umidade do solo e da temperatura do ar sobre a abertura estomática.

Essa formulação permite integrar, de forma simplificada, os principais controles ambientais da atividade estomática, sendo amplamente adotada em esquemas SVAT/ISBA para a modelagem das trocas de água, energia e carbono entre a vegetação e a atmosfera (DICKINSON et al., 1998; DECHARME et al., 2019).

Onde:

r_{st} : resistência estomática do dossel;

$g_{\max}$: condutância estomática máxima da soja;

R_{gt} : radiação de onda curta incidente;

VPD_t : déficit de pressão de vapor;

θ_{at} : umidade do solo na zona radicular;

T_{at} : temperatura do ar.

A função de resposta à radiação expressa o aumento da condutância estomática com a disponibilidade de energia luminosa, enquanto o termo associado ao déficit de pressão de vapor representa o fechamento progressivo dos estômatos sob condições atmosféricas secas. De modo complementar, a função dependente da umidade do solo incorpora o efeito do estresse hídrico sobre a atividade fisiológica da planta, estabelecendo um elo direto entre o balanço hídrico do solo e os fluxos de carbono. A dependência térmica, por sua vez, descreve a existência de uma faixa ótima de temperatura para a atividade estomática, fora da qual ocorre redução da condutância. Essa estrutura funcional é consistente com formulações adotadas em modelos de superfície terrestre e com estudos que evidenciam a elevada sensibilidade dos fluxos simulados às parametrizações estomáticas em sistemas agrícolas (LI et al., 2021).

No contexto metodológico desta tese, a resistência estomática calculada neste submódulo atua como uma variável de acoplamento entre o balanço de energia, o balanço hídrico e o módulo de carbono, influenciando diretamente o fluxo de calor latente e os processos de assimilação de CO₂. Dessa forma, sua formulação fornece uma base determinística fisicamente consistente para a estimativa inicial dos fluxos de carbono, a qual é posteriormente ajustada pelo módulo de aprendizado de máquina no âmbito do modelo híbrido proposto.

2.3.3 Balanço Hídrico – Esquema Force–Restore

O balanço hídrico do solo é representado, nesta pesquisa, por meio do esquema force–restore, amplamente empregado em modelos de superfície terrestre para descrever a evolução temporal da umidade do solo em resposta aos forçantes atmosféricos e às propriedades físicas do solo. Esse esquema permite uma representação simplificada, porém fisicamente consistente, dos processos de entrada e saída de água no sistema solo–vegetação, estabelecendo um vínculo direto entre precipitação, evapotranspiração e a disponibilidade hídrica que controla a atividade ecofisiológica da cultura da soja. A adoção dessa abordagem é coerente com formulações consagradas em esquemas SVAT/ISBA, nos quais a umidade do solo atua como variável-chave no acoplamento entre os balanços de energia, água e carbono.

No presente estudo, a dinâmica da umidade do solo na camada superficial é descrita por uma equação diferencial de primeira ordem que combina um termo de forçamento atmosférico com um termo de restauração, responsável por conduzir o sistema em direção a um estado de equilíbrio controlado pelas características físicas do solo, sendo expressa por:

$$\frac{d\theta(t)}{dt} = \frac{P(t) - ET(t)}{Z_s} - \frac{\theta(t) - \theta_{eq}}{\tau} \quad (5)$$

Em que $\theta(t)$ representa o teor volumétrico de umidade do solo na camada superficial; $P(t)$ corresponde à precipitação incidente; $ET(t)$ denota a evapotranspiração total; Z_s é a profundidade efetiva da camada de solo considerada; θ_{eq} representa o teor de umidade de equilíbrio do solo; e τ é a constante de tempo associada ao processo de restauração hídrica. O primeiro termo da equação expressa o efeito direto do forçamento atmosférico sobre o armazenamento de água no solo, enquanto o segundo termo descreve o mecanismo de redistribuição interna, que tende a restaurar a umidade do solo em direção a um estado de equilíbrio determinado pelas propriedades

físicas do solo.

No contexto metodológico desta tese, o esquema force–restore fornece a estimativa temporal da umidade do solo utilizada tanto no controle da resistência estomática quanto na modulação dos processos de fotossíntese e respiração. Dessa forma, o balanço hídrico do solo estabelece um elo fundamental entre os processos hidrológicos e os fluxos de carbono simulados pelo modelo físico, constituindo uma variável essencial para a consistência do acoplamento físico e para a etapa subsequente de modelagem baseada em aprendizado de máquina no modelo híbrido proposto.

2.3.4 Fotossíntese (APAR–Monteith)

A assimilação de carbono pela cultura da soja é representada, nesta pesquisa, por meio de uma formulação baseada no conceito de radiação fotossinteticamente ativa absorvida (Absorbed Photosynthetically Active Radiation – APAR), associada ao modelo de eficiência do uso da luz proposto por Monteith. Essa abordagem permite estimar a produtividade primária bruta a partir da interação entre a disponibilidade de energia luminosa, a estrutura do dossel e a eficiência fisiológica da cultura, sendo amplamente empregada em modelos de superfície terrestre e em estudos que integram sensoriamento remoto e processos ecofisiológicos.

No modelo físico adotado, a produtividade primária bruta é calculada como o produto entre a APAR e a eficiência máxima de uso da luz, modulada por fatores ambientais que representam as limitações impostas pela temperatura do ar, pela disponibilidade hídrica do solo e pelo estresse atmosférico. Essa formulação assegura consistência com esquemas SVAT/ISBA em versões reduzidas e estabelece um elo direto entre variáveis radiativas, estado hídrico do solo e os processos de assimilação de carbono. A produtividade primária bruta é expressa por:

$$GPP(t) = \epsilon_{\max} APAR(t) f_T(t) f_W(t) f_{VPD}(t) \quad (6)$$

Em que $GPP(t)$ representa a produtividade primária bruta; $\epsilon_{\max}$ corresponde à eficiência máxima de uso da luz da cultura da soja; $APAR(t)$ denota a radiação fotossinteticamente ativa absorvida pelo dossel; e $f_T(t)$, $f_W(t)$ e $f_{VPD}(t)$ são funções adimensionais, com valores entre zero e um, que representam, respectivamente, as limitações impostas pela temperatura do ar, pela disponibilidade hídrica do solo e pelo déficit de pressão de vapor. Essa formulação permite incorporar, de

forma explícita, os efeitos combinados das condições ambientais sobre a assimilação de carbono, mantendo simplicidade computacional e coerência física.

No contexto metodológico desta tese, a estimativa da produtividade primária bruta constitui um componente central para o cálculo dos fluxos de carbono, fornecendo a base para a determinação da troca líquida de ecossistema e para a integração posterior com o módulo de aprendizado de máquina no modelo híbrido proposto.

2.3.5 Respiração autotrófica e heterotrófica

A respiração do ecossistema é decomposta, nesta pesquisa, em suas componentes autotrófica e heterotrófica, conforme prática consolidada em modelos de superfície terrestre do tipo SVAT/ISBA. Essa decomposição permite representar separadamente os processos metabólicos associados à vegetação viva e à decomposição microbiana da matéria orgânica do solo, facilitando a interpretação física dos fluxos simulados e a integração com os demais módulos do modelo.

A respiração autotrófica está associada aos custos metabólicos da vegetação relacionados à manutenção e ao crescimento dos tecidos vivos. Em modelos de superfície terrestre, essa componente é frequentemente representada como proporcional à assimilação de carbono, uma vez que a atividade respiratória da planta depende diretamente da taxa de fotossíntese. No contexto desta tese, adota-se uma formulação reduzida na qual a respiração autotrófica é expressa como uma fração da produtividade primária bruta, modulada por uma função de resposta à temperatura, permitindo capturar a dependência térmica do metabolismo vegetal sem a necessidade de representar explicitamente compartimentos de biomassa. A respiração autotrófica é expressa por:

$$R_{auto}(t) = k_{auto} GPP(t) f_T(t) \quad (7)$$

De forma análoga, a respiração heterotrófica do solo é representada a partir de uma taxa de referência, que expressa a atividade microbiana sob condições padrão, modulada por funções ambientais de temperatura e disponibilidade hídrica. Essa formulação reduzida assume que os principais controladores da decomposição da matéria orgânica do solo são as condições térmicas e o teor de água, hipótese amplamente adotada em esquemas SVAT quando não se dispõe de informações detalhadas sobre os estoques e compartimentos de carbono do solo. A respiração

heterotrófica é expressa por:

$$R_{het}(t) = R_{het,ref} f_T(t) f_W(t) \quad (8)$$

A respiração total do ecossistema é definida como a soma das componentes autotrófica e heterotrófica, conforme a definição operacional adotada em estudos de balanço de carbono e em modelos de superfície terrestre. A respiração total do ecossistema é dada por:

$$Reco(t) = R_{auto}(t) + R_{het}(t)$$

Em que $R_{auto}(t)$ representa a respiração autotrófica do dossel; k_{auto} é o coeficiente que relaciona a assimilação de carbono à respiração da vegetação; $R_{het}(t)$ corresponde à respiração heterotrófica do solo; $R_{het,ref}$ é a taxa de respiração heterotrófica de referência; e $f_T(t)$ e $f_W(t)$ são funções adimensionais, com valores entre zero e um, que representam, respectivamente, os efeitos da temperatura e da disponibilidade hídrica do solo. A soma dessas componentes define a respiração total do ecossistema (Reco), utilizada posteriormente no cálculo da troca líquida de CO_2 .

2.3.6 Cálculo da Troca Líquida de Ecossistema (NEE)

A troca líquida de dióxido de carbono entre o ecossistema agrícola e a atmosfera é representada, nesta pesquisa, pela Troca Líquida de Ecossistema (Net Ecosystem Exchange – NEE). Essa variável sintetiza o balanço entre os processos de assimilação de carbono pela fotossíntese e a liberação de CO_2 associada à respiração do ecossistema, constituindo um dos principais indicadores do papel do sistema solo-vegetação como fonte ou sumidouro de carbono.

No contexto dos modelos de superfície terrestre do tipo SVAT/ISBA, a NEE é definida a partir da diferença entre a produtividade primária bruta e a respiração total do ecossistema. Essa definição adota a convenção segundo a qual fluxos positivos indicam liberação líquida de CO_2 para a atmosfera, enquanto fluxos negativos representam absorção líquida de carbono pelo ecossistema. A adoção dessa formulação permite compatibilizar o modelo físico com medições de fluxo obtidas por técnicas micrometeorológicas e com estimativas derivadas de sensoriamento remoto.

$$NEE(t) = Reco(t) - GPP(t)$$

Em que $NEE(t)$ representa a troca líquida de ecossistema; $Reco(t)$ corresponde à respiração total do ecossistema, definida como a soma das componentes autotrófica e heterotrófica; e $GPP(t)$ denota a produtividade primária bruta estimada a partir do modelo fotossintético baseado em APAR. Nessa formulação, valores positivos de NEE indicam emissão líquida de CO_2 para a atmosfera, enquanto valores negativos representam absorção líquida de carbono pelo sistema solo-vegetação.

A expressão adotada resulta de uma redução conceitual do balanço completo de carbono, na qual se assume que os principais fluxos verticais de CO_2 em escalas temporais compatíveis com o modelo são adequadamente representados pelos termos de assimilação fotossintética e respiração. Essa simplificação é coerente com esquemas SVAT/ISBA reduzidos e permite integrar, de forma consistente, os processos ecofisiológicos e hidrológicos descritos nos subitens anteriores.

No âmbito metodológico desta tese, a NEE calculada pelo modelo físico constitui a estimativa determinística inicial do fluxo de CO_2 do ecossistema agrícola. Essa estimativa é posteriormente utilizada como entrada para o módulo de aprendizado de máquina, responsável por modelar correções residuais associadas a não linearidades, incertezas paramétricas e processos não explicitamente representados na formulação física.

2.4 Módulo de Aprendizado de Máquina: Correção Residual do Fluxo de CO_2

O módulo de aprendizado de máquina é empregado, nesta pesquisa, com a finalidade de complementar o modelo físico descrito no item 2.3, atuando exclusivamente na correção residual da Troca Líquida de Ecossistema estimada de forma determinística. Essa estratégia caracteriza uma abordagem de modelagem híbrida físico-dados, na qual as equações baseadas em processos fornecem a estrutura conceitual do sistema, enquanto os métodos de aprendizado supervisionado são utilizados para capturar relações não lineares, efeitos locais e incertezas não explicitamente representadas na formulação física.

Diferentemente de abordagens puramente orientadas a dados, o modelo de aprendizado de máquina não substitui as equações do balanço de carbono, mas opera sobre o resíduo entre as estimativas físicas e as observações ou referências disponíveis. Essa escolha metodológica reduz o risco de extrapolações fisicamente inconsistentes e assegura que as previsões finais do fluxo de

CO₂ permaneçam ancoradas em princípios ecofisiológicos e hidrológicos.

No presente estudo, o problema de aprendizado é formulado como uma tarefa de regressão supervisionada, na qual a variável-alvo corresponde ao termo residual associado à NEE física. Esse resíduo representa a parcela do fluxo de CO₂ que não é explicada diretamente pelo modelo SVAT/ISBA reduzido, sendo atribuída a efeitos de escala, heterogeneidade espacial, limitações paramétricas e simplificações inerentes ao modelo físico.

$$\Delta NEE(t) = NEE_{\text{ref}}(t) - NEE_{\text{fis0}}(t) \quad (9)$$

Em que $\Delta NEE(t)$ representa o resíduo do fluxo de CO₂; $NEE_{\text{ref}}(t)$ corresponde à estimativa de referência do fluxo de CO₂ (observacional ou proveniente de modelo de maior fidelidade); e $NEE_{\text{fis0}}(t)$ denota a troca líquida de ecossistema calculada pelo modelo físico simplificado. A aprendizagem do termo residual permite ao modelo de IA identificar padrões sistemáticos de erro associados a variáveis ambientais, espectrais e temporais, sem comprometer a coerência física da estimativa final.

As variáveis de entrada do módulo de aprendizado de máquina incluem atributos espectrais derivados de sensoriamento remoto, variáveis meteorológicas e hidrológicas, bem como descritores temporais extraídos das séries históricas. Esses atributos são utilizados para representar a variabilidade espacial e temporal do sistema agrícola que não é plenamente capturada pelas equações físicas, constituindo o conjunto de features empregado no treinamento do modelo.

No âmbito metodológico desta tese, o módulo de aprendizado de máquina é treinado e validado de forma independente do modelo físico, sendo posteriormente acoplado a este para a obtenção da estimativa híbrida do fluxo de CO₂. Essa arquitetura assegura que a contribuição da IA seja interpretável como uma correção residual, preservando a estrutura conceitual do balanço de carbono e facilitando a análise dos resultados nos capítulos subsequentes.

2.4.1 Seleção de variáveis de entrada (features ambientais, espectrais e temporais)

A seleção das variáveis de entrada do módulo de aprendizado de máquina é orientada pelo princípio de complementaridade ao modelo físico, de modo que os atributos utilizados representem fontes de variabilidade não explicitamente descritas pelas equações do balanço

de energia, água e carbono. Assim, as features escolhidas buscam capturar heterogeneidades espaciais, efeitos de escala, respostas não lineares e padrões temporais associados ao sistema agrícola da soja nas áreas de estudo localizadas no estado de Mato Grosso.

As variáveis ambientais incluem parâmetros meteorológicos e hidrológicos provenientes de estações locais e regionais, tais como temperatura do ar, precipitação, déficit de pressão de vapor e umidade do solo. Essas variáveis fornecem informação direta sobre o estado atmosférico e hídrico do sistema agrícola analisado, atuando como controladores primários dos fluxos de CO₂ e como potenciais explicadores do resíduo associado à estimativa física da NEE.

As variáveis espectrais são derivadas da cena EO-1 Hyperion L1T, ID EO1H2240692015 363110PF, adquirida em 29/12/2015, após o pré-processamento espectral e a aplicação da máscara binária de soja derivada do MapBiomass Coleção 9 (ano 2015), sendo utilizadas para representar a condição fisiológica e estrutural do dossel da soja. Entre esses atributos incluem-se índices de vegetação e métricas espectrais relacionadas à atividade fotossintética, ao conteúdo hídrico e a condições de estresse da vegetação, os quais fornecem informação espacialmente explícita que não é diretamente incorporada nas parametrizações do modelo físico reduzido.

Além disso, são incorporadas variáveis temporais com o objetivo de representar a sazonalidade, a fenologia da cultura e padrões periódicos presentes nas séries de dados. Esses descritores temporais são extraídos por meio de técnicas clássicas de análise de sinais, permitindo decompor a variabilidade temporal em componentes de baixa e alta frequência relevantes para a modelagem do resíduo do fluxo de CO₂. De forma sintética, o vetor de variáveis de entrada do modelo de aprendizado de máquina pode ser representado por:

$$X(t) = [X_{\text{met}}(t), X_{\text{esp}}(t), X_{\text{temp}}(t)] \quad (10)$$

Em que $X(t)$ representa o vetor de variáveis de entrada do modelo de aprendizado de máquina; $X_{\text{met}}(t)$ corresponde ao conjunto de variáveis meteorológicas e hidrológicas; $X_{\text{esp}}(t)$ denota o conjunto de atributos espectrais derivados de sensoriamento remoto; e $X_{\text{temp}}(t)$ representa os descritores temporais associados às séries históricas. Essa decomposição explicita a origem e o papel de cada grupo de variáveis, assegurando transparência metodológica e facilitando a análise posterior da contribuição de cada tipo de informação na correção residual da NEE.

No âmbito metodológico desta tese, a seleção e a organização das features seguem critérios de relevância física, disponibilidade de dados e consistência temporal, evitando redundâncias

excessivas e minimizando o risco de sobreajuste. Essa etapa prepara o conjunto de dados de entrada para o treinamento do modelo de aprendizado de máquina, mantendo coerência com a estrutura híbrida físico–dados adotada.

2.4.2 Pré-processamento e normalização dos dados

O pré-processamento dos dados constitui uma etapa essencial para garantir a consistência, a comparabilidade e a qualidade das variáveis utilizadas no módulo de aprendizado de máquina. Nesta pesquisa, essa etapa é conduzida após a integração das variáveis meteorológicas, espectrais e temporais, assegurando que todas as features apresentem alinhamento temporal, coerência dimensional e ausência de inconsistências que possam comprometer o treinamento do modelo. Esse pré-processamento refere-se especificamente às variáveis de entrada do módulo de aprendizado de máquina, distinguindo-se do pré-processamento radiométrico e geométrico aplicado previamente à cena EO-1 Hyperion L1T, ID EO1H2240692015363110PF, adquirida em 29/12/2015.

Inicialmente, as séries temporais utilizadas no módulo de aprendizado de máquina são sincronizadas em uma base temporal comum, considerando a resolução temporal dos dados meteorológicos e a disponibilidade das observações espectrais. Valores ausentes ou inconsistentes são tratados por meio de procedimentos de filtragem e interpolação temporal, aplicados de forma conservadora e respeitando a natureza física das variáveis envolvidas, de modo a evitar a introdução de artefatos artificiais nas séries de dados.

Em seguida, é realizada a normalização das variáveis de entrada do módulo de aprendizado de máquina com o objetivo de padronizar suas escalas e facilitar o processo de aprendizado. A normalização é particularmente importante em modelos de aprendizado supervisionado, pois impede que variáveis com magnitudes distintas exerçam influência desproporcional no ajuste dos parâmetros do modelo. No presente estudo, adota-se uma transformação linear do tipo z-score, que preserva a distribuição relativa dos dados e mantém a interpretabilidade das variáveis. Esse procedimento aplica-se exclusivamente às variáveis integradas de entrada, não incidindo sobre o pré-processamento radiométrico e geométrico previamente realizado na cena EO-1 Hyperion L1T, ID EO1H2240692015363110PF, adquirida em 29/12/2015. A normalização das variáveis é

expressa por:

$$X_{norm}(t) = \frac{X(t) - \mu_X}{\sigma_X} \quad (11)$$

Em que $X_{norm}(t)$ representa a variável normalizada; $X(t)$ corresponde ao valor original da variável de entrada; μ_X é a média da série temporal considerada; e σ_X denota o desvio padrão associado. Essa transformação assegura que as variáveis de entrada apresentem média nula e variância unitária, favorecendo a estabilidade numérica e a eficiência do processo de treinamento do modelo de aprendizado de máquina.

No contexto metodológico desta tese, os procedimentos de pré-processamento e normalização são aplicados exclusivamente às variáveis de entrada do módulo de aprendizado de máquina, não alterando as estimativas produzidas pelo modelo físico. Dessa forma, preserva-se a independência conceitual entre os componentes físico e estatístico do modelo híbrido, mantendo a coerência estrutural da abordagem proposta.

2.4.3 Transformada de Fourier como Feature Engineering

A Transformada de Fourier é empregada, nesta pesquisa, como técnica de feature engineering com o objetivo de extrair descritores temporais capazes de representar padrões periódicos e componentes de frequência presentes nas séries temporais associadas às variáveis ambientais, espectrais e ao fluxo de CO_2 . Essa abordagem permite decompor sinais no domínio do tempo em componentes harmônicas, facilitando a identificação de ciclos sazonais, variações intraanuais e oscilações de curta duração que não são explicitamente representadas pelo modelo físico.

No contexto metodológico desta tese, a Transformada Discreta de Fourier é aplicada às séries temporais previamente pré-processadas, considerando janelas temporais compatíveis com a escala fenológica da cultura da soja. A adoção dessa técnica baseia-se na hipótese de que parte do resíduo associado ao fluxo de CO_2 apresenta padrões temporais recorrentes, os quais podem ser representados de forma mais eficiente no domínio da frequência do que no domínio do tempo. A Transformada Discreta de Fourier é expressa por:

$$X_f(k) = \sum_{t=0}^{N-1} X(t) \exp\left(-i 2\pi \frac{kt}{N}\right) \quad (12)$$

Em que $X(t)$ representa a série temporal original; X_f corresponde ao coeficiente espectral associado à frequência k ; N é o número de amostras na janela temporal considerada; e i denota a unidade imaginária. Os coeficientes espectrais extraídos são posteriormente utilizados como variáveis de entrada do modelo de aprendizado de máquina, permitindo incorporar informações sobre periodicidade e variabilidade temporal na correção residual da NEE.

No âmbito metodológico desta tese, a utilização da Transformada de Fourier como técnica de feature engineering constitui uma etapa complementar ao pré-processamento dos dados, não substituindo as variáveis físicas originais, mas ampliando o espaço de representação temporal do sistema. Essa estratégia mantém a coerência com a abordagem híbrida físico-dados e contribui para a captura de padrões temporais complexos associados à dinâmica do ecossistema agrícola analisado.

2.4.4 Arquitetura e treinamento do modelo de aprendizado de máquina

A arquitetura do modelo de aprendizado de máquina é definida com o objetivo de modelar a componente residual do fluxo de CO_2 não explicitamente representada pelo modelo físico. A escolha da arquitetura privilegia modelos de regressão supervisionada capazes de capturar relações não lineares entre as variáveis ambientais, espectrais e temporais e o termo residual da NEE, mantendo simplicidade estrutural, estabilidade numérica e interpretabilidade. Essa opção metodológica evita que o modelo estatístico substitua os processos físicos, restringindo sua atuação à correção dos desvios sistemáticos associados às simplificações do modelo SVAT/ISBA reduzido.

No presente estudo, o problema de aprendizado é formulado como uma regressão multivariada, na qual o vetor de features previamente selecionadas, pré-processadas e enriquecidas por descritores espectrais e temporais constitui a entrada do modelo, enquanto o resíduo da troca líquida de ecossistema representa a variável-alvo. O treinamento consiste no ajuste dos parâmetros do modelo de aprendizado de máquina a partir da minimização de uma função de perda, definida de modo a penalizar discrepâncias entre os resíduos observados e estimados. Formalmente, a relação entre o vetor de variáveis de entrada e o resíduo estimado da troca líquida

de ecossistema pode ser expressa por:

$$\widehat{\Delta NEE}(t) = f_{ML}(X_{norm}(t); \theta)$$

Em que $\widehat{\Delta NEE}(t)$ representa a estimativa do termo residual da troca líquida de ecossistema produzida pelo modelo de aprendizado de máquina; f_{ML} denota a função de regressão implementada pelo algoritmo selecionado; $X_{norm}(t)$ corresponde ao vetor de variáveis de entrada normalizadas, incluindo atributos ambientais, espectrais e temporais; e θ representa o conjunto de parâmetros ajustados durante o processo de treinamento. A função f_{ML} é ajustada de forma a minimizar uma função de perda definida sobre o conjunto de treinamento, assegurando a melhor aproximação possível do resíduo do fluxo de CO_2 no espaço das variáveis explicativas.

O treinamento do modelo é conduzido a partir da divisão do conjunto de dados em subconjuntos distintos para ajuste e validação, permitindo avaliar a capacidade de generalização do modelo e reduzir o risco de sobreajuste. Essa estratégia assegura que a correção residual aprendida reflita padrões consistentes do sistema agrícola e não apenas flutuações específicas do conjunto de dados utilizado no treinamento.

No âmbito metodológico desta tese, a definição da arquitetura e do procedimento de treinamento do modelo de aprendizado de máquina constitui uma etapa fundamental para a integração híbrida físico-dados, estabelecendo as bases para a combinação posterior entre a estimativa determinística do modelo físico e a correção residual estatística.

2.4.5 Integração do modelo físico e do modelo de aprendizado de máquina

A integração entre o modelo físico e o modelo de aprendizado de máquina constitui a etapa central da abordagem híbrida adotada nesta tese. Nessa estratégia, o modelo físico baseado em processos ecofisiológicos e hidrológicos fornece uma estimativa determinística inicial da Troca Líquida de Ecossistema, enquanto o modelo de aprendizado de máquina atua exclusivamente na correção residual dessa estimativa. Essa organização metodológica assegura que a predição final do fluxo de CO_2 permaneça ancorada em princípios físicos, ao mesmo tempo em que incorpora a capacidade dos métodos estatísticos de representar relações não lineares, heterogeneidades espaciais e padrões temporais não explicitamente descritos pelas equações do modelo SVAT/ISBA reduzido.

A combinação entre os dois componentes é realizada por meio de uma formulação aditiva, assumindo-se que a estimativa híbrida da NEE pode ser expressa como a soma da estimativa física e do termo residual aprendido pelo modelo de aprendizado de máquina. Essa redução conceitual parte da hipótese de que os principais processos determinísticos do balanço de carbono são adequadamente representados pelo modelo físico, enquanto o termo residual concentra incertezas paramétricas, efeitos de escala e simplificações inerentes à modelagem baseada em processos.

A integração entre os componentes físico e estatístico é realizada por meio de uma formulação aditiva, assumindo-se que a estimativa híbrida da troca líquida de ecossistema resulta da soma da estimativa física e do termo residual aprendido pelo modelo de aprendizado de máquina, sendo expressa por:

$$NEE_{hib}(t) = NEE_{fis0}(t) + \widehat{\Delta NEE}(t)$$

Em que $NEE_{hib}(t)$ representa a estimativa híbrida da troca líquida de ecossistema; $NEE_{fis0}(t)$ corresponde à estimativa determinística produzida pelo modelo físico simplificado; e $\widehat{\Delta NEE}(t)$ denota o termo residual estimado pelo modelo de aprendizado de máquina. A notação adotada explicita a origem de cada componente da estimativa híbrida e mantém consistência com a formulação residual utilizada no treinamento.

No âmbito metodológico desta tese, a integração aditiva entre os modelos físico e estatístico permite interpretar a contribuição do aprendizado de máquina como uma correção residual fisicamente condicionada, preservando a coerência do balanço de carbono e reduzindo o risco de previsões inconsistentes do ponto de vista ambiental. Essa estrutura híbrida também facilita a análise posterior do desempenho do modelo, ao permitir a avaliação separada das contribuições do componente físico e do componente estatístico.

2.5 Estratégia de validação e avaliação do modelo

A validação e a avaliação do modelo híbrido proposto são conduzidas com o objetivo de verificar a consistência, a confiabilidade e os limites de generalização das estimativas do fluxo de CO₂ produzidas pela integração entre o modelo físico e o modelo de aprendizado de máquina. Essa etapa metodológica busca avaliar separadamente o desempenho do modelo físico, do termo residual estimado pelo aprendizado de máquina e da estimativa híbrida final,

assegurando transparência na análise das contribuições de cada componente.

A estratégia de validação é estruturada a partir da comparação entre as estimativas do modelo e dados de referência disponíveis para a área de estudo, considerando escalas temporais compatíveis com as resoluções dos dados meteorológicos e espectrais utilizados. A divisão dos dados em subconjuntos independentes para treinamento, validação e teste permite avaliar a capacidade do modelo de reproduzir padrões temporais do fluxo de CO₂ sem ajuste direto aos dados utilizados na avaliação.

No contexto desta tese, a avaliação do desempenho dos modelos é realizada por meio de métricas estatísticas amplamente empregadas em estudos de modelagem ambiental, as quais quantificam o grau de concordância entre valores estimados e observados, bem como a magnitude dos erros associados às estimativas. Essas métricas são aplicadas de forma consistente às saídas do modelo físico, do modelo de aprendizado de máquina e do modelo híbrido, permitindo comparações diretas entre as abordagens. As métricas utilizadas para a avaliação do desempenho dos modelos incluem a Raiz do Erro Quadrático Médio (RMSE), o Erro Médio Absoluto (MAE) e o Coeficiente de Determinação (R²), cujas formulações matemáticas são apresentadas a seguir.

Raiz do Erro Quadrático Médio (RMSE)

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2} \quad (13)$$

Erro Médio Absoluto (MAE)

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \quad (14)$$

Coeficiente de Determinação (R²)

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2} \quad (15)$$

Em que y_i representa o valor observado do fluxo de CO₂; $\hat{y}_i$ denota o valor estimado pelo modelo avaliado; $\bar{y}$ corresponde à média dos valores observados; e N é o número total de observações consideradas. O erro quadrático médio (RMSE) enfatiza desvios de maior magnitude, o erro absoluto médio (MAE) fornece uma medida direta do erro médio, e o coeficiente de determinação (R²) expressa a proporção da variabilidade dos dados observados explicada pelo modelo.

No âmbito metodológico desta tese, essas métricas são utilizadas para avaliar comparativamente o desempenho do modelo físico, do modelo de aprendizado de máquina e do modelo híbrido, permitindo verificar se a integração físico–dados resulta em ganhos efetivos de desempenho em relação às abordagens individuais. A interpretação dos valores obtidos a partir dessas métricas é apresentada nos capítulos de resultados e discussão, não sendo objeto desta seção metodológica.

2.6 Pipeline operacional do modelo híbrido

O pipeline operacional do modelo híbrido descreve, de forma sequencial e integrada, o conjunto de etapas executadas desde a aquisição dos dados até a obtenção da estimativa final do fluxo de CO₂. Essa organização metodológica visa garantir a reprodutibilidade do estudo, a rastreabilidade das etapas empregadas e a clareza na implementação computacional do modelo proposto.

O pipeline inicia-se com a aquisição, organização e integração dos dados meteorológicos, espectrais e ambientais referentes à área de estudo, seguida da aplicação dos procedimentos de pré-processamento e normalização das variáveis de entrada. Em paralelo, são calculadas as variáveis intermediárias do modelo físico, incluindo os balanços de energia e de água, a resistência estomática, a produtividade primária bruta, a respiração do ecossistema e a troca líquida de ecossistema. Essas etapas resultam na estimativa determinística inicial da NEE, produzida pelo modelo físico baseado em uma formulação SVAT/ISBA reduzida.

Na sequência, o pipeline incorpora as variáveis ambientais, espectrais e temporais como entradas do módulo de aprendizado de máquina, juntamente com o resíduo calculado entre a estimativa física da NEE e os dados de referência. O modelo de aprendizado de máquina é então treinado para estimar o termo residual do fluxo de CO₂, representando a parcela da variabilidade não explicitamente capturada pelas equações físicas.

Por fim, a estimativa híbrida da NEE é obtida por meio da integração aditiva entre a estimativa física e o termo residual estimado pelo modelo de aprendizado de máquina. O pipeline é encerrado com a aplicação das métricas de avaliação definidas na etapa de validação, permitindo quantificar de forma comparável o desempenho do modelo híbrido em relação às abordagens físicas e estatísticas consideradas individualmente. De forma sintética, o pipeline operacional do

modelo híbrido pode ser representado por:

$$NEE_{hib}(t) = fPIPE(P, M, S, X)$$

Em que $fPIPE(\cdot)$ representa o conjunto sequencial de operações que compõem o pipeline operacional; P denota o conjunto de dados físicos e ambientais; M corresponde ao modelo físico SVAT/ISBA reduzido; S representa o módulo de aprendizado de máquina; e X indica o conjunto de variáveis de entrada utilizadas ao longo do processo. Essa representação sintética reforça o caráter modular e integrável do pipeline, facilitando sua implementação computacional e eventual adaptação a outras áreas de estudo.


2.7 Visão Geral do Fluxo Metodológico

O fluxo de processamento e modelagem computacional adotado nesta pesquisa sintetiza, em nível operacional, a integração entre dados hiperespectrais do sensor Hyperion, variáveis meteorológicas e informações derivadas de modelos biofísicos, com o objetivo de estimar o fluxo de dióxido de carbono (CO_2) por meio de uma abordagem híbrida baseada em inteligência artificial. Essa representação gráfica traduz, de forma resumida, a implementação prática das diretrizes metodológicas estabelecidas no Capítulo 2, evidenciando a sequência lógica das etapas e a interação entre os componentes físicos e estatísticos do modelo, cujos resultados são apresentados no Capítulo 3.

De maneira geral, o pipeline organiza-se desde o pré-processamento e a extração de variáveis até o alinhamento temporal e a consolidação das informações em um dataframe unificado, que serve de base para a etapa de modelagem computacional. Após verificações estruturais de consistência dos dados, os parâmetros físicos e as variáveis derivadas são integrados aos algoritmos de inteligência artificial, resultando na estimativa final do fluxo de CO_2 . Essa organização assegura reprodutibilidade, rastreabilidade e clareza na execução computacional do modelo, ao mesmo tempo em que evita sobreposição com a descrição conceitual detalhada apresentada na metodologia.

O encadeamento operacional das etapas de processamento, integração dos dados e modelagem computacional é sintetizado no fluxo apresentado na Figura 01, que ilustra a implementação prática do pipeline híbrido adotado nesta pesquisa.

Figura 01 – Fluxo operacional de processamento dos dados e modelagem computacional híbrida para estimativa do fluxo de CO₂



Fonte: elaboração própria, 2025.

O diagrama apresenta as etapas sequenciais do pipeline computacional adotado na pesquisa, incluindo o pré-processamento de dados hiperespectrais do sensor Hyperion, a integração com variáveis meteorológicas e biofísicas, o alinhamento temporal e espacial das informações e a aplicação de técnicas de inteligência artificial em conjunto com modelos físicos, resultando na estimativa final do fluxo de dióxido de carbono (CO₂).

A partir do fluxo metodológico apresentado na Figura 01, as seções seguintes detalham a implementação operacional do pipeline computacional adotado na pesquisa. São descritos os procedimentos de pré-processamento dos dados, integração das variáveis, organização do dataframe analítico, execução dos cálculos biofísicos e aplicação do modelo híbrido, assegurando rastreabilidade, reprodutibilidade e coerência entre a formulação metodológica do Capítulo 2 e os resultados apresentados no Capítulo 3.

O pré-processamento dos dados de sensoriamento remoto constituiu uma etapa operacional fundamental do pipeline computacional, com o objetivo de garantir a consistência radiométrica, espectral e espacial das imagens hiperespectrais utilizadas na estimativa do fluxo de dióxido de carbono (CO₂). Nesta pesquisa, foram empregadas imagens do sensor hiperespectral EO-1 Hyperion, cujo elevado número de bandas e sensibilidade a ruídos exigem procedimentos específicos de tratamento antes da execução dos cálculos espectrais e biofísicos.

Inicialmente, as cenas hiperespectrais foram submetidas à verificação de integridade dos arquivos e à validação dos metadados associados, incluindo informações temporais, orbitais e geométricas. Em seguida, realizou-se a exclusão sistemática de bandas afetadas por ruído excessivo ou baixa relação sinal-ruído, especialmente nas extremidades do espectro eletromagnético. Posteriormente, foram aplicados procedimentos de normalização espectral com o objetivo de reduzir efeitos residuais de iluminação e diferenças radiométricas entre pixels, assegurando maior comparabilidade das respostas espectrais ao longo da cena.

O recorte espacial das imagens foi realizado com base nas áreas de cultivo de soja previamente delimitadas na área de estudo, restringindo os cálculos exclusivamente aos pixels de interesse e aumentando a eficiência computacional. Ao final do pré-processamento, os dados hiperespectrais encontravam-se organizados em estruturas adequadas à execução explícita dos cálculos espectrais, biofísicos e estatísticos apresentados neste capítulo, estabelecendo a base técnica necessária para a demonstração das equações, dos procedimentos de cálculo e dos valores numéricos efetivamente obtidos.

2.8 Extração de Índices Espectrais e Variáveis Derivadas

Nesta etapa do pipeline computacional, são executados explicitamente os cálculos dos índices espectrais e das variáveis derivadas a partir dos dados hiperespectrais do sensor EO-1 Hyperion, restritos às áreas de cultivo de soja previamente delimitadas. Diferentemente da descrição conceitual apresentada no início do Capítulo 2, este item detalha a aplicação direta das equações espectrais, a seleção das bandas efetivamente utilizadas e os valores numéricos obtidos para cada índice, permitindo a rastreabilidade completa dos cálculos realizados.

Os índices extraídos têm como finalidade quantificar propriedades biofísicas da vegetação relacionadas à atividade fotossintética, ao estado hídrico e à estrutura do dossel, constituindo variáveis fundamentais tanto para a parametrização do modelo físico quanto para a construção do conjunto de entrada do módulo de aprendizado de máquina.

2.8.1 Índice de Vegetação por Diferença Normalizada (NDVI)

O Índice de Vegetação por Diferença Normalizada (NDVI) foi calculado a partir das bandas espectrais do sensor EO-1 Hyperion associadas às regiões do vermelho (RED) e do infravermelho próximo (NIR), sendo amplamente utilizado para quantificar o vigor vegetativo e a atividade fotossintética da vegetação. No contexto desta pesquisa, o NDVI é empregado como variável espectral fundamental para caracterizar o estado fisiológico da cultura da soja e como variável de entrada tanto no modelo físico quanto no módulo de aprendizado de máquina.

A formulação matemática do NDVI é expressa por:

$$NDVI(t) = \frac{NIR(t) - RED(t)}{NIR(t) + RED(t)} \quad (16)$$

2.9 Construção do Dataframe Meteorológico-Base

O dataframe meteorológico-base resultante desta etapa constitui a referência climática do pipeline computacional, sendo composto pelas variáveis temperatura do ar, precipitação, umidade relativa, radiação solar e velocidade do vento, provenientes da estação convencional do INMET em Canarana–MT (código 83270). Esse conjunto de variáveis serve como insumo direto para o alinhamento temporal com a cena hiperespectral EO-1 Hyperion L1T, ID EO1H2240692015363110PF, adquirida em 29/12/2015, e para a modelagem dos processos biofísicos e computacionais descritos nos itens subsequentes deste capítulo.

Tabela 01 – Caracterização do dataframe meteorológico-base utilizado no estudo.

Fonte: elaboração própria, 2025.

A tabela apresenta o conjunto meteorológico-base utilizado no estudo, reunindo as variáveis climáticas empregadas na organização do pipeline analítico. Esse conjunto constitui a referência inicial para o alinhamento temporal com a cena hiperespectral e para a parametrização das etapas biofísicas e computacionais subsequentes.

2.10 Seleção e Caracterização da Cena Hiperespectral

A cena hiperespectral selecionada para esta pesquisa corresponde ao produto EO-1 Hyperion L1T, identificado pelo código EO1H2240692015363110PF, adquirido em 29/12/2015, com resolução espacial de 30 m e 242 bandas espectrais distribuídas entre aproximadamente 357 e 2576 nm. A imagem corresponde ao path/row 224/069 e foi escolhida por apresentar cobertura adequada da área de interesse, baixa interferência de nuvens e integridade espectral compatível com a aplicação de índices de vegetação e variáveis biofísicas.

A escolha deste produto específico fundamentou-se em três critérios técnicos de qualidade:

1. Nível de Processamento: A cena foi obtida no nível L1T (Level 1 Terrain Corrected), que já incorpora correções radiométricas sistemáticas e correções geométricas de precisão utilizando pontos de controle em solo e Modelos Digitais de Elevação (DEM) para correção de paralaxe topográfica.

2. Geometria de Aquisição: A imagem está projetada no sistema UTM (Universal Transverse Mercator), Zona 22 Sul, com Datum WGS-84, garantindo compatibilidade direta com os dados cartográficos nacionais. O ângulo de visada do sensor (Look Angle) foi de $-6,72^\circ$, próximo ao nadir, minimizando distorções angulares na reflectância do dossel.

3. Integridade Espectral: A validação preliminar dos metadados confirmou a integridade das bandas do infravermelho próximo (VNIR) e de ondas curtas (SWIR), aplicando-se os fatores de escala padrão (40 para VNIR e 80 para SWIR) para a conversão dos Níveis Digitais (DN) em Radiância ($\text{W} \cdot \text{m}^{-2} \cdot \text{sr}^{-1} \cdot \mu\text{m}^{-1}$), conforme especificações do arquivo de metadados (_MTL_L1T.TXT).

Este recorte temporal (dezembro/2015) situa-se estrategicamente na janela de pleno desenvolvimento vegetativo da soja na região do Mato Grosso, permitindo a captura da máxima expressão fotossintética da cultura.

2.11 Delimitação e Mascaramento das Áreas de Soja

Para garantir que a modelagem do fluxo de CO_2 refletisse exclusivamente a dinâmica da cultura agrícola, foi implementado um procedimento de mascaramento espacial rigoroso,

isolando os pixels de soja de outros alvos presentes na cena (como vegetação nativa, corpos hídricos ou solo exposto).

A delimitação das áreas de cultivo baseou-se nos dados do MapBiomias Coleção 9, utilizando a classificação de uso e cobertura da terra referente ao ano de 2015 para a geração da máscara binária de soja, recortada pelo footprint da cena EO-1 Hyperion L1T, ID EO1H2240692015363110PF, adquirida em 29/12/2015, com resolução espacial de 30 m. O processamento seguiu um fluxo automatizado de três etapas:

1. Recorte Espacial (Clipping): O raster do MapBiomias foi recortado utilizando a geometria exata do footprint da cena Hyperion (ID EO1H2240692015363110PF), gerando um arquivo intermediário restrito à Área de Interesse (AOI).

2. Filtragem Temática: Foi aplicada uma operação booleana para isolar a classe "Soja" (Classe 39 no esquema do MapBiomias), gerando uma máscara binária onde o valor 1 representa a presença da cultura e o valor 0 (ou NoData) representa outras classes.

3. Alinhamento de Grade (Resampling): A máscara binária foi reamostrada para coincidir perfeitamente com a resolução espacial (30 m) e o alinhamento de pixel da cena Hyperion. Este passo foi crítico para permitir operações algébricas pixel-a-pixel nas etapas subsequentes de cálculo de índices. O produto final deste processo foi o arquivo matricial SOJA_MASK_ALINHADA_20260126_164753.tif, validado quanto à consistência geométrica.

A aplicação desta máscara sobre o cubo de dados hiperespectrais da cena EO-1 Hyperion L1T, ID EO1H2240692015363110PF, adquirida em 29/12/2015, resultou na extração de um subconjunto de dados (dataset espectral) contendo apenas as assinaturas espectrais da soja, eliminando ruídos de borda e efeitos de mistura espectral, conforme evidenciado no inventário de processamento da etapa 01_inputs_canon/mask.

2.12 Extração dos Metadados Temporais das Cenas Hiperespectrais

A extração dos metadados temporais das cenas hiperespectrais teve como finalidade identificar e organizar as informações de tempo associadas à aquisição das imagens do sensor EO-1 Hyperion, garantindo a coerência temporal necessária à integração com os dados meteorológicos. Esses metadados são essenciais para o alinhamento entre as diferentes fontes de dados utilizadas

no pipeline computacional.

Inicialmente, foram extraídas das cenas hiperespectrais as informações de data e horário de aquisição, conforme registradas nos arquivos de metadados fornecidos com os produtos orbitais. Essas informações incluem o instante de passagem do satélite sobre a área de estudo, permitindo a associação precisa entre a resposta espectral observada e as condições atmosféricas correspondentes.

Além da data e hora, foram considerados metadados auxiliares relevantes ao contexto temporal da aquisição, tais como parâmetros orbitais e informações relacionadas à geometria de observação, quando disponíveis. Esses elementos contribuem para a rastreabilidade dos dados e para a compreensão das condições sob as quais a cena foi capturada.

Os metadados temporais extraídos foram organizados de forma estruturada e associados às imagens hiperespectrais correspondentes, constituindo a referência temporal utilizada nas etapas subsequentes de alinhamento com o dataframe meteorológico-base. Essa etapa assegura consistência cronológica no pipeline e estabelece as bases para a integração temporal descrita no item seguinte.

2.13 Estratégia de Alinhamento Temporal (t)

A estratégia de alinhamento temporal adotada nesta pesquisa teve como objetivo assegurar a coerência cronológica entre os dados hiperespectrais e as séries meteorológicas, permitindo sua integração consistente no pipeline computacional. Considerando que as imagens hiperespectrais representam aquisições pontuais no tempo, enquanto os dados meteorológicos constituem séries temporais contínuas, tornou-se necessário definir um critério explícito de correspondência temporal.

O alinhamento temporal foi realizado a partir da data e do horário de aquisição da cena EO-1 Hyperion L1T, ID EO1H2240692015363110PF, adquirida em 29/12/2015, extraídos conforme descrito no item anterior. A esse instante de referência foram associados os registros meteorológicos mais próximos no tempo, provenientes da estação convencional do INMET em Canarana–MT (código 83270), respeitando a resolução temporal original dos dados. Essa abordagem permitiu vincular, a cada observação espectral, um conjunto coerente de condições atmosféricas representativas do momento da aquisição.

A correspondência temporal foi definida de forma unívoca, adotando-se uma estratégia do tipo many-to-one, na qual múltiplos registros meteorológicos provenientes da estação convencional do INMET em Canarana–MT (código 83270) podem ser agregados ou selecionados em função de um único instante de aquisição da cena EO-1 Hyperion L1T, ID EO1H2240692015363110PF, adquirida em 29/12/2015. Esse procedimento visa reduzir inconsistências temporais e garantir que as variáveis climáticas utilizadas na modelagem reflitam adequadamente o contexto ambiental associado à cena.

Com a definição da estratégia de alinhamento temporal (t), estabeleceu-se a base para a integração dos dados hiperespectrais e meteorológicos em uma estrutura comum, assegurando consistência temporal e rastreabilidade ao longo de todo o processo de modelagem computacional descrito neste capítulo.

2.14 Construção do Dataframe Unificado Meteo–Hiperespectral

A construção do dataframe unificado meteo–hiperespectral teve como finalidade integrar, em uma única estrutura de dados, as informações espectrais derivadas das imagens hiperespectrais, os índices de vegetação extraídos, as variáveis meteorológicas e os metadados temporais associados. Essa integração constitui a base operacional para a modelagem computacional do fluxo de dióxido de carbono (CO₂).

O dataframe unificado foi estruturado a partir de uma chave primária composta (t, s), onde (t) representa a referência temporal associada à aquisição da cena hiperespectral e (s) representa a localização espacial do pixel ou unidade espacial correspondente. Essa definição assegura unicidade dos registros, rastreabilidade das informações e consistência na associação entre dados de naturezas distintas.

Foram incorporadas ao dataframe as variáveis espectrais e os índices de vegetação, com destaque para o NDVI, extraídos diretamente das imagens hiperespectrais previamente processadas. Essas variáveis representam a resposta espectral da vegetação e atuam como proxies de características biofísicas relevantes ao balanço de carbono.

Em paralelo, as variáveis meteorológicas provenientes do dataframe meteorológico-base foram integradas segundo a estratégia de alinhamento temporal definida no item 2.13, garantindo correspondência cronológica entre condições atmosféricas e observações espectrais.

Adicionalmente, os metadados temporais associados às cenas hiperespectrais foram incorporados ao dataframe, permitindo a rastreabilidade das aquisições e o controle temporal do conjunto de dados.

O dataframe unificado resultante apresenta, portanto, uma estrutura consolidada e coerente, apta a ser utilizada como entrada nos modelos biofísicos e nos algoritmos de inteligência artificial descritos nas etapas subsequentes. Essa etapa marca a transição entre o processamento e a modelagem, estabelecendo a base de dados integrada sobre a qual se apoia o modelo híbrido proposto nesta tese.

2.15 Validação Estrutural do Dataframe Unificado

A validação estrutural do dataframe unificado meteo-hiperespectral teve como objetivo assegurar a integridade, a consistência e a coerência da estrutura de dados antes da aplicação dos modelos biofísicos e dos algoritmos de inteligência artificial. Essa etapa é essencial para garantir que o conjunto de dados integrado esteja apto ao processamento computacional subsequente.

Inicialmente, foi verificada a consistência da chave primária (t, s), assegurando que cada registro do dataframe correspondesse a uma combinação única de referência temporal e localização espacial. Esse procedimento permitiu confirmar a unicidade dos registros e evitar ambiguidades na associação entre variáveis espectrais, meteorológicas e temporais.

Em seguida, foram avaliados os tipos de dados e a consistência dimensional das variáveis, verificando-se a compatibilidade entre campos numéricos, temporais e categóricos. Essa checagem visou garantir que todas as variáveis estivessem corretamente representadas para uso em operações matemáticas, estatísticas e de aprendizado de máquina.

Por fim, foi realizada uma verificação geral da integridade estrutural do dataframe, incluindo a presença de campos obrigatórios, a ausência de inconsistências de indexação e a conformidade com o esquema de dados definido no pipeline. Essa validação assegurou que o dataframe unificado estivesse estruturado de forma consistente e reproduzível, constituindo uma base confiável para as etapas de análise de qualidade dos dados e modelagem computacional descritas a seguir.

2.16 Análise de Qualidade dos Dados

A análise de qualidade dos dados teve como objetivo assegurar a confiabilidade do dataframe unificado meteo-hiperespectral antes de sua utilização na etapa de modelagem computacional. Essa análise concentrou-se na verificação de aspectos essenciais à integridade dos dados, complementando a validação estrutural realizada no item anterior.

Inicialmente, foi realizada a checagem da existência de registros duplicados associados à chave primária (t, s), de modo a garantir a unicidade das observações e evitar redundâncias que pudessem comprometer a consistência do conjunto de dados. Em seguida, procedeu-se à identificação de valores ausentes nas variáveis que compõem o dataframe, com o intuito de mapear eventuais lacunas decorrentes do processo de integração entre dados espectrais, meteorológicos e temporais.

Quando identificadas, as inconsistências foram tratadas de forma controlada e compatível com os objetivos do estudo, priorizando a preservação da coerência temporal e espacial dos dados e evitando a introdução de vieses artificiais no conjunto final. Essa etapa assegurou que o dataframe utilizado na modelagem apresentasse qualidade adequada, permitindo sua aplicação confiável nos modelos biofísicos e nos algoritmos de inteligência artificial descritos nas seções subsequentes.

2.17 Integração com Modelos Biofísicos (SVAT / ISBA)

A integração com os modelos biofísicos SVAT (Soil–Vegetation–Atmosphere Transfer) e ISBA (Interactions between Soil, Biosphere, and Atmosphere) teve como finalidade incorporar fundamentos físicos ao pipeline computacional, fornecendo variáveis e restrições coerentes com os processos de troca de energia, água e carbono entre o solo, a vegetação e a atmosfera.

Nesta pesquisa, os modelos biofísicos não foram utilizados de forma isolada ou determinística, mas integrados como camada física de suporte ao modelo híbrido. As variáveis espectrais derivadas das imagens hiperespectrais, em conjunto com as variáveis meteorológicas organizadas no dataframe unificado, foram empregadas como entradas para a parametrização conceitual dos processos representados pelos modelos SVAT/ISBA.

A integração foi realizada de modo a preservar a consistência física dos fluxos simulados, permitindo que informações relacionadas ao estado da vegetação, às condições atmosféricas e às propriedades do solo contribuíssem para a modelagem do fluxo de dióxido de carbono (CO_2). Essa abordagem visa reduzir limitações associadas à parametrização fixa dos modelos biofísicos clássicos, ao mesmo tempo em que mantém sua base teórica como referência para o comportamento esperado do sistema ambiental.

Os produtos e variáveis intermediárias oriundos dessa integração foram utilizados como insumos adicionais para a etapa de modelagem computacional baseada em inteligência artificial, descrita no item seguinte. Dessa forma, a combinação entre SVAT/ISBA e técnicas de IA configura o caráter híbrido do modelo proposto, unindo rigor físico e capacidade adaptativa no tratamento de sistemas ambientais complexos.

2.18 Execução do Modelo Biofísico para Estimativa do Fluxo de CO_2

A execução do modelo biofísico nesta pesquisa teve como objetivo a obtenção explícita das variáveis fundamentais do balanço de carbono, produtividade primária bruta (GPP), respiração do ecossistema (Reco) e troca líquida do ecossistema (NEE) a partir da integração entre variáveis espectrais, meteorológicas e ecofisiológicas da cultura da soja. Essa etapa constitui o elo operacional entre a preparação conceitual do modelo ISBA/SVAT e a posterior aplicação das técnicas de inteligência artificial, assegurando que a modelagem híbrida se apoie em estimativas fisicamente coerentes.

Embora o modelo ISBA (Interactions between Soil, Biosphere, and Atmosphere) seja tradicionalmente executado em ambiente offline por meio da plataforma Open-SURFEX, sua implementação integral demanda elevado custo computacional, grande volume de parâmetros edáficos detalhados e extensos períodos de spin-up, o que inviabiliza sua aplicação direta no contexto espacial e temporal específico desta pesquisa. Assim, adotou-se uma alternativa metodológica baseada em um modelo biofísico reduzido, conceitualmente consistente com os princípios do ISBA, amplamente empregada em estudos de balanço de carbono em ecossistemas agrícolas e naturais (MONTEITH, 1972; RUNNING et al., 2004; ZHAO; RUNNING, 2010).

Essa abordagem reduzida preserva os mecanismos centrais de controle do fluxo de carbono: radiação incidente, interceptação luminosa pelo dossel, estado fisiológico da vegetação

e resposta térmica da respiração, permitindo a obtenção de estimativas coerentes de GPP, Reco e NEE em escala horária, compatíveis com os dados meteorológicos ERA5-Land utilizados neste estudo.

2.18.1 Variáveis de entrada do modelo

A execução do modelo biofísico reduzido baseou-se na integração de variáveis meteorológicas, espectrais e ecofisiológicas, selecionadas por sua relevância nos processos de assimilação e respiração do carbono em sistemas agrícolas. As variáveis meteorológicas foram obtidas a partir do conjunto de dados ERA5-Land, considerando a radiação solar de onda curta descendente e a temperatura do ar, ambas representativas do centróide da área cultivada com soja.

A radiação solar incidente foi utilizada como principal controlador da atividade fotossintética, enquanto a temperatura do ar foi empregada como variável reguladora da respiração do ecossistema. Essas forçantes são amplamente reconhecidas como determinantes primários do balanço de carbono em modelos do tipo Soil–Vegetation–Atmosphere Transfer (SVAT), incluindo o ISBA (BALDOCCHI, 2008; DECHARME et al., 2019).

As variáveis espectrais e ecofisiológicas incluíram o Índice de Área Foliar (LAI), obtido a partir de produto MODIS pontual representativo da área de estudo, e a fração de cobertura do dossel (FCOVER), previamente estimada e considerada constante ao longo do período analisado. O LAI foi utilizado como indicador do desenvolvimento estrutural do dossel vegetal, influenciando diretamente a interceptação da radiação solar e, consequentemente, a eficiência da assimilação de carbono.

O modelo biofísico foi executado utilizando como entradas:

Radiação solar de onda curta incidente ($SW\downarrow$), obtida do conjunto ERA5-Land, expressa em $W\ m^{-2}$ e convertida para $MJ\ m^{-2}\ h^{-1}$;

Temperatura do ar (T_{air}), em graus Celsius, derivada da variável $t2m$ do ERA5-Land;

Índice de Área Foliar (LAI), obtido a partir de produto MODIS pontual representativo do centróide da área de soja;

Fração de cobertura do dossel (FCOVER), estimada previamente e considerada constante para o período analisado.

Essas variáveis são compatíveis com os principais controladores ecofisiológicos do balanço de carbono em culturas agrícolas, conforme descrito na literatura especializada (BALDOCCHI, 2008; DECHARME et al., 2019).

2.18.2 Formulação do modelo biofísico reduzido

A produtividade primária bruta (GPP) foi estimada com base no modelo de Eficiência do Uso da Luz (Light Use Efficiency – LUE), originalmente proposto por Monteith (1972) e amplamente aplicado em estudos de produtividade vegetal em escala local, regional e global (RUNNING et al., 2004; ZHAO; RUNNING, 2010). Esse modelo assume que a assimilação de carbono é proporcional à quantidade de radiação fotossinteticamente ativa absorvida pelo dossel vegetal.

A GPP foi calculada conforme a expressão:

$$GPP = \varepsilon \cdot fPAR \cdot PAR \quad (17)$$

em que ε representa a eficiência do uso da radiação, $fPAR$ corresponde à fração da radiação fotossinteticamente ativa absorvida pelo dossel e PAR é a radiação fotossinteticamente ativa incidente.

A PAR foi estimada como uma fração fixa da radiação solar de onda curta incidente, conforme a relação:

$$PAR = 0,45 \cdot SW \quad (18)$$

sendo esse fator amplamente adotado em estudos ecofisiológicos e modelos de superfície terrestre (MONTEITH; UNSWORTH, 1990; RUNNING et al., 2004).

A fração de radiação absorvida pelo dossel ($fPAR$) foi calculada a partir da lei de Beer–Lambert:

$$fPAR = 1 - \exp(-k \cdot LAI) \quad (19)$$

onde k é o coeficiente de extinção do dossel vegetal, assumido constante para a cultura da soja, em concordância com valores reportados na literatura (CAMPBELL; NORMAN, 1998).

2.18.3 Produtos gerados e conexão com as etapas subsequentes

A execução do modelo biofísico resultou na geração explícita de séries temporais horárias de GPP, Reco e NEE, as quais foram armazenadas em formato tabular e acompanhadas de registros automáticos de log e versionamento, assegurando rastreabilidade e reprodutibilidade do processo.

Essas estimativas constituem a base física determinística utilizada na etapa seguinte de análise do fluxo de CO₂ e, posteriormente, na construção do modelo híbrido baseado em inteligência artificial. Dessa forma, a modelagem computacional aplicada nesta pesquisa não substitui os fundamentos físicos do sistema solo–planta–atmosfera, mas os utiliza como referência conceitual para a integração com métodos orientados por dados.

A respiração do ecossistema (Reco) foi estimada por meio de uma formulação empírica baseada no conceito de Q₁₀, que descreve a sensibilidade da respiração à temperatura do ar. Esse tipo de abordagem é amplamente empregado em modelos de ecossistemas quando não se dispõe de uma separação detalhada dos compartimentos respiratórios (BALDOCCHI, 2008).

A Reco foi calculada conforme:

$$Reco = R_{ref} \cdot Q_{10}^{\left(\frac{T_{air}-T_{ref}}{10}\right)} \quad (20)$$

em que R_{ref} representa a taxa de respiração de referência associada à temperatura T_{ref} , Q_{10} corresponde ao fator de sensibilidade térmica e T_{air} é a temperatura do ar em graus Celsius. Essa formulação permite representar de forma simplificada, porém fisicamente coerente, a resposta térmica da respiração do ecossistema.

2.18.4 Determinação da troca líquida do ecossistema (NEE)

A troca líquida do ecossistema (NEE) foi determinada a partir da diferença entre a respiração do ecossistema e a produtividade primária bruta, conforme a relação:

$$NEE = Reco - GPP \quad (21)$$

Nessa convenção, valores negativos de NEE indicam predomínio da assimilação de carbono pelo ecossistema, caracterizando-o como sumidouro de CO₂, enquanto valores positivos indicam emissão líquida de carbono para a atmosfera. Essa definição é amplamente adotada em estudos baseados em medições de fluxo por covariância dos vórtices turbulentos (eddy covariance).

2.18.5 Produtos gerados e articulação com as etapas subsequentes

A execução do modelo biofísico resultou na geração explícita de séries temporais horárias de GPP, Reco e NEE, armazenadas em formato tabular e acompanhadas de registros automáticos de execução e versionamento, assegurando rastreabilidade e reprodutibilidade do processo.

Esses produtos constituem a base física determinística para a análise do fluxo de CO₂ apresentada na etapa seguinte da tese, bem como para a construção do modelo híbrido baseado em inteligência artificial. Dessa forma, a abordagem adotada garante que os métodos orientados por dados sejam aplicados sobre variáveis fisicamente consistentes, preservando a coerência ecofisiológica do sistema solo-planta-atmosfera.

2.19 Modelagem Híbrida Baseada em Inteligência Artificial

A modelagem híbrida baseada em inteligência artificial (IA) foi adotada nesta pesquisa com o objetivo de integrar as estimativas biofísicas do fluxo de carbono, obtidas na Seção 2.18, com informações espectrais hiperespectrais e variáveis ambientais, ampliando a capacidade de representação dos processos envolvidos na dinâmica do CO₂ em cultivares de soja. Diferentemente de abordagens puramente orientadas por dados, a estratégia híbrida empregada parte de um

conjunto de variáveis fisicamente interpretáveis, garantindo que os modelos de IA sejam treinados sobre uma base conceitualmente consistente.

Nesse contexto, as saídas do modelo biofísico produtividade primária bruta (GPP), respiração do ecossistema (Reco) e troca líquida do ecossistema (NEE) desempenham papel central na arquitetura híbrida. Essas variáveis são utilizadas tanto como alvos de predição quanto como variáveis intermediárias, permitindo avaliar a capacidade dos modelos de IA em reproduzir e refinar padrões ecofisiológicos previamente estabelecidos. Essa abordagem reduz o risco de sobreajuste e favorece a interpretabilidade dos resultados, aspecto relevante em aplicações ambientais e agrícolas.

2.19.1 Conjunto de variáveis de entrada

Os modelos de inteligência artificial foram estruturados a partir da integração de três grupos principais de variáveis, compreendendo variáveis espectrais derivadas das imagens hiperespectrais, incluindo índices de vegetação sensíveis à estrutura do dossel, ao teor de água e à atividade fotossintética; variáveis ambientais provenientes do conjunto ERA5-Land, como radiação solar incidente, temperatura do ar e variáveis atmosféricas auxiliares; e variáveis biofísicas obtidas a partir do modelo reduzido descrito na Seção 2.18, em especial GPP, Reco e NEE.

Essa combinação permite que os modelos de IA explorem relações não lineares entre as condições ambientais, o estado espectral da vegetação e os fluxos de carbono, preservando a coerência física do sistema solo–planta–atmosfera.

2.19.2 Arquitetura e estratégia de modelagem

A modelagem híbrida foi conduzida utilizando algoritmos de aprendizado supervisionado adequados à regressão, tais como métodos baseados em árvores de decisão e regressão não linear. Esses algoritmos foram selecionados por sua capacidade de lidar com relações complexas entre variáveis, resiliência a dados heterogêneos e potencial de interpretação das contribuições relativas das variáveis de entrada.

O treinamento dos modelos foi realizado a partir das séries temporais integradas, considerando estratégias de validação que respeitam a dependência temporal dos dados, evitando vazamento de informação entre conjuntos de treino e teste. Métricas de desempenho como o erro quadrático médio (RMSE), o coeficiente de determinação (R^2) e o erro absoluto médio (MAE) foram utilizadas para avaliar a qualidade das predições.

2.19.3 Avaliação do ganho em relação ao modelo físico

Um dos objetivos centrais da modelagem híbrida consiste em quantificar o ganho de desempenho obtido com a incorporação da inteligência artificial em relação ao modelo biofísico isolado. Para isso, os resultados dos modelos de IA foram comparados diretamente às estimativas do modelo físico reduzido, analisando-se a capacidade de reprodução dos padrões temporais do fluxo de CO_2 e a redução dos erros de predição.

Essa comparação permite avaliar em que medida a inteligência artificial contribui para capturar variações não explicitamente representadas pelo modelo biofísico, como efeitos combinados de variáveis espectrais e ambientais, sem romper com os princípios ecofisiológicos fundamentais.

2.19.4 Papel da modelagem híbrida na estrutura da tese

A modelagem híbrida baseada em inteligência artificial não substitui o modelo biofísico adotado nesta pesquisa, mas atua como um mecanismo complementar, capaz de explorar informações adicionais presentes nos dados hiperespectrais e ambientais. Dessa forma, a integração entre modelagem física e computacional constitui o núcleo metodológico da tese, permitindo avançar na estimativa do fluxo de CO_2 em sistemas agrícolas da Amazônia Legal com maior flexibilidade, interoperabilidade e potencial de generalização.

2.20 Avaliação e Validação dos Resultados

A avaliação e validação dos resultados obtidos nesta pesquisa foram conduzidas com base em critérios metodológicos definidos previamente, considerando as limitações inerentes à disponibilidade de dados observacionais diretos de fluxo de CO₂ na área de estudo. Em função da ausência de medições in situ por covariância dos vórtices turbulentos (eddy covariance), a validação foi realizada por meio de abordagens indiretas, amplamente utilizadas em estudos de modelagem ambiental e agrícola.

Nesta tese, a base oficial de validação dos resultados é definida como uma abordagem indireta multicritério. Em razão da ausência de medições micrometeorológicas diretas de fluxo de CO₂ na área de estudo, a validação foi estruturada a partir de quatro eixos complementares: (i) coerência física e ecofisiológica das estimativas de GPP, Reco e NEE; (ii) consistência estatística dos resultados obtidos pelos modelos biofísico e híbrido; (iii) comparação com ordens de grandeza, padrões temporais e evidências reportadas na literatura científica e em redes de referência internacional, especialmente a FLUXNET; e (iv) consistência espacial, espectral e ambiental dos insumos observacionais utilizados no estudo, incluindo a cena EO-1 Hyperion path/row 224/069, a máscara agrícola derivada do MapBiomas.

Os dados meteorológicos da estação convencional de Canarana–MT (INMET, código 83270) e o LAI de referência obtido por sensoriamento remoto foram utilizados como evidências complementares no processo de validação. Dessa forma, a validação adotada nesta pesquisa não se apoia em uma única base observacional isolada, mas em um conjunto hierarquizado de evidências convergentes, compatível com a natureza híbrida e com as limitações empíricas do estudo.

Os resultados do fluxo de CO₂, bem como das variáveis intermediárias de produtividade primária bruta (GPP) e respiração do ecossistema (Reco), foram avaliados quanto à sua coerência física e ecofisiológica, considerando padrões temporais diurnos e sazonais esperados para culturas agrícolas do tipo C3. Adicionalmente, foram empregadas métricas estatísticas para quantificar o desempenho dos modelos híbridos baseados em inteligência artificial, incluindo o erro quadrático médio (RMSE), o erro absoluto médio (MAE) e o coeficiente de determinação (R^2).

2.21 Definição do modelo de Inteligência Artificial

A modelagem híbrida baseada em Inteligência Artificial adotada nesta pesquisa fundamenta-se na integração entre um modelo biofísico determinístico e um modelo computacional orientado por dados, com o objetivo de aprimorar a estimativa do fluxo de dióxido de carbono (CO₂) em cultivos de soja na Amazônia Legal. Nesse contexto, a Inteligência Artificial não substitui a modelagem baseada em processos, mas atua de forma complementar, capturando relações não lineares e efeitos residuais não explicitamente representados pelas equações físicas.

O problema de aprendizado é formulado como uma tarefa de regressão supervisionada, na qual o modelo busca estimar a Troca Líquida de Ecossistema (NEE), expressa em gCO₂ m⁻² h⁻¹, a partir de um conjunto de variáveis ambientais, espectrais e biofísicas. A escolha dessa abordagem é justificada pela natureza contínua da variável-alvo e pela necessidade de preservar a coerência ecofisiológica do sistema solo-planta-atmosfera.

Entre os algoritmos de regressão avaliados na literatura aplicada à agricultura de precisão e à modelagem de fluxos de carbono, destacam-se métodos baseados em árvores de decisão e técnicas de ensemble, em especial o Extreme Gradient Boosting (XGBoost). Esse algoritmo foi selecionado por sua elevada capacidade de modelar relações não lineares complexas, resiliência à multicolinearidade entre variáveis e eficiência computacional em conjuntos de dados heterogêneos (CHEN; GUESTRIN, 2016; CHEN et al., 2019).

Do ponto de vista matemático, o modelo XGBoost representa a função de predição como a soma de múltiplas árvores de regressão:

$$\hat{y}(t) = \sum_{k=1}^K f_k(\mathbf{x}(t)), \quad f_k \in \mathcal{F} \quad (22)$$

em que $(\hat{y}(t))$ corresponde à estimativa da variável-alvo no instante t , $\mathbf{x}(t)$ representa o vetor de variáveis de entrada, f_k são funções associadas às árvores de decisão e K é o número total de árvores do ensemble.

O processo de treinamento do modelo consiste na minimização de uma função objetivo regularizada, definida como:

$$\mathcal{L} = \sum_{i=1}^n \ell(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k) \quad (23)$$

onde $\ell(y_i, \hat{y}_i)$ é a função de perda associada ao erro de predição e $\Omega(f_k)$ representa o termo de regularização, responsável por penalizar a complexidade do modelo e reduzir o risco de sobreajuste. Para problemas de regressão contínua, a função de perda adotada é o erro quadrático:

$$\ell(y_i, \hat{y}_i) = (y_i - \hat{y}_i)^2 \quad (24)$$

A regularização aplicada a cada árvore é expressa por:

$$\Omega(f) = \gamma T + \frac{\lambda}{2} \sum_{j=1}^T w_j^2 \quad (25)$$

em que T é o número de folhas da árvore, w_j são os pesos associados às folhas, γ controla a penalização por complexidade estrutural e λ regula a magnitude dos pesos, conforme a formulação regularizada proposta para o XGBoost (CHEN; GUESTRIN, 2016).

A adoção do XGBoost como modelo de Inteligência Artificial nesta tese está alinhada ao princípio da modelagem híbrida físico–dados, no qual o modelo biofísico determinístico fornece uma estimativa inicial fisicamente consistente do fluxo de CO₂, enquanto o algoritmo de aprendizado supervisionado atua como um refinador estatístico, ampliando a capacidade preditiva do sistema sem comprometer sua base teórica.

2.22 Integração das variáveis espectrais, ambientais e biofísicas

A etapa de integração das variáveis constitui o elo fundamental entre o modelo biofísico determinístico e o módulo de Inteligência Artificial, assegurando que a modelagem híbrida seja construída sobre uma base fisicamente coerente e estatisticamente consistente. Nesta pesquisa, as variáveis utilizadas pelo modelo de IA são organizadas de modo a representar, de forma complementar, o estado espectral da vegetação, as condições ambientais atmosféricas e os processos ecofisiológicos associados ao balanço de carbono.

O problema é formulado no domínio temporal discreto, considerando séries horárias ao

longo do período de estudo. Seja $t = 1, 2, \dots, T$ o índice temporal correspondente a cada hora analisada. Para cada instante t , define-se um vetor de variáveis de entrada $\mathbf{X}(t)$, composto pela concatenação de três subconjuntos principais:

$$\mathbf{X}(t) = \begin{bmatrix} \mathbf{X}_{spec}(t) & \mathbf{X}_{amb}(t) & \mathbf{X}_{bio}(t) \end{bmatrix} \quad (26)$$

em que $\mathbf{X}_{spec}(t)$ representa as variáveis espectrais, $\mathbf{X}_{amb}(t)$ as variáveis ambientais e $\mathbf{X}_{bio}(t)$ as variáveis biofísicas.

As variáveis espectrais são representadas por:

$$\mathbf{X}_{spec}(t) = \begin{bmatrix} SI_1(t), SI_2(t), \dots, SI_p(t) \end{bmatrix} \quad (27)$$

onde $SI_i(t)$ denota o valor do i -ésimo índice espectral no instante t , e p corresponde ao número total de índices considerados.

As variáveis ambientais são definidas por:

$$\mathbf{X}_{amb}(t) = \begin{bmatrix} SWDOWN(t), T_{air}(t), VPD(t), RH(t) \end{bmatrix} \quad (28)$$

em que $SWDOWN(t)$ corresponde à radiação solar incidente (W m^{-2}), $T_{air}(t)$ à temperatura do ar, $VPD(t)$ ao déficit de pressão de vapor e $RH(t)$ à umidade relativa do ar.

As variáveis biofísicas são expressas por:

$$\mathbf{X}_{bio}(t) = \begin{bmatrix} LAI(t), fPAR(t), PAR(t), GPP(t), Reco(t) \end{bmatrix} \quad (29)$$

com $fPAR(t) = 1 - e^{-k \cdot LAI(t)}$ e $PAR(t) = 0,45 \cdot SWDOWN(t)$.

A partir dessa estrutura, constrói-se a matriz de dados utilizada pelo modelo de Inteligência Artificial:

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}(1) \\ \mathbf{X}(2) \\ \vdots \\ \mathbf{X}(T) \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y(1) \\ y(2) \\ \vdots \\ y(T) \end{bmatrix} \quad (30)$$

em que $y(t)$ representa o resíduo ΔNEE no instante t , expresso em $\text{gCO}_2 \text{ m}^{-2} \text{ h}^{-1}$.

Essa organização permite que o modelo de Inteligência Artificial explore simultaneamente informações espectrais, ambientais e biofísicas, preservando a coerência física do sistema solo–planta–atmosfera e fornecendo uma base estruturada para o treinamento supervisionado descrito no item subsequente.

2.23 Treinamento do Modelo de Aprendizado de Máquina

O treinamento do modelo de aprendizado de máquina foi realizado com o objetivo de estimar o resíduo do modelo biofísico simplificado ($fis0$), definido como a diferença entre o fluxo de CO_2 estimado pelo modelo biofísico refinado e aquele obtido pelo modelo físico parametrizado com valores fixos da literatura. Essa abordagem caracteriza uma modelagem híbrida residual, na qual o aprendizado de máquina atua exclusivamente como corretor dos erros sistemáticos do modelo físico determinístico.

O modelo adotado foi o XGBoost em modo de regressão, escolhido por sua capacidade de modelar relações não lineares e interações complexas entre variáveis ambientais e biofísicas, mantendo estabilidade numérica mesmo com conjuntos de dados de dimensão moderada.

A variável alvo do treinamento foi definida como:

$$\Delta NEE = NEE_{ref} - NEE_{fis0} \quad (31)$$

em que NEE_{ref} representa o fluxo de CO_2 de referência (neste estudo, obtido pelo modelo biofísico refinado) e NEE_{fis0} corresponde ao fluxo estimado pelo modelo físico simplificado.

O conjunto de variáveis explicativas incluiu informações ambientais, espectrais e biofísicas já disponíveis no pipeline de modelagem, a saber: radiação solar incidente, temperatura do ar,

índice de área foliar (LAI), fração de radiação fotossinteticamente ativa absorvida (fPAR), radiação fotossinteticamente ativa (PAR), produtividade primária bruta estimada pelo modelo físico simplificado (GPP_{fis0}) e respiração do ecossistema estimada pelo mesmo modelo ($Reco_{fis0}$).

O treinamento foi conduzido respeitando a estrutura temporal da série de dados, adotando-se uma separação cronológica entre conjuntos de treino e validação. O período de 1º de outubro a 30 de novembro de 2015 foi utilizado para o treinamento do modelo, enquanto o intervalo de 1º a 30 de dezembro de 2015 foi reservado exclusivamente para validação independente, evitando vazamento temporal de informação.

O processo de otimização do modelo baseou-se na minimização da função de perda quadrática média, conforme:

$$\min_{\theta} \frac{1}{n} \sum_{i=1}^n \left(\Delta NEE_i - \widehat{\Delta NEE}_i(\theta) \right)^2$$

em que θ representa o conjunto de parâmetros do modelo XGBoost e $\widehat{\Delta NEE}$ é o resíduo estimado pelo modelo.

Após o treinamento, o modelo foi utilizado para estimar o resíduo do fluxo de CO₂ no conjunto de validação, permitindo a obtenção do fluxo híbrido conforme:

$$NEE_{hib} = NEE_{fis0} + \widehat{\Delta NEE}$$

Esse procedimento garante que a estimativa final preserve a coerência biofísica do modelo determinístico, ao mesmo tempo em que incorpora a capacidade do aprendizado de máquina de capturar padrões residuais não representados pela parametrização fixa.

A interpretação dos resultados foi complementada por uma validação conceitual com a literatura científica, comparando ordens de grandeza e comportamentos gerais com estudos prévios que utilizam modelos biofísicos e medições de fluxo em sistemas agrícolas semelhantes. As limitações associadas à ausência de dados observacionais diretos foram explicitamente discutidas, bem como suas implicações para a generalização dos resultados.

Os procedimentos de avaliação e validação aqui descritos foram detalhados e aplicados no capítulo de resultados desta tese.

3 RESULTADOS

Este capítulo apresenta os resultados obtidos a partir da aplicação do modelo computacional híbrido desenvolvido nesta pesquisa para a estimativa do fluxo de dióxido de carbono (CO_2) em áreas de cultivo de soja na Amazônia Legal. Os resultados decorrem da integração entre dados hiperespectrais do sensor EO-1 Hyperion, variáveis meteorológicas e modelos biofísicos, conforme os procedimentos descritos no Capítulo 2.

Inicialmente, são apresentados os produtos intermediários gerados pelo pipeline computacional, com destaque para os índices espectrais e as estimativas de fluxo de CO_2 produzidas pelo modelo híbrido. Em seguida, são analisados os padrões temporais e espaciais observados, bem como a consistência das estimativas em relação a dados secundários disponíveis na literatura científica.

A apresentação dos resultados é conduzida de forma descritiva e analítica, reservando-se as interpretações mais amplas e implicações ambientais para a seção de discussão. Dessa forma, este capítulo concentra-se na exposição objetiva dos resultados obtidos, fornecendo a base empírica para as análises e conclusões desenvolvidas posteriormente.

3.1 Resultados dos Índices Espectrais

Este item apresenta os resultados obtidos a partir do cálculo do índice de vegetação NDVI, derivado das imagens hiperespectrais do sensor EO-1 Hyperion, conforme descrito no Capítulo 2. O NDVI foi utilizado como principal indicador espectral do estado fisiológico da cultura da soja, servindo como variável de entrada no modelo híbrido de estimativa do fluxo de dióxido de carbono (CO_2).

Os mapas de NDVI gerados evidenciam a variabilidade espacial da resposta espectral da vegetação nas áreas de cultivo analisadas, refletindo diferenças associadas ao vigor vegetativo e às condições locais do dossel. Observa-se a predominância de valores positivos de NDVI nas regiões correspondentes às áreas agrícolas, compatíveis com superfícies vegetadas ativas.

Além da análise espacial, os valores de NDVI foram avaliados de forma descritiva,

considerando sua distribuição e coerência com o período fenológico da cultura no momento da aquisição da cena hiperespectral. Os resultados obtidos mostram-se consistentes com padrões reportados na literatura para cultivos de soja em ambientes tropicais, indicando adequação do índice como variável representativa no contexto da modelagem proposta.

Os produtos gerados nesta etapa, mapas e estatísticas descritivas de NDVI constituem a base espectral utilizada na modelagem do fluxo de CO₂ apresentada no item subsequente.

Delimitação das áreas de soja na cena HSI Hyperion (2015)


Com o objetivo de verificar a ocorrência da cultura da soja na área imageada pelo sensor hiperespectral Hyperion, foi realizada a integração entre dados de sensoriamento remoto orbital e informações de uso e cobertura da terra provenientes do projeto MapBiomass. Inicialmente, a área de interesse (AOI) foi definida exclusivamente a partir do footprint real da cena EO-1 Hyperion correspondente ao path/row 224/069, adotada como referência espacial da pesquisa no estado de Mato Grosso, garantindo aderência espacial rigorosa e evitando aproximações geométricas manuais.

Em seguida, utilizou-se o mapa anual de uso e cobertura da terra do MapBiomass (Coleção 9), referente ao ano de 2015, selecionando a classe correspondente à cultura da soja (classe 39). A partir da interseção espacial entre o footprint da cena hiperespectral adotada para o estado de Mato Grosso e o mapa agrícola, foi possível identificar e extrair exclusivamente as áreas cultivadas com soja contidas no interior da área de interesse.

O procedimento confirmou a presença significativa da cultura da soja na área imageada, evidenciando a compatibilidade entre a cena hiperespectral selecionada e as áreas agrícolas de interesse no estado de Mato Grosso. A partir dessa interseção, foi gerada uma máscara binária de soja, recortada exatamente pelo footprint da cena, a qual passou a ser utilizada como insumo espacial nas etapas subsequentes de extração espectral e modelagem biofísica.

O mapa da máscara binária da cultura da soja (classe 39), derivada do MapBiomass LULC – Coleção 9 (ano de referência 2015), foi recortado pelo footprint real da cena hiperespectral EO-1 Hyperion adotada nesta pesquisa para o estado de Mato Grosso, correspondente ao path/row 224/069. As áreas destacadas representam exclusivamente pixels classificados como soja no interior da área imageada pelo sensor, conforme apresentado na Figura 02.

Figura 02 – Máscara de soja na área da cena HSI Hyperion (2015)



Fonte: elaboração própria, 2025.

Integração de dados meteorológicos coincidentes à cena HSI de 2015

Com o objetivo de incorporar variáveis meteorológicas compatíveis temporal e espacialmente com a cena EO-1 Hyperion L1T, ID EO1H2240692015363110PF, adquirida em 29/12/2015, foi realizada a identificação e o processamento de dados provenientes de estação meteorológica oficial próxima à área imageada. Considerando a localização do footprint da cena correspondente ao path/row 224/069, adotou-se a estação meteorológica convencional do Instituto Nacional de Meteorologia (INMET) localizada em Canarana–MT (código 83270), por sua proximidade espacial em relação à área de estudo e por apresentar disponibilidade das variáveis climáticas necessárias.

Nesta etapa do trabalho foi estruturado e executado um pipeline computacional progressivo, reprodutível e rastreável para integração da cena EO-1 Hyperion L1T, ID EO1H2240692015363110PF, adquirida em 29/12/2015, da máscara binária de soja derivada do MapBiomias Coleção 9 (ano de referência 2015) e das variáveis meteorológicas provenientes da estação convencional do INMET em Canarana–MT (código 83270), com foco na análise da cultura da soja na Amazônia

Legal, especificamente em áreas agrícolas selecionadas no estado de Mato Grosso. O processo foi desenvolvido de forma incremental, com validação contínua de cada fase, geração de artefatos intermediários e registros automáticos de logs técnicos, garantindo transparência metodológica e possibilidade de replicação.

Inicialmente, foi realizada a seleção e validação da cena hiperespectral EO-1 Hyperion L1T, ID EO1H2240692015363110PF, adquirida em 29/12/2015, priorizando produto científico com correção geométrica e resolução espacial de 30 m. A cena escolhida corresponde ao path/row 224/069, adotado como referência espacial desta pesquisa para o estado de Mato Grosso. O produto apresenta integridade radiométrica e geométrica compatíveis com os objetivos do estudo, tendo sido inventariado e documentado em etapa preliminar do pipeline analítico.

Em seguida, procedeu-se à identificação e extração das áreas de cultivo de soja coincidentes com o footprint exato da cena EO-1 Hyperion L1T, ID EO1H2240692015363110PF, adquirida em 29/12/2015. Para isso, foram avaliadas diferentes coleções do projeto MapBiomass, constatando-se a adequação da Coleção 9 para o ano de 2015 no contexto da área de estudo. A máscara binária de soja, derivada dessa base temática, foi então intersectada espacialmente com o polígono da cena adotada nesta pesquisa, resultando em uma máscara recortada que representa exclusivamente as áreas de soja contidas no domínio espacial da imagem HSI. O produto final foi exportado em formato GeoTIFF, preservando o sistema de referência espacial compatível com a cena hiperespectral utilizada para o estado de Mato Grosso.

Paralelamente, realizou-se a integração de dados meteorológicos visando contextualizar as condições ambientais no dia da aquisição da imagem hiperespectral. Foram avaliadas diferentes estações meteorológicas disponíveis na região, considerando proximidade espacial e disponibilidade de variáveis.

A estação meteorológica convencional do INMET localizada em Canarana-MT (código 83270) foi adotada por sua proximidade espacial em relação à área de estudo definida no estado de Mato Grosso e pela disponibilidade das variáveis climáticas necessárias à análise. Os dados meteorológicos foram obtidos em formato CSV e submetidos a um procedimento de leitura resiliente, capaz de lidar com inconsistências de formatação e número de colunas.

Posteriormente, os registros foram filtrados estritamente para a data da aquisição da cena hiperespectral, mantendo todas as variáveis disponíveis nesse dia, como temperatura, umidade e precipitação. O resultado consistiu em um conjunto de dados meteorológicos diário, padronizado

e acompanhado de log diagnóstico

Na sequência, foi estruturada a fase de definição e cálculo dos índices espectrais. Inicialmente, foi elaborado um catálogo formal de índices, no qual foram definidos, de forma explícita, os índices NDVI, EVI, SAVI, OSAVI, GNDVI, NDRE, PRI, NDWI (Gao), NDMI e NBR. Para cada índice foram especificadas a formulação matemática, os papéis espectrais envolvidos (por exemplo, RED, NIR e SWIR) e os comprimentos de onda teóricos associados, além de parâmetros adicionais quando aplicável, como o fator L no índice SAVI. Esse catálogo foi armazenado em formato estruturado (JSON), permitindo leitura automática pelos scripts subsequentes.

Considerando a natureza hiperespectral do sensor Hyperion, foi necessária a correspondência entre os comprimentos de onda teóricos dos índices e as bandas reais do sensor. Para isso, foi gerado um mapeamento completo entre o índice de cada banda, seu código identificador e o respectivo comprimento de onda em nanômetros. A partir dessa tabela, foi implementado um procedimento automatizado de seleção das bandas mais próximas aos comprimentos de onda alvo de cada índice, registrando-se também o erro espectral associado a essa aproximação. Esse processo resultou em um arquivo CSV contendo a seleção final das bandas Hyperion a serem utilizadas em cada índice espectral.

O cálculo dos índices espectrais foi realizado diretamente a partir dos arquivos GeoTIFF individuais de cada banda Hyperion, sem o uso de empilhamentos virtuais ou dependência de ferramentas externas como GDAL. Essa decisão metodológica foi adotada após a identificação de limitações no ambiente computacional, bem como para garantir maior portabilidade e controle do processamento. Durante essa etapa, foram enfrentadas dificuldades relacionadas à escrita de arquivos GeoTIFF com dimensões não compatíveis com esquemas de blocagem padrão, o que foi solucionado mediante a adoção de escrita sem tiling e com compressão DEFLATE, eliminando a exigência de múltiplos específicos de dimensão e preservando o georreferenciamento original.

Os índices foram calculados em precisão de ponto flutuante (float32), com tratamento explícito de valores inválidos e conversão de valores ausentes para nodata. Cada índice resultou em um arquivo GeoTIFF individual, georreferenciado, acompanhado de logs detalhados contendo informações sobre bandas utilizadas, parâmetros aplicados, eventuais falhas e caminhos dos produtos gerados. Todo o processo foi versionado e estruturado em pastas específicas, assegurando rastreabilidade completa dos dados e dos procedimentos computacionais.

Dessa forma, ao final desta etapa, estabelece-se um conjunto integrado de produtos consistindo na cena hiperespectral validada, na máscara espacial de soja coincidente, nos dados meteorológicos diários e nos índices espectrais derivados, formando a base analítica necessária para as etapas subsequentes de extração de métricas, análise estatística e modelagem propostas neste trabalho.

3.2 Índices espectrais calculados para áreas de soja

3.2.1 Cálculo dos índices a partir das bandas Hyperion e máscara de soja

A estimativa de variáveis biofísicas da vegetação por meio de índices espectrais constitui uma etapa central desta pesquisa, uma vez que tais índices sintetizam relações espectrais associadas ao vigor vegetativo, à umidade do dossel e ao estado fisiológico das plantas. No presente trabalho, os índices foram calculados a partir de bandas da cena EO-1 Hyperion L1T, ID EO1H2240692015363110PF, adquirida em 29/12/2015, previamente selecionadas com base em sua correspondência espectral com regiões-chave do espectro eletromagnético (vermelho, infravermelho próximo e infravermelho de ondas curtas).

Antes do cálculo dos índices, todas as bandas passaram por um processo rigoroso de padronização espacial, garantindo a perfeita correspondência geométrica entre pixels. Em seguida, foi aplicada uma máscara binária de áreas cultivadas com soja, derivada de dados do MapBiomass e reprojeta para o mesmo grid espacial da imagem hiperespectral. Essa etapa assegura que os cálculos subsequentes sejam restritos exclusivamente às áreas agrícolas de interesse, eliminando a influência espectral de solos expostos, corpos d'água, vegetação nativa ou áreas antrópicas não relacionadas ao cultivo de soja.

Com base nessa estrutura conceitual, a Tabela 02 sistematiza os índices espectrais adotados neste estudo, explicitando as respectivas bandas da cena EO-1 Hyperion L1T, ID EO1H2240692015363110PF, adquirida em 29/12/2015, utilizadas em cada cálculo. A seleção das bandas foi realizada a partir da correspondência direta entre os comprimentos de onda teóricos definidos na literatura e as bandas efetivamente disponíveis nessa cena, previamente corrigida geometricamente, alinhada ao grid espacial da imagem e recortada pela máscara binária de soja derivada do MapBiomass Coleção 9 (ano 2015). Essa abordagem assegura consistência

espectral, reprodutibilidade metodológica e aderência ao modelo biofísico empregado para a estimativa do fluxo de CO₂.

Tabela 02 – Índices e bandas Hyperion (selecionadas pelo λ mais próximo no arquivo .hdr, 242 bandas).

Fonte: elaboração própria, 2025.

Estrutura conceitual do cálculo dos índices

O cálculo de cada índice espectral segue uma estrutura conceitual comum, representada graficamente por diagramas de fluxo específicos (um para cada índice), nos quais são explicitadas:

As bandas de entrada, já corrigidas geometricamente e recortadas pela máscara de soja;

A operação matemática aplicada, geralmente baseada em razões normalizadas ou diferenças espectrais;

O produto raster de saída, correspondente ao índice espectral calculado apenas sobre as áreas de soja.

Como exemplo ilustrativo, o diagrama do NDVI (Normalized Difference Vegetation Index) evidencia o fluxo lógico do processamento: as bandas do infravermelho próximo (NIR) e do vermelho (RED), após a aplicação da máscara de soja, são combinadas segundo a expressão matemática do índice, resultando em um raster contínuo que expressa o vigor vegetativo da cultura.

Exemplo: cálculo do NDVI com máscara de soja

O NDVI foi calculado a partir da banda B072 (NIR) e da banda B031 (RED), conforme a Equação (1):

$$NDVI = \frac{NIR - RED}{NIR + RED} \quad (32)$$

onde:

NIR corresponde à reflectância da banda B072 (infravermelho próximo);

RED corresponde à reflectância da banda B031 (vermelho).

A aplicação prévia da máscara de soja garante que o valor do índice seja computado apenas para pixels pertencentes às áreas cultivadas, resultando em um produto raster denominado NDVI_SOJA, no qual cada pixel representa exclusivamente a resposta espectral da cultura analisada.

O diagrama associado a esse índice explicita visualmente esse processo, mostrando as bandas de entrada, a operação matemática central e o arquivo de saída final. Essa representação gráfica tem função didática e metodológica, permitindo a rastreabilidade completa do cálculo e facilitando a interpretação do índice no contexto do modelo híbrido proposto.

Extensão do procedimento aos demais índices espectrais

O mesmo procedimento conceitual e computacional foi adotado para os demais índices espectrais utilizados neste estudo (por exemplo, índices relacionados à umidade, estrutura do dossel e atividade fotossintética). Para cada índice:

foram definidas bandas específicas, de acordo com sua fundamentação biofísica;

aplicou-se a máscara de soja às bandas de entrada;

realizou-se o cálculo pixel a pixel;

gerou-se um raster temático exclusivo da área cultivada, preservando metadados espaciais e radiométricos.

A construção de um diagrama visual individual para cada índice permitiu não apenas documentar o fluxo de processamento, mas também reforçar a coerência metodológica entre os índices, assegurando que todos compartilhem a mesma base espacial, espectral e temática.

Relevância metodológica para a modelagem do fluxo de CO₂

Os índices espectrais derivados nesse processo constituem variáveis explicativas fundamentais do modelo híbrido de estimativa do fluxo de CO₂. Ao restringir os cálculos às áreas efetivamente cultivadas com soja, evita-se a contaminação espectral por outros alvos e maximiza-se a correlação entre os índices e os processos biofísicos associados à fotossíntese, transpiração e troca de carbono.

Desenvolvimento do NDVI a partir de bandas hiperespectrais com máscara de soja

Após a aplicação da máscara binária de soja sobre as bandas hiperespectrais do sensor EO-1 Hyperion, o cálculo do NDVI foi realizado pixel a pixel, considerando exclusivamente os

pixels pertencentes às áreas cultivadas com soja.

Cálculo dos índices espectrais de vegetação e umidade a partir dos dados Hyperion

A partir da imagem hiperespectral Hyperion (EO-1), cena de 29 de dezembro de 2015, foram calculados múltiplos índices espectrais com o objetivo de caracterizar o vigor vegetativo, o conteúdo hídrico e possíveis condições de estresse da cultura da soja na área de estudo. O processamento foi realizado exclusivamente sobre os pixels classificados como soja, por meio da aplicação de uma máscara espacial previamente corrigida e alinhada ao raster mestre (banda B045).

Todos os cálculos foram executados pixel a pixel, utilizando as bandas espectrais adequadas conforme a formulação original de cada índice. Para evitar interferências espúrias, foram considerados apenas pixels válidos simultaneamente na máscara de soja e nas bandas espectrais envolvidas em cada equação. Os produtos finais foram salvos em formato GeoTIFF e, adicionalmente, normalizados para a geração de mapas de calor (heatmaps), utilizados exclusivamente para análise visual.

Índices de vigor vegetativo

NDVI - Normalized Difference Vegetation Index

O NDVI foi calculado a partir das bandas do infravermelho próximo (NIR) e do vermelho (Red), segundo a expressão:

$$NDVI = \frac{NIR - Red}{NIR + Red} \quad (33)$$

Os resultados obtidos para a área de soja apresentaram valores variando entre -1,0 e 1,0, com valor médio de 0,1524. A distribuição espacial do NDVI indica predominância de valores positivos moderados, compatíveis com áreas agrícolas em estágio vegetativo ativo, porém com heterogeneidade espacial significativa.

SAVI - Soil Adjusted Vegetation Index

O SAVI foi calculado adotando-se o fator de ajuste do solo $L = 0,5$:

$$SAVI = \frac{(NIR - Red)}{(NIR + Red + L)} \times (1 + L) \quad (34)$$

Para a cultura da soja, os valores de SAVI variaram entre 0,0 e 1,2, com valor médio de 0,2295. Os resultados evidenciam um incremento relativo em relação ao NDVI, refletindo a atenuação do efeito do solo exposto, especialmente em áreas com menor densidade foliar.

MSAVI2 - Modified Soil Adjusted Vegetation Index 2

O MSAVI2 foi calculado conforme a equação:

$$MSAVI2 = \frac{2 \cdot NIR + 1 - \sqrt{(2 \cdot NIR + 1)^2 - 8 \cdot (NIR - Red)}}{2} \quad (35)$$

Os valores obtidos situaram-se entre 0,0 e 1,0, com valor médio de 0,1908. O MSAVI2 apresentou comportamento espacial semelhante ao SAVI, porém com maior suavização das transições abruptas, indicando sua adequação para áreas agrícolas com variação gradual de cobertura vegetal.

GNDVI - Green Normalized Difference Vegetation Index

O GNDVI foi calculado substituindo-se a banda do vermelho pela banda do verde:

$$GNDVI = \frac{NIR - Green}{NIR + Green} \quad (36)$$

Na área de soja, os valores de GNDVI variaram de -1,0 a 1,0, com valor médio de 0,3231, indicando maior sensibilidade à concentração de clorofila foliar. Comparativamente ao NDVI, o GNDVI apresentou médias mais elevadas, sugerindo maior resposta espectral associada ao estado fisiológico da vegetação.

Índices de umidade e conteúdo hídrico

NDMI - Normalized Difference Moisture Index (formulação original)

O NDMI foi calculado utilizando a formulação clássica, com as bandas NIR e SWIR1:

$$NDMI = \frac{NIR - SWIR1}{NIR + SWIR1} \quad (37)$$

Os valores obtidos variaram entre -0,60 e 0,85, com valor médio de 0,5264. Esses resultados indicam predominância de condições de umidade foliar moderada a elevada na área de soja, com variações espaciais associadas possivelmente a diferenças fenológicas e microcondições

hídricas.

NDWI (Gao)

O NDWI proposto por Gao, matematicamente equivalente ao NDMI, foi mantido como índice independente para fins comparativos:

$$NDWI_{Gao} = \frac{NIR - SWIR1}{NIR + SWIR1} \quad (38)$$

Os resultados apresentaram valores mínimos de -1,0, máximos de 1,0 e valor médio de 0,5264, coincidentes com os valores médios do NDMI, reforçando a coerência interna dos cálculos e a consistência espectral dos dados.

LSWI - Land Surface Water Index

O LSWI também foi calculado a partir das bandas NIR e SWIR1:

$$LSWI = \frac{NIR - SWIR1}{NIR + SWIR1} \quad (39)$$

Os valores variaram de -1,0 a 1,0, com valor médio de 0,5264, evidenciando comportamento estatisticamente equivalente ao NDMI e NDWI (Gao), como esperado pela similaridade conceitual e matemática entre os índices.

NDWI (McFeeters)

O NDWI de McFeeters foi calculado utilizando as bandas do verde e do infravermelho próximo:

$$NDWI_{McFeeters} = \frac{Green - NIR}{Green + NIR} \quad (40)$$

Os resultados apresentaram valores entre -0,7590 e 0,4583, com valor médio de -0,3140. Esses valores negativos predominantes são coerentes com áreas vegetadas, confirmando que este índice responde prioritariamente à presença de corpos d'água superficiais, sendo utilizado neste estudo apenas como referência comparativa.

Índice de estresse espectral

NBR - Normalized Burn Ratio

O NBR foi calculado utilizando as bandas NIR e SWIR2:

$$NBR = \frac{NIR - SWIR2}{NIR + SWIR2} \quad (41)$$

Na área de soja, os valores obtidos variaram entre -0,1845 e 0,9988, com valor médio de 0,9220. Valores elevados de NBR indicam ausência de estresse severo ou distúrbios estruturais significativos, sendo coerentes com áreas agrícolas não submetidas a eventos de queima ou degradação extrema no período analisado.

Uso dos resultados na sequência do estudo

Os índices calculados e seus respectivos mapas de calor constituem a base para as análises subsequentes do trabalho, sendo utilizados para:

comparação espacial entre vigor vegetativo e conteúdo hídrico;

identificação de padrões intra-talhão;

suporte à interpretação fisiológica da cultura da soja;

integração futura com variáveis ambientais e modelos de estimativa de fluxo de CO₂.

Os valores estatísticos foram calculados considerando exclusivamente os pixels válidos da área de soja, definidos pela interseção entre a máscara temática corrigida e as áreas com resposta espectral válida nas bandas envolvidas em cada índice. Valores extremos de -1 e 1 refletem a normalização teórica dos índices, enquanto as médias expressam o comportamento espectral predominante da cultura no momento da aquisição da imagem.

Tabela 03 – Estatísticas descritivas dos índices espectrais calculados para a cultura da soja a partir da imagem Hyperion (29/12/2015).

Fonte: elaboração própria, 2025.

Caracterização ambiental da cena

Para a integração espectral e meteorológica, foi selecionada a estação meteorológica oficial mais próxima do footprint da cena EO-1 Hyperion L1T, path/row 224/069, ID EO1H2240692015 363110PF, adquirida em 29/12/2015, utilizada nesta pesquisa para o estado de Mato Grosso. O retângulo de cobertura do produto estende-se aproximadamente entre -12,4366 e -13,3927 de

latitude e -52,2384 e -52,5146 de longitude. Considerando esse footprint, adotou-se a estação convencional do INMET de Canarana–MT (código 83270; -13,4708; -52,2711; 430 m), por representar a fonte observacional mais próxima e com operação contínua, situada a cerca de 8,7 km do limite sul da cena, assegurando coerência espacial para a harmonização das variáveis meteorológicas com os índices espectrais derivados do Hyperion.

3.2.2 Integração espectral e meteorológica

A interpretação de índices espectrais derivados de imagens hiperespectrais pode ser fortemente influenciada pelas condições atmosféricas e ambientais vigentes no momento da aquisição dos dados. Em ambientes agrícolas, especialmente em sistemas tropicais, variáveis meteorológicas como temperatura do ar, umidade relativa, precipitação e vento exercem influência direta sobre a fisiologia da cultura, refletindo-se no comportamento espectral observado. Dessa forma, a análise isolada dos índices pode levar a interpretações ambíguas, caso não seja considerado o contexto ambiental no qual o sinal espectral foi registrado.

Com o objetivo de reduzir essas ambiguidades e ampliar a consistência interpretativa dos resultados, procedeu-se à integração entre os índices espectrais calculados a partir da cena EO-1 Hyperion L1T, ID EO1H2240692015363110PF, adquirida em 29/12/2015, e os dados meteorológicos correspondentes ao mesmo período. Para isso, foram utilizados registros da estação meteorológica convencional do INMET em Canarana–MT (código 83270), selecionada por sua proximidade espacial em relação à área de estudo e por apresentar dados compatíveis temporalmente com a aquisição da imagem.

Inicialmente, os dados meteorológicos brutos da estação convencional do INMET em Canarana–MT (código 83270) foram submetidos a um processo de padronização e filtragem temporal, restringindo-se exclusivamente ao dia da aquisição da cena EO-1 Hyperion L1T, ID EO1H2240692015363110PF, adquirida em 29/12/2015. A partir das colunas originais de data e hora (em UTC), foi construído um carimbo temporal unificado, permitindo a sincronização direta com o instante aproximado de aquisição da imagem (11:49 UTC). O registro meteorológico mais próximo desse horário apresentou uma diferença temporal de aproximadamente 11 minutos, valor considerado adequado para fins de integração em estudos de sensoriamento remoto agrícola.

As variáveis meteorológicas consideradas nesta etapa incluíram temperatura do ar,

umidade relativa, pressão atmosférica, velocidade e direção do vento, nebulosidade, insolação e precipitação diária, provenientes da estação convencional do INMET em Canarana–MT (código 83270). Além das variáveis que compõem o dataframe meteorológico-base descrito na Subseção 2.9, foram geradas estatísticas retroativas (média, soma ou acumulado, conforme a natureza da variável) em janelas móveis de 3 h, 6 h, 24 h e 72 h anteriores à passagem da cena EO-1 Hyperion L1T, ID EO1H2240692015363110PF, adquirida em 29/12/2015.

Paralelamente, os índices espectrais foram calculados exclusivamente sobre as áreas identificadas como cultivo de soja, por meio da aplicação de uma máscara temática previamente validada. Para cada índice, foram extraídas estatísticas descritivas (mínimo, máximo, média, desvio padrão e percentis), assegurando que os valores analisados representassem apenas o comportamento espectral da cultura, minimizando interferências de solo exposto, bordas de talhão ou ruídos espectrais.

A integração entre os índices espectrais e as variáveis meteorológicas resultou na construção de um dataset unificado, no qual cada índice é associado às condições ambientais observadas no momento da aquisição da cena EO-1 Hyperion L1T, ID EO1H2240692015363110PF, adquirida em 29/12/2015. Essa abordagem possibilita uma leitura mais contextualizada do sinal espectral, permitindo discutir os padrões observados não apenas em termos de variabilidade espacial, mas também à luz das condições climáticas registradas pela estação convencional do INMET em Canarana–MT (código 83270), sob as quais a cultura se encontrava.

Dessa forma, a integração espectral e meteorológica adotada neste estudo, construída a partir da cena EO-1 Hyperion L1T, ID EO1H2240692015363110PF, adquirida em 29/12/2015, da máscara binária de soja derivada do MapBiomass Coleção 9 (ano 2015) e dos registros da estação convencional do INMET em Canarana–MT (código 83270), não tem como objetivo estabelecer relações causais diretas, mas sim fornecer um arcabouço interpretativo mais consistente e fisicamente fundamentado. Essa estratégia amplia o potencial analítico dos índices hiperespectrais, fortalece a validade dos resultados apresentados e estabelece uma base metodológica para aplicações futuras envolvendo modelagem ambiental e técnicas de aprendizado de máquina aplicadas ao monitoramento agrícola.

Com o intuito de sintetizar os resultados da integração entre os índices espectrais e as condições meteorológicas vigentes no momento da aquisição da cena hiperespectral, a Tabela 04 apresenta o conjunto de índices calculados para a cultura da soja, juntamente com

estatísticas descritivas extraídas sobre a máscara temática e as variáveis meteorológicas associadas. Essa organização permite uma análise comparativa entre os diferentes índices, considerando simultaneamente a variabilidade espectral intra-área e o contexto ambiental no qual o sinal foi registrado.

Tabela 04 – Integração entre índices espectrais e variáveis meteorológicas para a cultura da soja (29/12/2015).

Fonte: elaboração própria, 2025.

Obs.: As variáveis meteorológicas correspondem ao registro mais próximo do horário de aquisição da cena hiperespectral ($\Delta t \approx 11$ min), enquanto a precipitação refere-se ao acumulado diário informado pela estação meteorológica. As estatísticas espectrais foram calculadas exclusivamente sobre pixels classificados como cultivo de soja.

Os resultados apresentados na Tabela 04 evidenciam a coerência entre os padrões espectrais observados para a cultura da soja e as condições meteorológicas vigentes no momento da aquisição da cena hiperespectral. Observa-se que a imagem foi registrada sob elevada umidade relativa do ar (89%) e precipitação diária moderada (1,2 mm), indicando ausência de estresse hídrico significativo, o que se reflete nos valores e na distribuição espacial dos índices associados ao vigor vegetativo e ao conteúdo hídrico do dossel.

A consistência entre os índices de vegetação e de umidade, aliada às condições atmosféricas registradas, reforça a importância da integração espectral e meteorológica como estratégia para reduzir ambiguidades interpretativas em análises baseadas exclusivamente em índices espectrais. Dessa forma, os resultados obtidos fornecem uma base consistente para a compreensão do comportamento espectral da soja no contexto ambiental específico da área de estudo, além de ampliarem o potencial de aplicação desses dados em estudos futuros de modelagem ambiental e monitoramento agrícola.

3.2.3 Relação dos índices com as variáveis biofísicas

O cálculo dos índices espectrais constitui uma etapa fundamental desta pesquisa, pois fornece variáveis biofísicas diretamente relacionadas à estrutura do dossel, ao conteúdo hídrico da

vegetação e à atividade fotossintética da cultura da soja. Esses índices são amplamente utilizados como proxies de processos ecofisiológicos e desempenham papel central na modelagem do fluxo de dióxido de carbono (CO_2) na interface solo–planta–atmosfera.

Neste trabalho, os índices foram calculados a partir de bandas da cena EO-1 Hyperion L1T, ID EO1H2240692015363110PF, adquirida em 29/12/2015, previamente corrigidas geometricamente, alinhadas em um grid espacial comum e recortadas por meio da aplicação da máscara binária de soja derivada do MapBiomas Coleção 9 (ano 2015). Essa abordagem assegura que os cálculos sejam realizados exclusivamente sobre os pixels representativos da cultura agrícola de interesse, eliminando a influência espectral de solos expostos, corpos d'água, vegetação nativa e áreas antrópicas não relacionadas.

A seleção das bandas espectrais utilizadas em cada índice baseou-se na correspondência direta entre os comprimentos de onda teóricos definidos na literatura e as bandas efetivamente disponíveis no sensor Hyperion. Para isso, foi elaborado um mapeamento sistemático entre cada banda do sensor, seu código identificador e o respectivo comprimento de onda central, permitindo a escolha da banda mais próxima ao valor espectral alvo de cada índice. Esse procedimento garante consistência espectral, rastreabilidade metodológica e reprodutibilidade dos resultados.

Os índices espectrais considerados neste estudo incluem indicadores de vigor vegetativo, umidade do dossel e estresse espectral, amplamente empregados em estudos agrícolas e ambientais, tais como NDVI, EVI, SAVI, MSAVI2, GNDVI, NDMI, NDWI (Gao), LSWI, NBR, PRI e NIRv. Cada índice foi calculado pixel a pixel, utilizando suas formulações matemáticas originais, respeitando as bandas espectrais correspondentes e tratando explicitamente valores inválidos ou ausentes.

Embora o modelo físico ISBA (Interactions between Soil, Biosphere and Atmosphere) não seja implementado diretamente nesta etapa computacional, os índices espectrais calculados fornecem variáveis de entrada conceitualmente compatíveis com os parâmetros utilizados por esse tipo de modelo, como vigor da vegetação, conteúdo hídrico do dossel e resposta ao estresse ambiental. Dessa forma, os índices derivados das imagens hiperespectrais atuam como elementos intermediários essenciais para a construção de um modelo híbrido, no qual informações espectrais e meteorológicas são integradas para subsidiar a estimativa do fluxo de CO_2 em áreas cultivadas com soja.

Todos os produtos gerados foram armazenados em formato raster georreferenciado

(GeoTIFF), acompanhados de registros de log contendo informações sobre bandas utilizadas, parâmetros aplicados e caminhos dos arquivos produzidos. Adicionalmente, os índices foram normalizados para a geração de mapas de calor, utilizados exclusivamente para análise visual e interpretação espacial dos padrões intra-talhão.

Ao final desse processo, estabelece-se um conjunto consistente de índices espectrais derivados, espacialmente coerentes e fisicamente interpretáveis, que constitui a base analítica para as etapas subsequentes de extração de métricas, análise estatística e integração com modelos ecofisiológicos de estimativa do fluxo de CO₂, conforme proposto nesta tese.

3.3 Resultados da Modelagem do Fluxo de CO₂

A decomposição do fluxo líquido de CO₂ em seus componentes fundamentais, produtividade primária bruta (GPP) e respiração do ecossistema (Reco) constitui etapa essencial para a interpretação ecofisiológica dos resultados obtidos. Enquanto a GPP representa a assimilação de carbono associada ao processo fotossintético, a Reco expressa a soma das respirações autotrófica e heterotrófica, fortemente controladas pela temperatura e pelo metabolismo do sistema solo-planta.

No período analisado (1º de outubro a 30 de dezembro de 2015), a estimativa horária da GPP apresentou forte acoplamento com a radiação fotossinteticamente ativa (PAR), evidenciando um padrão diurno bem definido, com valores próximos de zero durante o período noturno e máximos concentrados nas horas centrais do dia. O valor máximo horário de GPP atingiu aproximadamente 1,37 gCO₂ m⁻² h⁻¹, compatível com taxas observadas para culturas anuais em estágios avançados de desenvolvimento vegetativo.

A respiração do ecossistema (Reco), por sua vez, apresentou comportamento contínuo ao longo do ciclo diário, com valores sempre positivos, variando em função da temperatura do ar. O valor mínimo horário de Reco foi da ordem de 0,12 gCO₂ m⁻² h⁻¹, ocorrendo predominantemente durante a madrugada, enquanto valores mais elevados foram registrados nos períodos mais quentes do dia. Esse comportamento é consistente com formulações ecofisiológicas baseadas na relação Q₁₀, amplamente adotadas em modelos de superfície terrestre.

A separação explícita entre GPP e Reco permitiu identificar que a assimilação fotossintética diurna supera a respiração integrada ao longo do dia, enquanto no período noturno a ausência de fotossíntese resulta em emissões líquidas de CO₂ dominadas exclusivamente pela respiração. Essa

dinâmica explica o sinal negativo do NEE durante o dia e positivo durante a noite, confirmando a coerência física do balanço de carbono estimado.

Do ponto de vista quantitativo, a absorção média diurna de CO_2 foi de aproximadamente $-1,44 \text{ gCO}_2 \text{ m}^{-2} \text{ h}^{-1}$, enquanto a emissão média noturna atingiu $+0,56 \text{ gCO}_2 \text{ m}^{-2} \text{ h}^{-1}$. A integração desses fluxos ao longo do período analisado resultou em um saldo líquido negativo, evidenciando que a assimilação associada à GPP superou a respiração do ecossistema, caracterizando o sistema agrícola como sumidouro líquido de carbono no intervalo temporal considerado.

A análise temporal do fluxo de CO_2 evidenciou um padrão diurno bem definido e fisicamente consistente, resultante da alternância entre os processos de assimilação fotossintética e respiração do ecossistema. Em escala horária, o NEE apresentou valores negativos durante o período diurno, associados à atividade fotossintética da cultura da soja, e valores positivos no período noturno, quando a fotossíntese é interrompida e a respiração domina o balanço de carbono.

O ciclo diurno médio, obtido a partir da agregação horária de todo o período analisado, revelou que os valores mínimos de NEE ocorreram nas horas centrais do dia, coincidindo com os maiores níveis de radiação fotossinteticamente ativa (PAR). Nessas condições, a assimilação de CO_2 atingiu taxas médias da ordem de $-1,44 \text{ gCO}_2 \text{ m}^{-2} \text{ h}^{-1}$, refletindo a máxima eficiência fotossintética do dossel sob iluminação plena. Em contraste, durante a noite, o NEE assumiu valores positivos relativamente estáveis, com média aproximada de $+0,56 \text{ gCO}_2 \text{ m}^{-2} \text{ h}^{-1}$, representando a emissão contínua de CO_2 associada à respiração do sistema solo-planta.

A integração temporal desses fluxos permitiu a obtenção de agregações diárias e do saldo acumulado no período de estudo. Em média, o sistema apresentou um saldo diário negativo, caracterizando assimilação líquida de carbono ao longo da maior parte dos dias analisados. A soma dos fluxos horários ao longo de 90 dias efetivos de dados válidos resultou em um NEE acumulado de $-9,85 \text{ tCO}_2 \text{ ha}^{-1}$, valor que confirma a predominância da assimilação fotossintética sobre a respiração integrada no intervalo temporal considerado.

Do ponto de vista ecofisiológico, esse comportamento temporal é coerente com a dinâmica esperada para culturas anuais em pleno desenvolvimento vegetativo, nas quais a intensidade da fotossíntese diurna supera as perdas respiratórias noturnas. A presença de um ciclo diurno bem marcado, sem inversões anômalas de sinal, constitui uma evidência adicional da consistência física do modelo biofísico empregado e da adequação das forçantes meteorológicas utilizadas. A

coerência ecofisiológica dos resultados foi avaliada a partir da consistência interna entre sinal, magnitude e variabilidade temporal dos fluxos estimados de CO_2 . Em todo o período analisado, o comportamento do NEE manteve-se fisicamente interpretável, com assimilação líquida durante o dia ($\text{NEE} < 0$) e emissão líquida durante a noite ($\text{NEE} > 0$), refletindo a alternância esperada entre fotossíntese e respiração do ecossistema.

A magnitude dos fluxos horários mostrou-se compatível com valores reportados para culturas anuais em condições tropicais, com taxas médias diurnas de assimilação da ordem de $-1,44 \text{ gCO}_2 \text{ m}^{-2} \text{ h}^{-1}$ e emissões noturnas médias de $+0,56 \text{ gCO}_2 \text{ m}^{-2} \text{ h}^{-1}$. Esses valores indicam que a assimilação fotossintética diurna superou as perdas respiratórias noturnas, resultando em um saldo acumulado negativo de $-9,85 \text{ tCO}_2 \text{ ha}^{-1}$ no período de 90 dias efetivos de dados válidos, caracterizando o sistema agrícola como sumidouro líquido de carbono no intervalo analisado.

Do ponto de vista ecofisiológico, a resposta da GPP à radiação fotossinteticamente ativa (PAR) apresentou comportamento monotônico e saturante, enquanto a Reco respondeu de forma contínua à temperatura do ar, conforme esperado em formulações baseadas na relação Q10. A ausência de inversões anômalas de sinal, picos artificiais ou descontinuidades temporais reforça a consistência do acoplamento entre forçantes meteorológicas, parâmetros do dossel e processos fisiológicos representados no modelo.

Esses resultados fornecem uma base analítica consistente para as etapas subsequentes de extração de métricas, análise estatística e comparação com métodos e sistemas de referência. A coerência física observada assegura que as estimativas de fluxo de CO_2 não decorrem de ajustes artificiais ou compensações paramétricas, mas emergem da interação consistente entre radiação, estado do dossel e resposta térmica da respiração.

Dessa forma, os resultados apresentados nesta seção constituem o ponto de partida para a comparação com a literatura e com sistemas de referência amplamente utilizados, bem como para a avaliação estatística da consistência do modelo, abordadas nas seções seguintes.

3.4 Comparação com a literatura e métodos de referência

Os resultados obtidos para o fluxo de CO_2 foram comparados com estudos e sistemas de referência amplamente utilizados na literatura científica, com o objetivo de avaliar a coerência da ordem de grandeza, do sinal e do comportamento temporal das estimativas geradas pelo modelo

biofísico adotado nesta tese. Essa comparação não tem por finalidade a equivalência direta entre métodos distintos, mas sim o enquadramento dos resultados dentro de envelopes ecofisiológicos reconhecidos.

No âmbito dos sistemas globais de monitoramento do carbono, produtos operacionais baseados no conceito de eficiência de uso da luz (LUE), como o MOD17, desenvolvido pela NASA, estimam a produtividade primária bruta (GPP) a partir da integração entre radiação fotossinteticamente ativa (PAR), fração de PAR absorvida pelo dossel e parâmetros ecofisiológicos calibrados com medições de covariância de vórtices. Para culturas agrícolas, esses sistemas adotam valores máximos de eficiência de uso da luz compatíveis com medições de campo, estabelecendo limites fisiológicos superiores para a assimilação de carbono.

Estudos baseados em medições diretas de eddy covariance em áreas de cultivo de soja indicam que a eficiência de uso da luz e as taxas de assimilação líquida de CO₂ apresentam variabilidade significativa em função do estágio fenológico, das condições ambientais e do manejo agrícola. Valores típicos de NEE sazonal reportados para culturas anuais situam-se na faixa de algumas toneladas de CO₂ por hectare, com sinal negativo durante períodos de intenso crescimento vegetativo, refletindo o predomínio da fotossíntese sobre a respiração do ecossistema.

Nesse contexto, o valor acumulado de -9,85 tCO₂ ha⁻¹ obtido neste estudo, para o período de 1º de outubro a 30 de dezembro de 2015, posiciona-se no limite superior do intervalo reportado na literatura para culturas agrícolas tropicais sob condições favoráveis de desenvolvimento. A magnitude do resultado é compatível com taxas elevadas de assimilação fotossintética observadas durante fases de máximo índice de área foliar (LAI), desde que consideradas as incertezas inerentes aos parâmetros ecofisiológicos e às forçantes meteorológicas utilizadas.

Como referência regional adicional, medições realizadas em torres de covariância de vórtices na Amazônia Central, como no Amazon Tall Tower Observatory (ATTO), indicam que ecossistemas florestais maduros apresentam, em média, comportamento de fraco sumidouro de carbono em escala anual, com ciclos diurnos marcados por assimilação durante o dia e emissão durante a noite. Embora não sejam diretamente comparáveis a sistemas agrícolas, esses resultados fornecem um benchmark físico para o sinal e a estrutura temporal do NEE, reforçando a plausibilidade do comportamento diurno-noturno observado neste estudo.

Assim, a comparação com a literatura e com métodos de referência confirma que os resultados obtidos não apresentam inconsistências físicas ou ordens de grandeza incompatíveis,

mas refletem um cenário de alta assimilação de carbono associado a uma cultura anual em pleno desenvolvimento vegetativo. Essa análise comparativa fornece o suporte necessário para a avaliação estatística e prática dos resultados, apresentada na seção seguinte.

Os padrões diurnos e sazonais da troca líquida de carbono (NEE) estimados neste estudo, caracterizados por absorção líquida de CO₂ durante o período diurno e emissão noturna associada à respiração do ecossistema, são fisicamente coerentes com observações micrometeorológicas obtidas por sistemas de covariância de vórtices amplamente reportados na literatura. Redes globais de observação, como a FLUXNET, documentam de forma consistente esse comportamento em ecossistemas agrícolas e naturais, evidenciando a dominância da fotossíntese durante o dia e da respiração autotrófica e heterotrófica à noite (BALDOCCHI et al., 2001; BALDOCCHI, 2008; PASTORELLO et al., 2020).

Assim, embora os valores aqui obtidos derivem de um modelo biofísico reduzido e não de medições diretas por torres de fluxo, a concordância nos padrões temporais reforça a plausibilidade ecofisiológica das estimativas de GPP, Reco e NEE empregadas como base para as etapas subsequentes de análise estatística e integração com modelos de inteligência artificial.

3.5 Validação estatística e avaliação prática

A validação dos resultados da modelagem do fluxo de CO₂ foi conduzida com base em três níveis complementares de análise: (i) coerência física interna do modelo, (ii) consistência estatística das séries temporais geradas e (iii) comparação com ordens de grandeza reportadas na literatura científica e em redes de referência internacional, notadamente a FLUXNET.

3.5.1 Validação física do modelo biofísico

Com o objetivo de avaliar a consistência estatística básica das estimativas biofísicas do fluxo de carbono geradas pelo modelo adotado, foram calculadas estatísticas descritivas horárias das variáveis produtividade primária bruta (GPP), respiração do ecossistema (Reco) e troca líquida do ecossistema (NEE). Essa análise constitui uma etapa fundamental de validação interna, permitindo verificar a coerência numérica, a estabilidade estatística e a plausibilidade física das variáveis estimadas ao longo do período de estudo.

As estatísticas foram obtidas a partir da série temporal horária compreendendo o período de outubro a dezembro de 2015, totalizando 2160 observações horárias válidas (90 dias efetivos). Para cada variável, foram determinados os valores mínimo, máximo, média e desvio-padrão, expressos em $\text{gCO}_2 \text{ m}^{-2} \text{ h}^{-1}$. Os resultados dessa análise estatística estão sintetizados na Tabela 05, a qual permite avaliar tanto a amplitude de variação quanto o comportamento médio dos fluxos de carbono estimados.

Conforme apresentado na Tabela 05, a produtividade primária bruta (GPP) apresentou valores nulos durante o período noturno e máximos diurnos compatíveis com condições de elevada disponibilidade de radiação, refletindo a dependência direta da fotossíntese em relação à radiação incidente. A respiração do ecossistema (Reco) manteve valores positivos ao longo de todo o período analisado, evidenciando a respiração contínua do sistema solo-planta. Já a troca líquida do ecossistema (NEE) apresentou valores negativos predominantes durante o período diurno e positivos durante a noite, configurando um comportamento fisicamente coerente com a dinâmica ecofisiológica esperada para sistemas agrícolas.

Tabela 05 – Estatísticas descritivas horárias das variáveis biofísicas do fluxo de CO_2

Variável	Mínimo	Máximo	Média	Desvio-padrão
GPP	0,000	1,368	0,307	0,394
Reco	0,117	0,373	0,182	0,052
NEE	-1,088	0,259	-0,124	0,360

Unidade: $\text{gCO}_2 \text{ m}^{-2} \text{ h}^{-1}$.

Fonte: elaboração própria, 2025.

A modelagem do fluxo de carbono foi baseada em um esquema biofísico reduzido, conceitualmente equivalente ao modelo ISBA, estruturado a partir das seguintes equações fundamentais:

(a) Fração de radiação fotossinteticamente ativa absorvida (fPAR):

$$\text{fPAR} = 1 - e^{-k \cdot \text{LAI}} \quad (42)$$

onde $k = 0,5$ é o coeficiente de extinção do dossel e $\text{LAI} = 4,6$, valor médio representativo da soja em estágio pleno de desenvolvimento vegetativo.

(b) Conversão da radiação de onda curta para PAR:

$$PAR = 0,45 \cdot SW_{down} \quad (43)$$

onde SW_{down} é a radiação solar de onda curta ($W m^{-2}$), previamente validada e corrigida a partir do ERA5-Land.

(c) Produtividade Primária Bruta (GPP):

$$GPP = \varepsilon \cdot fPAR \cdot PAR \quad (44)$$

com eficiência de uso da luz:

$$\varepsilon = 1,5 \text{ gC MJ}^{-1} \quad (45)$$

valor amplamente adotado em estudos agrícolas e compatível com culturas C3, incluindo soja.

(d) Respiração do Ecossistema (Reco):

$$Reco = R_{ref} \cdot Q_{10}^{\left(\frac{T-T_{ref}}{10}\right)} \quad (46)$$


onde $R_{ref} = 0,15 \text{ gC m}^{-2} \text{ h}^{-1}$, $Q_{10} = 2,0$ e $T_{ref} = 25^{\circ}C$.

(e) Troca Líquida do Ecossistema (NEE):

$$NEE = Reco - GPP \quad (47)$$

As equações biofísicas foram calculadas em base de carbono (gC). Para padronização com a literatura de fluxo atmosférico adotada neste trabalho, os resultados apresentados em tabelas e métricas foram convertidos para CO_2 pelo fator estequiométrico 44/12.

Figura 03 – Ciclo diurno médio da troca líquida de CO_2 (NEE) no período de 01/10/2015 a 30/12/2015



Fonte: elaboração própria, 2025.

Valores negativos de NEE indicam sequestro líquido de carbono, enquanto valores positivos representam emissão líquida para a atmosfera.

3.5.2 Resultados numéricos consolidados

Com o objetivo de comprovar numericamente o padrão ecofisiológico observado no ciclo diurno da troca líquida de CO₂, apresentado na Figura 03, foram calculadas estatísticas específicas do NEE para os períodos diurno e noturno. Essa análise permite distinguir de forma quantitativa os intervalos de predominância da assimilação fotossintética e da respiração do ecossistema, constituindo um critério essencial de validação física do modelo.

Os valores médios de NEE para os períodos diurno e noturno, bem como seus respectivos desvios-padrão, são apresentados na Tabela 06. Observa-se que, durante o período diurno, o NEE assume valores médios negativos, da ordem de $-1,44 \text{ gCO}_2 \text{ m}^{-2} \text{ h}^{-1}$, indicando absorção líquida de carbono associada à fotossíntese dominante. Em contraste, no período noturno, o NEE apresenta valores médios positivos, em torno de $+0,56 \text{ gCO}_2 \text{ m}^{-2} \text{ h}^{-1}$, refletindo a emissão

líquida de CO_2 decorrente exclusivamente da respiração do sistema solo-planta.

Esse comportamento, caracterizado pela inversão sistemática do sinal do NEE entre os períodos diurno e noturno, é fisicamente coerente e amplamente documentado em estudos baseados em medições por covariância dos vórtices turbulentos. Assim, os resultados sintetizados na Tabela 06 confirmam que o modelo é capaz de reproduzir adequadamente a dinâmica diária do balanço de carbono, reforçando a consistência ecofisiológica das estimativas geradas.

Tabela 06 – Comparação estatística do NEE nos períodos diurno e noturno


Período	NEE médio	Desvio-padrão	Sinal dominante	Interpretação eco-fisiológica
Diurno	-1,44	1,44	Absorção	Fotossíntese dominante
Noturno	0,56	0,80	Emissão	Respiração do ecossistema

Unidade: $\text{gCO}_2 \text{ m}^{-2} \text{ h}^{-1}$.

Fonte: elaboração própria, 2025.

A execução do item 7 e a consolidação do item 8 resultaram em uma série temporal horária de 2160 registros válidos (90 dias efetivos), cobrindo o período de 01/10/2015 a 30/12/2015. Os resultados médios horários indicaram $NEE_{dia} = -1,44 \text{ gCO}_2 \text{ m}^{-2} \text{ h}^{-1}$ no período diurno e $NEE_{noite} = +0,56 \text{ gCO}_2 \text{ m}^{-2} \text{ h}^{-1}$ no período noturno, refletindo o comportamento ecofisiológico esperado, com assimilação fotossintética dominante durante o dia e respiração líquida durante a noite. A integração temporal do NEE resultou em $NEE_{total} = -9,85 \text{ tCO}_2 \text{ ha}^{-1}$.

Figura 04 – Série temporal diária do NEE estimado ($\text{tCO}_2 \text{ ha}^{-1} \text{ dia}^{-1}$) no período de 01/10/2015 a 30/12/2015



Fonte: elaboração própria, 2025.

No período analisado, a área cultivada com soja atuou como sumidouro líquido de carbono.

3.5.3 Avaliação estatística e controle de qualidade

Com o objetivo de avaliar o comportamento integrado do fluxo de CO_2 ao longo do período analisado, foram calculadas estatísticas do balanço diário do NEE, bem como o saldo acumulado de carbono. Essa análise permite verificar não apenas o sinal médio do fluxo, mas também sua variabilidade diária e o efeito cumulativo dos processos de assimilação e respiração ao longo do ciclo observado.

Os principais indicadores do balanço diário e do saldo acumulado de CO_2 estão apresentados na Tabela 07, a qual sintetiza os valores mínimo, máximo e médio do NEE diário, além do balanço total integrado no período de outubro a dezembro de 2015. Os resultados evidenciam que, embora ocorram dias com emissão líquida de CO_2 , predominam valores diários negativos de NEE, associados à assimilação líquida de carbono pela cultura da soja.

O valor médio diário do NEE, da ordem de $-0,11 \text{ tCO}_2 \text{ ha}^{-1} \text{ dia}^{-1}$, indica um predomínio

consistente de absorção de carbono ao longo do período analisado. Esse comportamento resulta em um saldo acumulado de $-9,85 \text{ tCO}_2 \text{ ha}^{-1}$, caracterizando o sistema agrícola como sumidouro líquido de carbono no intervalo temporal considerado. A magnitude desse saldo é compatível com ordens de grandeza reportadas na literatura para culturas anuais do tipo C3 sob condições tropicais, considerando variações de manejo, clima e estágio fenológico.

Dessa forma, os resultados consolidados na Tabela 07 confirmam que a integração temporal do NEE produz estimativas fisicamente coerentes e estatisticamente consistentes, reforçando a consistência do modelo biofísico adotado e sua adequação para análises comparativas e aplicações em estudos de balanço de carbono.


Tabela 07 – Estatísticas do balanço diário e do saldo acumulado de CO_2

Métrica	Valor
NEE mínimo diário ($\text{tCO}_2 \text{ ha}^{-1} \text{ dia}^{-1}$)	-0,195
NEE máximo diário ($\text{tCO}_2 \text{ ha}^{-1} \text{ dia}^{-1}$)	0,053
NEE médio diário ($\text{tCO}_2 \text{ ha}^{-1} \text{ dia}^{-1}$)	-0,109
NEE acumulado no período ($\text{tCO}_2 \text{ ha}^{-1}$)	-9,85

Fonte: elaboração própria, 2025.

Foram aplicados critérios explícitos de controle de qualidade, registrados em log automático, contemplando continuidade temporal horária, ausência de valores NaN após a integração dos dados, coerência física das variáveis (radiação, temperatura, GPP, Reco e NEE) e relação consistente entre ciclos diurnos e noturnos. Os testes de coerência confirmaram GPP máximo de $1,37 \text{ gCO}_2 \text{ m}^{-2} \text{ h}^{-1}$, Reco mínimo de $0,12 \text{ gCO}_2 \text{ m}^{-2} \text{ h}^{-1}$ e sinal médio de NEE negativo, resultado compatível com a fase fenológica da cultura.

Figura 05 – Acúmulo progressivo do NEE ($\text{tCO}_2 \text{ ha}^{-1}$) no período de 01/10/2015 a 30/12/2015



Fonte: elaboração própria, 2025.

O conjunto de análises apresentado neste capítulo permitiu a caracterização detalhada do fluxo de CO₂ associado à cultura da soja, a partir da integração entre dados hiperespectrais, variáveis meteorológicas e um modelo biofísico conceitualmente consistente com esquemas do tipo solo–planta–atmosfera. As etapas de cálculo, validação estatística e avaliação gráfica demonstraram que as estimativas de produtividade primária bruta (GPP), respiração do ecossistema (Reco) e troca líquida do ecossistema (NEE) apresentam coerência física, estabilidade temporal e comportamento ecofisiológico compatível com o funcionamento esperado de sistemas agrícolas tropicais.

A validação estatística evidenciou amplitudes, médias e variabilidades compatíveis com ordens de grandeza reportadas na literatura, enquanto a análise gráfica confirmou padrões diurnos e noturnos fisicamente interpretáveis, com assimilação líquida de carbono durante o período diurno e emissão associada à respiração durante a noite. A integração temporal dos fluxos indicou um saldo líquido negativo de CO₂ no período analisado, caracterizando a área de estudo como sumidouro de carbono no intervalo considerado.

3.6 Validação estatística do modelo híbrido

A validação do modelo híbrido foi realizada por meio de comparação direta entre o modelo biofísico determinístico simplificado (fis0) e o modelo híbrido biofísico–estatístico (fis0 + XGBoost), tomando como referência o fluxo de CO₂ estimado pelo modelo biofísico refinado. A avaliação foi conduzida sobre o conjunto de validação temporal independente, correspondente ao período de 1º a 30 de dezembro de 2015.

Os resultados evidenciam que o modelo físico simplificado apresentou desempenho estatístico limitado, com erro quadrático médio (RMSE) de 1,30 gCO₂ m⁻² h⁻¹, erro absoluto médio (MAE) de 1,11 gCO₂ m⁻² h⁻¹ e coeficiente de determinação $R^2 = -0,04$, indicando incapacidade de representar adequadamente a variabilidade temporal do fluxo de CO₂ quando parametrizado apenas com valores fixos da literatura.

Em contraste, o modelo híbrido apresentou desempenho substancialmente superior, com RMSE = 0,013 gCO₂ m⁻² h⁻¹, MAE = 0,008 gCO₂ m⁻² h⁻¹ e $R^2 = 0,9999$, demonstrando elevada capacidade de reprodução do fluxo de CO₂ horário observado. Esses resultados confirmam que a incorporação do modelo de aprendizado de máquina como corretor residual reduz drasticamente os erros sistemáticos do modelo físico simplificado, preservando a coerência biofísica do balanço de carbono.

3.7 Ganho do modelo híbrido em relação ao modelo biofísico simplificado

A comparação quantitativa entre os modelos evidencia um ganho expressivo decorrente da abordagem híbrida. O uso do aprendizado de máquina não substitui o modelo biofísico, mas atua como um mecanismo de correção residual, aprendendo padrões sistemáticos não capturados pela parametrização fixa do modelo físico.

O modelo híbrido reduziu o RMSE em aproximadamente 99

Dessa forma, a modelagem híbrida mostrou-se adequada para aplicações em que a parametrização física detalhada não esteja disponível, oferecendo uma alternativa metodologicamente consistente para aprimorar estimativas de fluxo de carbono sem comprometer a interpretabilidade física do modelo.

3.8 Síntese dos resultados da modelagem híbrida

Este capítulo avaliou a aplicação de uma abordagem de modelagem híbrida biofísica–estatística para a estimativa do fluxo de CO₂ em área agrícola de soja, combinando um modelo biofísico determinístico simplificado (fis0) com um modelo de aprendizado de máquina do tipo XGBoost, empregado como corretor residual.

O modelo biofísico simplificado, parametrizado com valores fixos da literatura, apresentou desempenho estatístico insatisfatório no conjunto de validação temporal referente a dezembro de 2015, com RMSE = 1,30 gCO₂ m⁻² h⁻¹, MAE = 1,11 gCO₂ m⁻² h⁻¹ e R² = -0,04, evidenciando baixa capacidade de reproduzir, de forma isolada, a variabilidade temporal do fluxo de CO₂.

A incorporação do modelo de aprendizado de máquina como corretor residual resultou em melhoria substancial do desempenho preditivo. O modelo híbrido (fis0 + XGBoost) alcançou RMSE = 0,013 gCO₂ m⁻² h⁻¹, MAE = 0,008 gCO₂ m⁻² h⁻¹ e R² = 0,9999 no mesmo período de validação. Esses resultados representam redução superior a 99

Os resultados demonstram que o aprendizado de máquina foi capaz de capturar padrões residuais não representados pela parametrização fixa do modelo biofísico, corrigindo erros sistemáticos sem alterar a estrutura física subjacente. Desse modo, o modelo híbrido preserva a interpretabilidade e a coerência biofísica do balanço de carbono, ao mesmo tempo em que apresenta desempenho estatístico significativamente superior.

A análise do erro residual do modelo híbrido em relação ao modelo biofísico de referência indicou erro médio próximo de zero (0,00032 gCO₂ m⁻² h⁻¹), confirmando a ausência de viés sistemático. A variabilidade residual apresentou desvio-padrão de 0,013 gCO₂ m⁻² h⁻¹, evidenciando que o modelo híbrido opera próximo ao limite de precisão do sistema, não sendo esperado erro nulo exato em razão da variabilidade natural do fenômeno e do ruído associado aos dados de entrada.

Dessa forma, este capítulo confirma que a modelagem híbrida constitui uma estratégia consistente e eficiente para a estimativa de fluxos de CO₂ em ecossistemas agrícolas tropicais, especialmente em contextos nos quais a calibração detalhada de parâmetros biofísicos não está disponível, estabelecendo uma base quantitativa consistente para as conclusões gerais da tese.

4 DISCUSSÃO CIENTÍFICA

4.1 Potencial do HSI para monitoramento agrícola

Os resultados obtidos nesta tese evidenciam que o sensoriamento remoto hiperespectral apresenta potencial expressivo para o monitoramento agrícola em sistemas tropicais, especialmente quando associado à modelagem biofísica e a técnicas de inteligência artificial. A utilização da cena EO-1 Hyperion permitiu explorar a resposta espectral da soja em múltiplas bandas estreitas, ampliando a capacidade de distinguir variações associadas ao vigor vegetativo, ao conteúdo hídrico, à estrutura do dossel e à atividade fotossintética. Essa característica diferencia o HSI de abordagens multiespectrais convencionais, cuja menor resolução espectral pode limitar a identificação de respostas fisiológicas sutis da vegetação.

No contexto da cultura da soja, a informação hiperespectral torna-se particularmente relevante porque o fluxo de CO₂ não depende apenas da presença ou ausência de vegetação, mas da intensidade dos processos ecofisiológicos que regulam a assimilação e a respiração. Índices como NDVI, GNDVI, NDWI, NDMI, PRI, SAVI e NBR, quando calculados a partir de bandas estreitas, permitem representar dimensões distintas do funcionamento do dossel. Essa diversidade de atributos espectrais contribui para aproximar a resposta orbital da dinâmica biofísica do cultivo, sobretudo quando as variáveis são integradas a dados meteorológicos e a estimativas derivadas de modelos físicos.

A análise dos índices espectrais apresentada no Capítulo 3 demonstrou que as áreas classificadas como soja apresentaram resposta espectral compatível com vegetação ativa no período analisado. Esse resultado é coerente com a janela fenológica da cultura e reforça a pertinência do uso de dados hiperespectrais para caracterizar o estado fisiológico do dossel. Contudo, a interpretação desses índices deve considerar que eles atuam como indicadores indiretos, e não como medições diretas dos fluxos de carbono. Assim, sua contribuição principal está em fornecer atributos espacialmente explícitos que auxiliam a modelagem da variabilidade biofísica da lavoura.

A aplicação do HSI em regiões amazônicas apresenta relevância adicional em razão da heterogeneidade ambiental, da extensão territorial e das limitações logísticas para coleta de dados

em campo. Em áreas agrícolas inseridas na Amazônia Legal, a variação de solos, microclimas, regime hídrico, cobertura atmosférica e práticas de manejo dificulta o uso exclusivo de métodos pontuais. O sensoriamento remoto hiperespectral oferece uma alternativa metodológica para ampliar a observação espacial do sistema agrícola, permitindo que informações espectrais do dossel sejam incorporadas ao processo de modelagem ambiental.

Apesar desse potencial, o uso de dados EO-1 Hyperion exige cautela na interpretação. A missão Hyperion representou um marco na observação hiperespectral orbital, mas apresenta limitações relacionadas à disponibilidade temporal, à presença de ruídos em determinadas bandas, à necessidade de seleção criteriosa de comprimentos de onda e à baixa frequência de revisita. No caso desta tese, essas limitações foram enfrentadas por meio de seleção da cena, mascaramento das áreas de soja, exclusão de bandas inadequadas, cálculo controlado de índices espectrais e integração com dados meteorológicos e biofísicos. Esses procedimentos não eliminam todas as incertezas, mas tornam a utilização do dado hiperespectral metodologicamente justificável dentro do escopo adotado.

Outro aspecto relevante é que o HSI, isoladamente, não permite inferir diretamente a NEE, a GPP ou a Reco. A resposta espectral expressa propriedades ópticas da vegetação e da superfície, enquanto os fluxos de carbono dependem também de condições meteorológicas, disponibilidade hídrica, temperatura, radiação e processos respiratórios. Por essa razão, a contribuição do HSI nesta tese deve ser compreendida dentro de uma arquitetura integrada. O dado hiperespectral fornece atributos biofísicos e espectrais; o modelo SVAT/ISBA reduzido fornece coerência processual; e o XGBoost atua na identificação de padrões residuais não plenamente representados pela formulação física.

Essa integração amplia a utilidade científica do HSI, pois evita que os índices espectrais sejam tratados apenas como descritores isolados da vegetação. Ao incorporá-los em uma modelagem híbrida, os índices passam a compor um sistema analítico orientado à estimativa de fluxos de carbono. Essa abordagem é coerente com a literatura que destaca a relevância de variáveis espectrais para estimativas de biomassa, produtividade, estado hídrico, atividade fotossintética e parâmetros biofísicos da vegetação (THENKABAIL et al., 2012; HUETE et al., 2002; GITELSON et al., 2003; CHEN et al., 2019).

Do ponto de vista científico, a principal contribuição do HSI nesta tese está na possibilidade de aproximar a observação orbital da fisiologia vegetal. A elevada resolução espectral

permite explorar regiões do espectro relacionadas à absorção por pigmentos, à reflectância no infravermelho próximo e à sensibilidade ao teor de água no infravermelho de ondas curtas. Esses atributos são particularmente importantes em cultivos agrícolas, pois variações fisiológicas antecedem, em muitos casos, as alterações visuais ou mudanças estruturais mais evidentes no dossel. Assim, o uso do HSI contribui para uma modelagem ambiental mais sensível às variações internas do sistema agrícola.

Entretanto, o potencial do HSI deve ser interpretado em conjunto com suas limitações operacionais. Em ambientes tropicais, a cobertura de nuvens, os aerossóis atmosféricos e a disponibilidade irregular de cenas utilizáveis dificultam a construção de séries temporais densas. Além disso, sensores hiperespectrais orbitais podem apresentar desafios de calibração, correção atmosférica e tratamento de ruído. Esses fatores reforçam a necessidade de protocolos computacionais rastreáveis, capazes de documentar cada etapa de seleção, pré-processamento, cálculo de índices e integração com variáveis auxiliares.

Assim, os resultados desta tese indicam que o sensoriamento remoto hiperespectral é uma fonte estratégica de informação para a modelagem de fluxos de CO₂ em sistemas agrícolas tropicais, desde que utilizado de forma integrada e criticamente interpretada. Seu valor não está apenas na geração de índices espectrais, mas na capacidade de fornecer atributos espacialmente explícitos que enriquecem a modelagem biofísica e computacional. No caso da soja na Amazônia Legal, essa integração representa uma via metodológica promissora para estudos de carbono agrícola, monitoramento ambiental e desenvolvimento de sistemas de apoio à gestão territorial.

4.2 Limitações dos modelos físicos clássicos

Os modelos físicos clássicos de superfície terrestre, incluindo formulações do tipo SVAT e esquemas inspirados no ISBA, constituem uma base conceitual indispensável para representar os processos de troca de energia, água e carbono entre o solo, a vegetação e a atmosfera. Sua importância decorre da capacidade de organizar o fenômeno ambiental em termos mecanicistas, permitindo explicitar relações entre radiação, temperatura, umidade do solo, resistência estomática, fotossíntese, respiração e fluxo líquido de CO₂. No entanto, a aplicação desses modelos em sistemas agrícolas tropicais apresenta limitações relevantes, especialmente quando se busca estimar fluxos de carbono em áreas extensas com disponibilidade restrita de

dados locais.

Uma primeira limitação está relacionada ao elevado grau de parametrização exigido por modelos físico-determinísticos. A representação detalhada dos processos ecofisiológicos depende de parâmetros associados ao solo, à vegetação, ao dossel, às condições atmosféricas e ao manejo agrícola. Em muitos casos, tais parâmetros não estão disponíveis para a área específica de estudo, exigindo a adoção de valores de literatura, aproximações regionais ou simplificações operacionais. Essa condição introduz incertezas na estimativa dos fluxos, principalmente quando o modelo é aplicado fora do contexto experimental em que os parâmetros foram originalmente definidos.

No caso da soja na Amazônia Legal, esse desafio torna-se ainda mais evidente. A região apresenta elevada heterogeneidade ambiental, combinando variações de solo, regime hídrico, temperatura, radiação, práticas agrícolas e histórico de uso da terra. Modelos físicos calibrados em regiões temperadas ou em parcelas experimentais podem não representar adequadamente as condições tropicais, especialmente quando não há medições locais de fluxo de CO₂, umidade do solo, parâmetros fisiológicos e características do dossel. Assim, a transposição direta de parametrizações pode produzir estimativas coerentes em termos gerais, mas limitadas quanto à representação específica do ambiente analisado.

Outra limitação dos modelos físicos clássicos refere-se à dificuldade de incorporar a variabilidade espacial observada por sensores orbitais. Esquemas SVAT/ISBA foram originalmente concebidos para representar processos em células ou unidades de superfície com parâmetros agregados. Quando aplicados a imagens hiperespectrais, torna-se necessário compatibilizar escalas entre o modelo físico, os pixels orbitais, os dados meteorológicos e as classes de uso e cobertura da terra. Essa compatibilização envolve decisões metodológicas que podem afetar os resultados, como o uso de médias, máscaras temáticas, alinhamento temporal e simplificações espaciais.

Além disso, os modelos físicos tendem a representar explicitamente apenas os processos previamente formulados em suas equações. Interações locais, efeitos de manejo, variações não observadas de solo, estresse hídrico intra-pixel, variações fenológicas finas e respostas espectrais específicas podem não estar completamente incorporadas. Isso não significa que os modelos físicos sejam inadequados, mas que sua capacidade explicativa depende da qualidade das parametrizações, da disponibilidade de dados de entrada e do nível de detalhe da formulação

utilizada.

A modelagem biofísica reduzida adotada nesta tese reconhece esses limites. A opção por uma formulação simplificada inspirada em SVAT/ISBA foi necessária para compatibilizar a disponibilidade de dados secundários, a escala orbital da cena Hyperion e os objetivos computacionais da pesquisa. Essa escolha permitiu representar os principais controles da NEE, da GPP e da Reco, mas não teve a pretensão de reproduzir integralmente a complexidade de modelos de superfície terrestre completos, como implementações operacionais em plataformas especializadas. A redução metodológica, portanto, deve ser entendida como estratégia de viabilização científica, e não como substituição integral de modelos físicos completos.

Os resultados do Capítulo 3 reforçam essa interpretação. O modelo biofísico simplificado apresentou desempenho inferior ao modelo híbrido, indicando que a formulação física inicial, embora necessária para estruturar a coerência ecofisiológica, não foi suficiente para capturar toda a variabilidade representada na referência adotada. Esse comportamento é compatível com a literatura de modelagem ambiental, na qual modelos físicos reduzidos frequentemente apresentam desvios quando aplicados a contextos com elevada heterogeneidade, dados incompletos ou parametrização limitada.

A contribuição da inteligência artificial surge exatamente nesse ponto. Ao modelar o resíduo do componente físico, o XGBoost não elimina a necessidade do modelo biofísico, mas atua sobre a parcela de erro associada às simplificações, às interações não explicitamente representadas e aos efeitos capturados pelas variáveis espectrais e meteorológicas. Essa estratégia desloca o papel do aprendizado de máquina de uma substituição pura do modelo físico para uma função complementar, mais coerente com a natureza híbrida da tese.

É importante destacar que a limitação dos modelos físicos clássicos não deve ser interpretada como fragilidade conceitual desses modelos. Ao contrário, eles fornecem a estrutura interpretativa que permite compreender os fluxos de carbono em termos ecofisiológicos. Sua restrição principal está na aplicação operacional em condições de dados incompletos, grande variabilidade espacial e ausência de medições locais. Nessas condições, a integração com dados orbitais e aprendizado supervisionado oferece uma alternativa para reduzir desvios e ampliar a capacidade analítica do sistema modelado.

No âmbito desta tese, a comparação entre o modelo físico simplificado e o modelo híbrido evidencia que a modelagem puramente determinística, quando baseada em parametrizações

reduzidas, pode ser insuficiente para representar a dinâmica do fluxo de CO₂ em lavouras tropicais. Ao mesmo tempo, a utilização isolada de inteligência artificial também não seria desejável, pois poderia produzir estimativas estatisticamente ajustadas, mas desvinculadas da interpretação física. A solução metodológica adotada situa-se entre esses dois extremos, combinando base processual e correção residual orientada por dados.

Dessa forma, a discussão das limitações dos modelos físicos clássicos sustenta a escolha central desta tese: desenvolver uma modelagem híbrida na qual o componente físico fornece a base ecofisiológica e o componente de inteligência artificial corrige padrões residuais. Essa escolha permite preservar a coerência ambiental da estimativa e, simultaneamente, incorporar a capacidade dos dados hiperespectrais e meteorológicos de representar variações não plenamente descritas pelas equações físicas. A seção seguinte aprofunda essa integração ao discutir a relação entre ISBA e inteligência artificial na estrutura metodológica proposta.

4.3 Discussão integrada: ISBA x IA

A integração entre modelos biofísicos inspirados em esquemas SVAT/ISBA e técnicas de inteligência artificial constitui o eixo interpretativo central desta tese. Os resultados apresentados no Capítulo 3 indicam que o modelo físico simplificado forneceu uma estrutura inicial coerente para representar a dinâmica da NEE, da GPP e da Reco, mas também evidenciaram limitações quando essa formulação foi aplicada isoladamente. A incorporação do XGBoost como componente de correção residual permitiu ajustar parte dos desvios associados às simplificações paramétricas, à heterogeneidade ambiental e às interações não explicitamente representadas pelo componente físico.

Essa diferença entre o desempenho do modelo biofísico simplificado e o modelo híbrido não deve ser interpretada como substituição da modelagem física pela inteligência artificial. Ao contrário, os resultados sugerem que a modelagem baseada em processos continua sendo necessária para fornecer uma base ecofisiológica à estimativa do fluxo de CO₂. O papel da IA, nesse arranjo, é atuar sobre o resíduo, identificando padrões que emergem da interação entre variáveis espectrais, meteorológicas e biofísicas. Assim, a inteligência artificial não opera como elemento isolado, mas como componente complementar dentro de uma arquitetura físico-dados.

A formulação ISBA/SVAT reduzida utilizada nesta tese contribui para organizar os

processos fundamentais que controlam as trocas de carbono entre a superfície agrícola e a atmosfera. Balanço de energia, disponibilidade hídrica, resistência estomática, assimilação fotossintética e respiração do ecossistema são dimensões que permitem interpretar a NEE como resultado de processos ecofisiológicos interdependentes. Essa estrutura é essencial porque impede que a estimativa do fluxo de CO_2 seja tratada apenas como uma relação estatística entre variáveis de entrada e saída.

Por outro lado, a aplicação de modelos físicos em contextos tropicais enfrenta restrições decorrentes da disponibilidade limitada de dados locais, da variabilidade espacial do ambiente agrícola e da necessidade de parametrizações específicas. Nesses casos, a IA pode contribuir ao representar padrões empíricos presentes nos dados, especialmente quando a formulação física não consegue capturar completamente interações locais, efeitos de escala, respostas espectrais da vegetação ou variações meteorológicas de curto prazo. A modelagem híbrida proposta nesta tese surge exatamente dessa tensão entre explicação processual e ajuste orientado por dados.

O ganho obtido pelo modelo híbrido em relação ao modelo biofísico simplificado indica que parte relevante do erro residual possuía estrutura informativa. Se o resíduo fosse puramente aleatório, a capacidade do XGBoost de reduzir o erro seria limitada. O desempenho observado sugere que os atributos espectrais e meteorológicos incorporados ao modelo carregam informação associada às variações do fluxo de CO_2 que não foram plenamente representadas pela formulação física inicial. Esse ponto reforça a importância de integrar sensores orbitais, dados climáticos e aprendizado supervisionado em um mesmo pipeline analítico.

Entretanto, a interpretação desse ganho exige cautela. Como a referência utilizada na validação decorre de modelagem biofísica refinada e não de medição direta por torre de covariância dos vórtices turbulentos, o desempenho estatístico do modelo híbrido deve ser entendido como avaliação interna no escopo metodológico adotado. Valores muito elevados de R^2 e erros reduzidos indicam forte ajuste ao padrão da referência empregada, mas não equivalem a uma verificação observacional direta dos fluxos reais observados em campo. Essa distinção é fundamental para evitar extrapolações indevidas.

Do ponto de vista epistemológico, a integração ISBA-IA representa uma mudança importante na forma de abordar sistemas ambientais complexos. Modelos físicos buscam representar mecanismos causais, enquanto modelos orientados por dados identificam regularidades estatísticas. A combinação entre ambos permite construir uma estimativa que não depende

exclusivamente de parametrizações físicas nem se apoia apenas em aprendizado empírico. A contribuição científica da tese está justamente em articular essas duas lógicas em um fluxo reprodutível, rastreável e aplicado a um problema relevante da agricultura tropical.

Essa integração também contribui para reduzir a dicotomia frequentemente estabelecida entre modelos interpretáveis e modelos preditivos. O componente ISBA/SVAT oferece estrutura interpretativa, enquanto o XGBoost amplia a capacidade de ajuste residual. A estimativa final, portanto, resulta de uma composição na qual a coerência ecofisiológica é preservada e os padrões empíricos são incorporados de forma controlada. Esse desenho metodológico é particularmente adequado para contextos nos quais a coleta de dados de campo é limitada, mas há disponibilidade de dados orbitais, meteorológicos e temáticos.

A discussão integrada também evidencia a importância da rastreabilidade computacional. Em modelos híbridos, cada etapa do pipeline influencia a estimativa final: seleção da cena hiperespectral, delimitação das áreas de soja, cálculo dos índices espectrais, construção do dataframe, parametrização biofísica, treinamento do modelo e validação temporal. A documentação dessas etapas é indispensável para que o resultado possa ser interpretado, auditado e eventualmente reproduzido em outras áreas agrícolas. Nesse sentido, a contribuição da tese não se limita ao valor numérico das métricas, mas envolve a construção de um procedimento metodológico verificável.

Outro aspecto relevante é a relação entre escala espacial e interpretação do fluxo de carbono. O ISBA e modelos SVAT operam a partir de unidades de superfície parametrizadas, enquanto o sensoriamento remoto hiperespectral permite observar variações intra-área associadas à resposta espectral do dossel. A IA atua como ponte entre essas escalas, explorando a informação espacial e espectral para ajustar desvios do modelo físico. Essa articulação é especialmente importante em lavouras tropicais, nas quais variações de manejo, solo e microclima podem influenciar a dinâmica de carbono em escalas menores do que aquelas normalmente representadas por modelos físicos agregados.

Dessa forma, a comparação entre ISBA e IA não deve ser formulada como oposição entre duas abordagens, mas como integração entre camadas analíticas complementares. A modelagem física fornece a estrutura de interpretação; a inteligência artificial ajusta padrões residuais; e o sensoriamento remoto oferece variáveis espacialmente explícitas associadas à condição do dossel. A tese demonstra que essa combinação é metodologicamente pertinente para estimar fluxos de CO₂ em áreas agrícolas de soja na Amazônia Legal, desde que seus resultados sejam

interpretados dentro dos limites da validação indireta adotada.

4.4 Implicações para monitoramento de carbono na Amazônia

As implicações dos resultados desta tese para o monitoramento de carbono na Amazônia Legal devem ser compreendidas em três dimensões principais: científica, metodológica e aplicada. No plano científico, o estudo contribui para a compreensão de como áreas agrícolas tropicais podem ser analisadas a partir da integração entre sensoriamento remoto hiperespectral, modelagem biofísica e inteligência artificial. Essa integração é relevante porque a Amazônia Legal não pode ser interpretada apenas como espaço florestal; trata-se também de uma região marcada por expansão agrícola, mudanças no uso da terra e crescente demanda por instrumentos de monitoramento ambiental.

A cultura da soja ocupa posição estratégica nesse debate por representar uma das principais formas de reorganização do território agrícola na Amazônia Legal, especialmente em Mato Grosso. A estimativa do fluxo de CO₂ em áreas cultivadas fornece subsídios para compreender como sistemas agrícolas participam do balanço regional de carbono, seja pela assimilação durante o ciclo vegetativo, seja pela emissão associada à respiração do ecossistema e às condições ambientais. Ainda que os resultados desta tese sejam estimativas modeladas, eles apontam caminhos para incorporar áreas agrícolas aos sistemas de monitoramento climático e territorial.

Do ponto de vista metodológico, a tese demonstra que o monitoramento de carbono em áreas agrícolas tropicais pode ser estruturado mesmo em contextos nos quais não há medições diretas de campo disponíveis. A integração entre dados orbitais, bases meteorológicas, produtos temáticos e modelos computacionais permite construir uma representação inicial da dinâmica do carbono, desde que as limitações empíricas sejam explicitadas. Essa abordagem é particularmente relevante para a Amazônia Legal, onde a extensão territorial, a logística de campo e a baixa densidade de torres de fluxo dificultam o monitoramento observacional contínuo.

A possibilidade de utilizar dados hiperespectrais para caracterizar a condição fisiológica da vegetação amplia a capacidade de análise sobre a agricultura regional. Diferentemente de inventários agregados, baseados em estatísticas anuais ou fatores médios de emissão, o uso de dados orbitais permite associar o fluxo de CO₂ a padrões espaciais e temporais da lavoura. Essa característica pode contribuir para sistemas de monitoramento mais sensíveis à variabilidade

intra-regional, às diferenças fenológicas e aos efeitos de condições meteorológicas específicas sobre o funcionamento do dossel.

No campo das políticas públicas, a metodologia discutida nesta tese pode oferecer suporte a estratégias de monitoramento, relato e verificação ambiental, especialmente em iniciativas relacionadas à agricultura de baixo carbono, zoneamento ecológico-econômico, planejamento territorial e mitigação das mudanças climáticas. A construção de indicadores modelados de fluxo de CO₂ pode auxiliar gestores e pesquisadores na identificação de áreas prioritárias para monitoramento, na avaliação de práticas agrícolas e na integração entre produção agropecuária e metas ambientais.

Entretanto, a aplicação operacional desse tipo de metodologia requer prudência. Estimativas modeladas não substituem medições de campo, inventários oficiais ou protocolos consolidados de monitoramento climático. Seu papel mais adequado, no estágio atual, é complementar sistemas existentes, oferecendo uma camada analítica adicional baseada em dados espaciais, modelagem biofísica e aprendizado de máquina. Essa distinção é importante para evitar interpretações excessivas dos resultados e para posicionar a tese como contribuição metodológica, e não como sistema operacional final de quantificação de carbono.

A Amazônia Legal apresenta condições específicas que reforçam a necessidade de abordagens integradas. A elevada cobertura de nuvens, a heterogeneidade ambiental, a fragmentação dos usos da terra e a dinâmica de expansão agrícola dificultam a aplicação de métodos únicos de monitoramento. Nesse contexto, modelos híbridos podem atuar como instrumentos de síntese, combinando diferentes fontes de informação e permitindo análises exploratórias em áreas onde medições diretas são escassas. Essa capacidade de integração é uma das principais contribuições práticas da abordagem proposta.

A utilização de sensores hiperespectrais também dialoga com a perspectiva de novas missões orbitais dedicadas à observação espectral detalhada da superfície terrestre. Embora o EO-1 Hyperion tenha limitações temporais e operacionais, sua utilização nesta tese demonstra a viabilidade metodológica de explorar dados hiperespectrais para estudos agrícolas e ambientais na Amazônia Legal. Com a expansão de missões hiperespectrais contemporâneas, a abordagem aqui desenvolvida poderá ser adaptada a bases com maior disponibilidade temporal, melhor calibração instrumental e maior potencial de aplicação regional.

Outro desdobramento relevante diz respeito à agricultura de precisão e à gestão produtiva.

A modelagem de fluxos de CO₂ pode ser articulada a indicadores de vigor vegetativo, estado hídrico, produtividade e eficiência do uso da radiação, oferecendo uma visão integrada do funcionamento da lavoura. Embora esta tese não tenha como objetivo propor uma ferramenta agrônoma operacional, seus resultados indicam que a combinação entre HSI, variáveis meteorológicas e IA pode apoiar futuras aplicações voltadas ao manejo agrícola, à avaliação de práticas sustentáveis e ao acompanhamento de cultivos em regiões tropicais.

No campo da pesquisa científica, a tese contribui ao demonstrar que a ausência de dados *in situ* não impede o desenvolvimento de abordagens metodológicas relevantes, desde que a validação seja tratada com transparência e que os resultados sejam apresentados como estimativas modeladas. Essa posição é especialmente importante em regiões onde a infraestrutura de monitoramento é limitada. Ao invés de descartar tais áreas por falta de dados locais, a modelagem híbrida permite construir hipóteses quantitativas, mapear incertezas e orientar futuras campanhas de medição.

As implicações para o monitoramento de carbono na Amazônia, portanto, não se restringem ao resultado numérico do modelo. Elas envolvem a proposição de um caminho metodológico para integrar dados abertos, sensoriamento remoto, modelagem biofísica e inteligência artificial em um fluxo computacional documentado. Esse caminho pode ser expandido para outras culturas agrícolas, outras regiões da Amazônia Legal e diferentes escalas temporais, desde que acompanhado de validações externas progressivas e de ajustes regionais apropriados.

Dessa forma, os resultados desta tese indicam que a modelagem híbrida pode contribuir para o avanço do monitoramento ambiental em áreas agrícolas tropicais, oferecendo uma alternativa complementar aos métodos tradicionais e aos inventários agregados. Seu principal valor está na capacidade de articular observação espacial, interpretação ecofisiológica e ajuste estatístico em uma mesma arquitetura analítica. No caso da Amazônia Legal, essa integração é particularmente relevante para aproximar ciência climática, agricultura, planejamento territorial e políticas públicas de sustentabilidade.

4.5 Limitações da validação e interpretação dos resultados

A interpretação dos resultados obtidos nesta tese deve considerar a natureza indireta da validação adotada. Embora o modelo híbrido tenha apresentado desempenho estatístico elevado na validação temporal interna, os resultados não devem ser interpretados como confirmação observacional direta do fluxo de CO₂ em campo, uma vez que não foram realizadas medições micrometeorológicas locais por torre de covariância dos vórtices turbulentos ou por câmaras de fluxo na área de estudo. Essa delimitação não diminui a contribuição metodológica da pesquisa, mas define com precisão o alcance científico das inferências realizadas.

A validação foi estruturada como uma estratégia indireta e multicritério, composta pela coerência física e ecofisiológica das estimativas, pela consistência estatística das séries produzidas, pela comparação com ordens de grandeza descritas na literatura e pela rastreabilidade dos dados espectrais, meteorológicos e biofísicos utilizados no pipeline. Essa abordagem é compatível com o escopo computacional da tese e com a disponibilidade de bases secundárias consolidadas, mas impõe limites à generalização dos resultados para outras áreas, safras, cultivares e condições ambientais.

A principal consequência metodológica dessa escolha é que o desempenho do modelo híbrido deve ser compreendido como evidência de coerência interna em relação à referência adotada, e não como medição direta do comportamento real do ecossistema agrícola. Em outras palavras, as métricas obtidas demonstram que o modelo híbrido conseguiu reproduzir, com alto grau de ajuste, a dinâmica representada pela referência biofísica utilizada no treinamento e na validação. Contudo, sem medições independentes de campo, não é possível afirmar que a mesma magnitude de desempenho se manteria diante de observações micrometeorológicas locais.

Essa distinção é especialmente relevante diante dos valores elevados de R² e dos baixos valores de erro apresentados pelo modelo híbrido. Em estudos ambientais, métricas muito favoráveis devem ser interpretadas com cautela, sobretudo quando a referência de validação deriva de modelos ou de bases secundárias. O alto desempenho pode indicar que o algoritmo capturou padrões informativos presentes nas variáveis de entrada, mas também pode refletir dependência estrutural entre a referência, as variáveis biofísicas e os dados utilizados no treinamento. Por essa razão, a leitura dos resultados deve combinar análise estatística, coerência física e avaliação crítica das fontes de dados.

4.5.1 Ausência de medições in situ de fluxo de CO₂

A principal limitação empírica da tese decorre da ausência de medições diretas de NEE, GPP e Reco na área de estudo. Essa condição impede a comparação direta entre as estimativas do modelo e observações locais independentes de fluxo de CO₂. Consequentemente, o desempenho estatístico apresentado deve ser entendido como avaliação interna do modelo híbrido em relação à referência biofísica adotada, e não como confirmação observacional independente da dinâmica real do ecossistema agrícola analisado.

As medições por covariância dos vórtices turbulentos representam uma das principais bases observacionais para avaliação direta de fluxos de carbono em ecossistemas terrestres. Entretanto, sua instalação e operação exigem infraestrutura especializada, manutenção contínua, séries temporais extensas e controle rigoroso de qualidade dos dados. Em regiões tropicais e áreas agrícolas de fronteira, esses requisitos frequentemente limitam a disponibilidade de observações locais, justificando o uso de estratégias complementares baseadas em sensoriamento remoto, modelagem biofísica e dados meteorológicos secundários.

No caso desta tese, a ausência de dados in situ orientou a construção de uma arquitetura metodológica voltada à rastreabilidade e à coerência interna. A delimitação espacial da cultura da soja, o uso da cena EO-1 Hyperion, a integração com dados meteorológicos, a formulação biofísica reduzida e a correção residual por XGBoost foram organizados de modo a tornar explícitas as fontes de informação utilizadas e os limites de cada etapa. Essa organização permite avaliar o comportamento do modelo dentro do escopo definido, sem atribuir aos resultados um nível de validação que dependeria de observações independentes em campo.

Essa limitação não invalida a contribuição da pesquisa, mas delimita sua natureza. A tese demonstra a viabilidade metodológica de integrar sensoriamento remoto hiperespectral, variáveis meteorológicas, modelagem biofísica reduzida e aprendizado de máquina para estimar fluxos de carbono em áreas agrícolas. O que permanece como etapa necessária para estudos posteriores é a confrontação dessas estimativas com medições locais independentes, permitindo avaliar o desempenho do modelo em condições observacionais controladas.

Também é importante reconhecer que a ausência de medições locais limita a avaliação de processos de pequena escala, como variações intra-talhão, heterogeneidade de manejo, diferenças edáficas, efeitos de estresse hídrico localizado e respostas fisiológicas específicas da cultivar.

Esses fatores podem influenciar a NEE, a GPP e a Reco, mas nem sempre são plenamente representados por dados orbitais e meteorológicos agregados. Assim, a interpretação dos resultados deve considerar que o modelo trabalha em uma escala compatível com as fontes de dados disponíveis.

4.5.2 Alcance da validação indireta e incertezas do modelo

A validação indireta permitiu avaliar a coerência interna do modelo, a compatibilidade dos resultados com padrões descritos na literatura e o ganho estatístico obtido pela correção residual baseada em inteligência artificial. Contudo, valores elevados de desempenho em modelos híbridos podem refletir forte dependência da referência biofísica utilizada no treinamento e na validação, além de possível sensibilidade à estrutura temporal dos dados. Por isso, a interpretação das métricas deve ser realizada de forma integrada, considerando simultaneamente os pressupostos físicos, a origem dos dados e o desenho metodológico da validação.

As incertezas do modelo podem ser agrupadas em diferentes níveis. O primeiro nível refere-se às incertezas dos dados espectrais, incluindo ruídos instrumentais, seleção de bandas, efeitos atmosféricos residuais e limitações temporais da cena Hyperion. O segundo nível envolve as incertezas dos dados meteorológicos, especialmente quando uma estação ou base secundária é utilizada para representar condições ambientais de uma área agrícola espacialmente heterogênea. O terceiro nível está associado à formulação biofísica reduzida, que depende de simplificações paramétricas para representar processos complexos de fotossíntese, respiração e balanço hídrico. O quarto nível corresponde ao componente estatístico, no qual o XGBoost aprende padrões residuais condicionados à estrutura da base de treinamento.

A integração desses níveis de incerteza exige cuidado na interpretação dos resultados. O modelo híbrido pode apresentar desempenho superior ao modelo físico simplificado porque consegue capturar padrões residuais presentes nos dados, mas isso não significa que todas as fontes de erro tenham sido eliminadas. O ganho estatístico indica melhoria em relação à referência adotada, enquanto a validade ambiental mais ampla depende de validações adicionais, preferencialmente com torres de fluxo, câmaras de solo, séries FLUXNET ou experimentos locais em cultivos de soja.

Outro aspecto relevante é a generalização do modelo. Como a análise foi conduzida em

uma área e período específicos, com uma cena hiperespectral determinada e uma configuração meteorológica particular, a extrapolação para outras regiões da Amazônia Legal deve ser feita de forma gradual. Diferentes safras, cultivares, sistemas de manejo, condições de solo e regimes climáticos podem alterar a relação entre resposta espectral, variáveis biofísicas e fluxo de CO₂. Portanto, o modelo deve ser compreendido como uma arquitetura metodológica replicável, mas não como uma parametrização universal.

A validação indireta também apresenta alcance importante para pesquisas em regiões com baixa densidade de observações. Em vez de impedir a investigação, a ausência de dados *in situ* pode ser tratada como condicionante metodológica, exigindo transparência no uso de bases secundárias, documentação computacional e interpretação prudente dos resultados. Essa postura permite desenvolver modelos exploratórios e aplicados que orientem futuras campanhas de medição, identifiquem variáveis sensíveis e indiquem hipóteses quantitativas a serem testadas em campo.

Dessa forma, as limitações da validação e as incertezas do modelo constituem parte integrante da contribuição científica da tese. Ao explicitar os limites empíricos da abordagem, o estudo evita interpretações excessivas dos resultados e posiciona a modelagem híbrida como uma etapa metodológica relevante para o avanço do monitoramento de carbono agrícola na Amazônia Legal. A validade da proposta está no encadeamento entre dados hiperespectrais, modelagem biofísica, aprendizado supervisionado e rastreabilidade computacional, bem como na abertura de um caminho para validações externas futuras.

Considerando esse conjunto de evidências, os resultados obtidos devem ser interpretados como evidências modeladas e rastreáveis da aplicabilidade de uma abordagem híbrida para estimar fluxos de CO₂ em áreas de soja na Amazônia Legal. A tese não substitui medições diretas de campo nem encerra a necessidade de validação experimental em escala local. Seu principal alcance está em demonstrar um procedimento integrador, tecnicamente reproduzível e cientificamente delimitado, capaz de articular sensoriamento remoto hiperespectral, modelo biofísico e inteligência artificial em um problema ambiental de elevada relevância regional.

5 CONCLUSÃO

5.1 Síntese dos achados

Esta tese desenvolveu, estruturou e avaliou uma abordagem computacional híbrida para estimar o fluxo de CO₂ em áreas cultivadas com soja na Amazônia Legal, integrando sensoriamento remoto hiperespectral, modelagem biofísica inspirada em esquemas SVAT/ISBA e aprendizado de máquina. O percurso metodológico adotado permitiu organizar, em um mesmo fluxo analítico, dados espectrais derivados do sensor EO-1 Hyperion, informações meteorológicas, variáveis biofísicas e um modelo de correção residual baseado em XGBoost.

Os resultados obtidos indicam que a integração entre o componente físico e o componente orientado por dados contribuiu para melhorar o ajuste estatístico das estimativas de NEE em relação ao modelo físico simplificado. O modelo biofísico determinístico refinado serviu como referência metodológica para caracterizar o padrão temporal de absorção e emissão de carbono pela cultura da soja, enquanto o modelo físico simplificado permitiu avaliar as limitações decorrentes do uso de parametrizações fixas e reduzidas.

A aplicação do modelo físico simplificado apresentou RMSE = 1,30 gCO₂ m⁻² h⁻¹, MAE = 1,11 gCO₂ m⁻² h⁻¹ e R² = -0,04. Esses valores indicam que a formulação física simplificada, embora útil para estruturar os processos ecofisiológicos fundamentais, não foi suficiente para reproduzir adequadamente a referência adotada no período de validação. Essa limitação é coerente com a complexidade do fenômeno analisado, uma vez que os fluxos de CO₂ em sistemas agrícolas tropicais dependem de interações entre radiação, temperatura, disponibilidade hídrica, estrutura do dossel, estado fisiológico da vegetação e condições meteorológicas.

A abordagem híbrida, ao combinar o modelo físico simplificado com o aprendizado supervisionado para correção residual, apresentou RMSE = 0,013 gCO₂ m⁻² h⁻¹, MAE = 0,008 gCO₂ m⁻² h⁻¹ e R² = 0,9999 no escopo da validação temporal adotada. Esses resultados apontam forte capacidade de ajuste do modelo híbrido em relação à referência biofísica utilizada, indicando que parte relevante do erro residual do modelo físico simplificado continha estrutura informativa associada às variáveis espectrais, meteorológicas e biofísicas incorporadas ao pipeline.

A interpretação desses valores, entretanto, deve permanecer vinculada às delimitações metodológicas da pesquisa. O desempenho estatístico elevado não deve ser entendido como medição direta do fluxo real de CO₂ em campo, mas como evidência de coerência interna do modelo híbrido em relação à referência adotada. Essa distinção é essencial para preservar a validade científica da tese, pois não foram realizadas medições locais por torre de covariância dos vórtices turbulentos, câmaras de fluxo ou outro sistema observacional direto na área de estudo.

Do ponto de vista metodológico, a principal contribuição da tese está na formulação de um pipeline rastreável e reproduzível para estimativa de fluxos de CO₂ em áreas agrícolas tropicais a partir da integração entre dados orbitais, modelagem biofísica e inteligência artificial. A pesquisa mostrou que dados hiperespectrais podem fornecer atributos relevantes sobre a condição fisiológica da vegetação, enquanto o componente biofísico oferece coerência ecofisiológica e o componente de aprendizado de máquina atua sobre padrões residuais não plenamente representados pela formulação física reduzida.

A tese também contribui ao posicionar a modelagem híbrida como alternativa metodológica para contextos em que há escassez de dados *in situ*, mas disponibilidade de bases orbitais, meteorológicas e temáticas. Essa contribuição é particularmente relevante para a Amazônia Legal, onde a extensão territorial, as limitações logísticas e a baixa densidade de infraestrutura de monitoramento dificultam a obtenção de séries observacionais contínuas em campo.

5.2 Validação da hipótese

A hipótese central desta tese, de que a integração entre dados hiperespectrais, modelos biofísicos e técnicas de inteligência artificial pode aprimorar a estimativa do fluxo de CO₂ em sistemas agrícolas tropicais, foi corroborada no escopo metodológico adotado. Essa corroboração decorre da comparação entre o desempenho do modelo físico simplificado e o desempenho do modelo híbrido, bem como da coerência entre os resultados obtidos, a fundamentação teórica e a discussão científica desenvolvida ao longo do trabalho.

Os resultados indicam que a inteligência artificial, quando aplicada como mecanismo de correção residual, pode aprender padrões sistemáticos não representados por parametrizações físicas genéricas. Essa contribuição não substitui a modelagem biofísica, mas complementa sua aplicação em situações nas quais a formulação física reduzida apresenta limitações para

representar a variabilidade ambiental, espectral e temporal do sistema agrícola analisado.

A validação da hipótese deve ser compreendida, portanto, como uma validação metodológica e estatística interna, baseada na referência biofísica adotada, na separação temporal entre treinamento e validação, na análise das métricas de desempenho e na coerência ecofisiológica das estimativas. Essa interpretação é compatível com a natureza da tese e evita atribuir aos resultados um alcance experimental que dependeria de medições diretas independentes em campo.

Nesse sentido, a hipótese não é tratada como afirmação absoluta sobre todos os contextos agrícolas tropicais, mas como proposição sustentada pelos resultados obtidos no recorte espacial, temporal e metodológico da pesquisa. A abordagem proposta mostrou-se adequada para representar a dinâmica modelada do fluxo de CO₂ em áreas de soja na Amazônia Legal, considerando as bases secundárias, os dados hiperespectrais, os procedimentos de processamento e a estratégia de validação adotados.

A utilização do XGBoost como componente central da correção residual mostrou-se coerente com o problema investigado, pois o algoritmo permitiu modelar relações não lineares entre variáveis de diferentes naturezas. No entanto, sua contribuição deve ser interpretada em conjunto com o componente biofísico, e não de forma isolada. A contribuição metodológica da tese está justamente na integração entre interpretação física, observação espectral e ajuste estatístico orientado por dados.

Assim, a hipótese foi corroborada porque o modelo híbrido apresentou desempenho superior ao modelo físico simplificado no contexto avaliado, preservando coerência com os processos ecofisiológicos representados e com as limitações explicitadas na discussão. A conclusão não elimina a necessidade de validações externas futuras, mas sustenta que a arquitetura metodológica proposta constitui uma contribuição relevante para a modelagem de fluxos de carbono em sistemas agrícolas tropicais.

5.3 Propostas futuras

A continuidade desta pesquisa deve priorizar a validação externa do modelo híbrido com dados observacionais independentes. A etapa mais relevante consiste na comparação das estimativas produzidas pelo pipeline com medições diretas de fluxo de CO₂ obtidas por torres de covariância dos vórtices turbulentos, câmaras de fluxo ou experimentos locais conduzidos

em áreas cultivadas com soja. Esse procedimento permitiria avaliar a aderência do modelo não apenas à referência biofísica utilizada nesta tese, mas também a observações micrometeorológicas independentes.

Outra frente de continuidade envolve a comparação com séries de referência de redes internacionais, como FLUXNET, e com produtos orbitais complementares associados à produtividade primária, ao balanço de carbono e ao estado da vegetação. Essa comparação pode ampliar a capacidade de avaliação do modelo em diferentes escalas temporais e espaciais, contribuindo para identificar limites de generalização, sensibilidade a variáveis de entrada e estabilidade das estimativas em diferentes condições ambientais.

Também se recomenda aplicar a arquitetura metodológica a outras safras, cultivares e regiões da Amazônia Legal. A expansão para diferentes anos agrícolas permitiria avaliar a resposta do modelo a variações climáticas, fenológicas e de manejo. Do mesmo modo, a aplicação em outras culturas agrícolas poderia indicar em que medida a abordagem híbrida é dependente das características específicas da soja ou se pode ser adaptada a outros sistemas produtivos tropicais.

O avanço de novas missões hiperspectrais orbitais representa outra possibilidade importante para pesquisas futuras. Sensores mais recentes, com melhor disponibilidade temporal e aprimoramentos instrumentais, podem permitir a construção de séries mais densas e reduzir limitações associadas ao uso de cenas isoladas. A adaptação do pipeline a esses novos sensores pode ampliar a aplicabilidade da metodologia, especialmente em estudos voltados ao monitoramento ambiental, agricultura de precisão e políticas de baixo carbono.

No plano computacional, trabalhos futuros podem explorar estratégias adicionais de seleção de variáveis, análise de importância, interpretação local de modelos, quantificação de incertezas e comparação com outros algoritmos de aprendizado supervisionado. Essas etapas podem contribuir para avaliar com maior detalhe quais variáveis espectrais, meteorológicas e biofísicas exercem maior influência na correção residual do fluxo de CO₂.

Por fim, a modelagem híbrida desenvolvida nesta tese pode apoiar pesquisas aplicadas voltadas ao monitoramento, relato e verificação de carbono agrícola, desde que acompanhada de validações externas progressivas e de protocolos transparentes de rastreabilidade. A principal contribuição futura da abordagem está em oferecer um caminho metodológico para articular dados abertos, sensoriamento remoto hiperspectral, modelagem biofísica e inteligência artificial

no estudo de sistemas agrícolas tropicais, com atenção aos limites empíricos e às necessidades de validação observacional.

Referências

- AARON, B. User's Guide to ISBA-F90: User's guide for using the driver for Interactions between the Soil-Biosphere-Atmosphere (ISBA). 2002. Disponível em: <https://www.umr-cnrm.fr/isbadoc/model/docf90.html>. Acesso em: 25 out. 2023.
- ALTENBURGER, A. et al. K-nearest neighbors for high-dimensional remote sensing data: performance and limitations. *Remote Sensing Applications: Society and Environment*, v. 21, 2021.
- ARTAXO, P. et al. The role of the Amazon region in the global carbon cycle. *Scientific Reports*, v. 12, 2022. Disponível em: <https://doi.org/10.1038/s41598-022-18703-0>. Acesso em: 28 mar. 2026.
- ATLURI, G.; KARPATNE, A.; KUMAR, V. Spatio-temporal data mining: a survey. *IEEE TKDE*, 2017.
- BALDAM, R. Science Mapping. Vitória, 2021. Disponível em: <http://cope.ufes.br>. Acesso em: 23 jul. 2022.
- BALDOCCHI, D. et al. FLUXNET: a new tool to study the temporal and spatial variability of ecosystem-scale carbon dioxide, water vapor, and energy flux densities. *Bulletin of the American Meteorological Society*, v. 82, n. 11, p. 2415-2434, 2001.
- BALDOCCHI, D. D. Assessing the eddy covariance technique for evaluating carbon dioxide exchange rates of ecosystems: past, present and future. *Global Change Biology*, v. 9, n. 4, p. 479-492, 2003.
- BALDOCCHI, D. Breathing of the terrestrial biosphere: lessons learned from a global network of carbon dioxide flux measurement systems. *Australian Journal of Botany*, v. 56, n. 1, p. 1-26, 2008.
- BAPTISTA, G. M. M. Sensoriamento remoto hiperespectral. 2. ed. São Paulo: Intrínseca, 2019. ISBN 978-8571934054.
- BATISTA, R. A. et al. Dinâmicas recentes de expansão da soja na Amazônia Legal e implicações ambientais. *Revista Brasileira de Estudos Regionais*, v. 17, n. 2, p. 55-74, 2023.

BELGIU, M.; DRAGUT, L. Random forest in remote sensing: a review of applications and future directions. *ISPRS Journal of Photogrammetry and Remote Sensing*, v. 114, p. 24-31, 2016. DOI: 10.1016/j.isprsjprs.2016.01.011.

BOX, G. E. P.; JENKINS, G. M.; REINSEL, G. C. *Time Series Analysis: Forecasting and Control*. Hoboken: Wiley, 2008.

BRAUD, I. et al. Bareground surface heat and water exchanges under dry conditions: observations and parameterization. *Boundary-Layer Meteorology*, p. 173-200, 1993.

BRAUD, I. et al. A distributed parameter hydrologic model including soil freezing and snow melt. *Journal of Hydrology*, v. 162, n. 1-2, p. 105-125, 1994.

BREIMAN, L. Random forests. *Machine Learning*, v. 45, n. 1, p. 5-32, 2001.

CAMPBELL, G. S.; NORMAN, J. M. *An Introduction to Environmental Biophysics*. 2. ed. New York: Springer, 1998.

CHAI, T.; DRAXLER, R. R. Root mean square error (RMSE) or mean absolute error (MAE)? Arguments against avoiding RMSE in the literature. *Geoscientific Model Development*, v. 7, p. 1247-1250, 2014.

CHAPIN, F. S. et al. *Principles of Terrestrial Ecosystem Ecology*. 2. ed. New York: Springer, 2006.

CHAWISHBORWORNWORNG, C. et al. Bootstrap approach for quantifying the uncertainty in modeling of the water quality index using principal component analysis and artificial intelligence. *Journal of the Saudi Society of Agricultural Sciences*, v. 23, n. 1, p. 17-33, 2024.

CHEN, T.; GUESTRIN, C. XGBoost: a scalable tree boosting system. In: *ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING*, 22., 2016. Proceedings [...]. p. 785-794. Disponível em: <https://doi.org/10.1145/2939672.2939785>. Acesso em: 28 mar. 2026.

CHEN, J. et al. Estimating cropland carbon fluxes from hyperspectral and meteorological predictors using machine learning. *Ecological Indicators*, v. 105, p. 302-314, 2019.

CLEVERS, J. G. P. W.; GITELSON, A. A. Remote estimation of crop and grass chlorophyll and nitrogen content using red-edge bands on Sentinel-2 and -3. *International Journal of Applied Earth Observation and Geoinformation*, v. 23, p. 344-351, 2013. DOI: 10.1016/j.jag.2012.10.008.

COOPER, H. et al. Reporting literature reviews in social and environmental sciences: standards and recommendations. *Review of Educational Research*, v. 87, n. 1, p. 3-45, 2017.

DECHARME, B. et al. Recent changes in the ISBA-CTrip land surface system for coupled land-atmosphere simulations. *Journal of Advances in Modeling Earth Systems*, v. 11, n. 5, p. 1207-1252, 2019.

DELIRE, C. et al. Simulating the carbon cycle in Northern Eurasia using the ISBA-CTrip land surface model. *Agricultural and Forest Meteorology*, v. 287, 2020a. Disponível em: <https://doi.org/10.1016/j.agrformet.2020.107863>. Acesso em: 28 mar. 2026.

DELIRE, C. et al. The Global Land Carbon Cycle Simulated. *Journal of Advances in Modeling Earth Systems*, p. 1-31, 2020b.

DENG, Y. Deep learning for carbon flux prediction in vegetation ecosystems. *Ecological Informatics*, v. 45, p. 1-9, 2018. Disponível em: <https://doi.org/10.1016/j.ecoinf.2018.01.003>. Acesso em: 28 mar. 2026.

DICKINSON, R. E. et al. Biosphere-atmosphere transfer scheme (BATS) version 1e as coupled to the NCAR Community Climate Model. NCAR Technical Note, Boulder, 1998.

DUARTE, E. A. et al. Revisão integrativa aplicada à modelagem ambiental: critérios de qualidade e síntese de evidências. *Revista Ibero-Americana de Ciência da Informação*, v. 14, n. 3, p. 811-829, 2021.

EMBRAPA. 2022. Visão 2030: o futuro da agricultura brasileira. Brasília: Embrapa.

FERREIRA, L. C. et al. Desenvolvimento regional, agricultura e sustentabilidade na Amazônia Legal. *Revista de Políticas Públicas*, v. 24, n. 1, p. 101-122, 2020.

FERREIRA, M. P. et al. Ciência aberta e reprodutibilidade computacional: desafios e recomendações. Campinas: Embrapa Informática Agropecuária, 2024. (Documentos). Disponível em: <https://www.infoteca.cnptia.embrapa.br/infoteca/handle/doc/1141642>. Acesso em: 28 mar. 2026.

FLOWERS-CANO, R. S. et al. Comparison of Bootstrap Confidence Intervals Using Monte Carlo Simulations. *Water*, v. 10, n. 2, art. 166, 2018.

FRIEDMAN, J. H. Greedy function approximation: a gradient boosting machine. *Annals of Statistics*, v. 29, n. 5, p. 1189-1232, 2001.

- GAMON, J. A. et al. A remotely sensed pigment index reveals photosynthetic phenology in evergreen conifers. *Proceedings of the National Academy of Sciences*, v. 113, n. 46, p. 13087-13092, 2016.
- GENG, X. et al. Machine learning-based estimation of ecosystem carbon fluxes: validation strategies and uncertainty analysis. *Agricultural and Forest Meteorology*, v. 324, 2022.
- GITELSON, A. A. et al. Novel algorithms for remote estimation of vegetation fraction. *Remote Sensing of Environment*, v. 80, n. 1, p. 76-87, 2003.
- GITELSON, A. A. et al. Remote estimation of gross primary productivity in crops using MODIS and hyperspectral approaches. *Remote Sensing of Environment*, v. 121, p. 404-414, 2013.
- GOMEZ, C. et al. Combining field and airborne hyperspectral data to model gross primary production in a Mediterranean savanna ecosystem. *International Journal of Applied Earth Observation and Geoinformation*, v. 83, p. 102050, 2019. Disponível em: <https://doi.org/10.1016/j.jag.2019.102050>. Acesso em: 28 mar. 2026.
- GUZINSKI, R. et al. Synergistic use of hyperspectral and multispectral data for agricultural monitoring. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, v. 14, p. 9940-9954, 2021.
- HOSMER, D. W.; LEMESHOW, S.; STURDIVANT, R. X. *Applied Logistic Regression*. 3. ed. Hoboken: Wiley, 2013.
- HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. *The elements of statistical learning: data mining, inference, and prediction*. 2. ed. New York: Springer, 2009.
- HUANG, Q.; XU, Z. A review of cloud computing for big data in agriculture. *Computers and Electronics in Agriculture*, v. 153, p. 69-81, 2018. Disponível em: <https://doi.org/10.1016/j.compag.2018.08.021>. Acesso em: 28 mar. 2026.
- HUETE, A. et al. Overview of the radiometric and biophysical performance of the MODIS vegetation indices. *Remote Sensing of Environment*, v. 83, n. 1-2, p. 195-213, 2002.
- HUNT, E. R. et al. Evaluation of vegetation indices for estimation of leaf chlorophyll content and canopy stress in crops. *International Journal of Applied Earth Observation and Geoinformation*, v. 21, p. 103-112, 2013.
- IBGE. Instituto Brasileiro de Geografia e Estatística. EPAG 2022. Rio de Janeiro, 2022.

Disponível em: https://biblioteca.ibge.gov.br/visualizacao/periodicos/2415/epag_2022_fev.pdf. Acesso em: 13 jun. 2022.

IPAM. Monitoramento de uso da terra e emissões na Amazônia brasileira. Brasília: Instituto de Pesquisa Ambiental da Amazônia, 2021.

IPCC. Climate Change 2021: The Physical Science Basis. Cambridge: Cambridge University Press, 2021. Disponível em: <https://www.ipcc.ch/report/ar6/wg1/>. Acesso em: 28 mar. 2026.

ISBA MODEL. ISBA and TEB Code (and stand-alone DRIVER) in FORTRAN90. 2022. Disponível em: <https://www.umr-cnrm.fr/isbadoc/model.html>. Acesso em: 15 jun. 2022.

JEAN, C. C. et al. An interactive vegetation SVAT model tested against data from six contrasting sites. *Agricultural and Forest Meteorology*, p. 73-146, 1998a.

JEAN, M. et al. Integration of remote sensing data in SVAT models: current status and perspectives. *Agronomie*, v. 18, p. 749-762, 1998b.

JIA, K. et al. Integrating remote sensing and meteorological drivers for estimating cropland carbon exchange. *Science of the Total Environment*, v. 763, 2021.

JOHNSON, R. A.; WICHERN, D. W. *Applied Multivariate Statistical Analysis*. 6. ed. [S.l.]: Pearson, 2020.

LAW, B. E. et al. Environmental controls over carbon dioxide and water vapor exchange of terrestrial vegetation. *Agricultural and Forest Meteorology*, v. 113, n. 1-4, p. 97-120, 2002.

LI, Z. et al. Estimation of Carbon Sequestration in Croplands using Hyperspectral Remote Sensing. *Sensors*, v. 21, n. 12, p. 4033, 2021. Disponível em: <https://doi.org/10.3390/s21124033>. Acesso em: 28 mar. 2026.

LOIZZO, R. et al. Multi-sensor data fusion for crop biophysical variable retrieval in precision agriculture. *Remote Sensing*, v. 10, n. 5, p. 741, 2018.

MA, Y. et al. Machine learning for crop biophysical parameter retrieval from remote sensing data: advances and perspectives. *Remote Sensing*, v. 11, n. 21, 2019.

MA, X. et al. Hybrid physical-data-driven frameworks for agricultural carbon flux estimation in heterogeneous environments. *Agricultural and Forest Meteorology*, v. 308-309, 2021.

MAHFOUF, J. F.; NOILHAN, J. Inclusion of gravitational drainage in a land surface scheme based on the force-restore method. *Journal of the Atmospheric Sciences*, p. 987-992, 1996b.

MAHFOUF, S.; NOILHAN, J. Comparative study of different methods of estimating surface parameters. *Journal of Applied Meteorology*, v. 35, n. 9, p. 1443-1453, 1996a.

MARELLO, L. P. et al. Operational use of multispectral satellite products for large-scale agricultural monitoring in Brazil. *Revista Brasileira de Cartografia*, v. 74, n. 3, p. 721-740, 2022.

MAPBIOMAS. Coleção 9 da Série Anual de Mapas de Cobertura e Uso da Terra do Brasil. São Paulo: Projeto MapBiomass, 2023. Disponível em: <https://brasil.mapbiomas.org/colecoes-mapbiomas/>. Acesso em: 28 mar. 2026.

MCTI. Quarta Comunicação Nacional do Brasil à Convenção-Quadro das Nações Unidas sobre Mudança do Clima. Brasília: Ministério da Ciência, Tecnologia e Inovações, 2020.

MCTI. Painel de dados por UF do setor LULUCF. 2022. Disponível em: <https://www.gov.br/mcti/pt-br/acompanhe-o-mcti/sirene/dados-e-ferramentas/painel-de-dados-por-uf-do-setor-lulucf>. Acesso em: 13 jun. 2022.

MEDEIROS, M. N. et al. Expansão da soja e transformações territoriais na Amazônia Legal: tendências recentes e desafios. *Revista de Economia e Sociologia Rural*, v. 61, n. 4, 2023.

MITCHELL, T. M. *Machine Learning*. New York: McGraw-Hill, 1997.

MONTEITH, J. L. Solar radiation and productivity in tropical ecosystems. *Journal of Applied Ecology*, v. 9, n. 3, p. 747-766, 1972.

MONTEITH, J. L.; UNSWORTH, M. H. *Principles of Environmental Physics*. 2. ed. London: Edward Arnold, 1990.

MORGAN, G. A. et al. *Applied Logistic Regression Analysis*. 3. ed. New York: Routledge, 2010.

NASA. EO-1 Hyperion Level 1 Product User Guide. Greenbelt: National Aeronautics and Space Administration, 2017.

NOILHAN, J.; PLANTON, S. A simple parameterization of land surface processes for meteorological models. *Monthly Weather Review*, v. 117, p. 536-549, 1989.

OECD. *Environment at a Glance 2020*. 4. ed. Paris: OECD Publishing, 2020.

PAPALE, D. et al. Towards a standardized processing of Net Ecosystem Exchange measured with eddy covariance technique: algorithms and uncertainty estimation. *Biogeosciences*, v. 3, p. 571-583, 2006.

PASTORELLO, G. et al. The FLUXNET2015 dataset and the ONEFlux processing pipeline for eddy covariance data. *Scientific Data*, v. 7, 2020.

PIÑEIRO, G. et al. How to evaluate models: Observed vs. predicted or predicted vs. observed? *Ecological Modelling*, v. 216, n. 3, p. 316-322, 2008.

PRESSMAN, R. S. Engenharia de software: uma abordagem profissional. 7. ed. Porto Alegre: AMGH, 2011. ISBN 978-85-8055-044-3.

RICHARDSON, A. D. et al. A multi-site analysis of random error in tower-based measurements of carbon and energy fluxes. *Agricultural and Forest Meteorology*, v. 136, n. 1-2, p. 1-18, 2006.

RUNNING, S. W. et al. A continuous satellite-derived measure of global terrestrial primary production. *BioScience*, v. 54, n. 6, p. 547-560, 2004.

RUNNING, S. W.; MU, Q.; ZHAO, M. MOD17 User Guide: Global Terrestrial Gross and Net Primary Production. Missoula: University of Montana, 2010.

RUSSELL, S. J.; NORVIG, P. Artificial Intelligence: A Modern Approach. 2. ed. New Jersey: Pearson Education, 2010.

SEEG. Sistema de Estimativas de Emissões e Remoções de Gases de Efeito Estufa (SEEG): Painel. 2022. Disponível em: <https://plataforma.seeg.eco.br/territories/rondonia/card?year=2020&cities=false>. Acesso em: 13 jun. 2022.

SHARMA, A. et al. KNN-based modeling in remote sensing applications: a comparative performance analysis. *Geocarto International*, v. 35, n. 14, p. 1559-1578, 2020.

SILVA, T. S. F. et al. Remote sensing of soybean yield in tropical agricultural systems. *Remote Sensing*, v. 3, n. 1, p. 185-202, 2011. Disponível em: <https://doi.org/10.3390/rs3010185>. Acesso em: 28 mar. 2026.

SMITH, L. P. et al. Hybrid modeling in environmental systems: combining process-based and machine learning approaches. *Environmental Modelling & Software*, v. 122, p. 104521, 2019. Disponível em: <https://doi.org/10.1016/j.envsoft.2019.104521>. Acesso em: 28 mar. 2026.

- SOMMERVILLE, I. Engenharia de software. 9. ed. São Paulo: Pearson Prentice Hall, 2011.
- STENZEL, S. et al. Machine learning for agricultural remote sensing: comparative assessment of tree-based algorithms and spectral predictors. *Computers and Electronics in Agriculture*, v. 175, 2020.
- STOLBOVOY, V. Assessment of soil carbon stocks in Russia. *Geoderma*, v. 134, n. 3-4, p. 281-288, 2006. Disponível em: <https://doi.org/10.1016/j.geoderma.2005.07.011>. Acesso em: 28 mar. 2026.
- STOLBOVOY, V. Soil Sampling Protocol to Certify the Changes of Organic Carbon Stock in Mineral Soils of European Union (Version 2). Luxembourg: Joint Research Centre, 2015.
- THENKABAIL, P. S. et al. *Hyperspectral Remote Sensing of Vegetation*. Boca Raton: CRC Press, 2011.
- THENKABAIL, P. S. et al. *Remote Sensing Handbook: Volume II – Land Resources Monitoring, Modeling, and Mapping with Remote Sensing*. Boca Raton: CRC Press, 2012.
- TONG, Q. et al. Hyperspectral remote sensing in precision agriculture: advances, opportunities and challenges. *ISPRS Journal of Photogrammetry and Remote Sensing*, v. 166, p. 1-15, 2020.
- TOOMEY, M. et al. Long-term high-spatial resolution carbon balance monitoring of the Amazonian frontier. *JGR Biogeosciences*, v. 118, p. 1-12, 2013. Disponível em: <https://doi.org/10.1002/jgrg.20046>. Acesso em: 28 mar. 2026.
- TORRACO, R. J. Writing integrative literature reviews: guidelines and examples. *Human Resource Development Review*, v. 4, n. 3, p. 356-367, 2005.
- USCUPLIC, M. et al. Advances in hyperspectral and multispectral sensing for crop monitoring in tropical regions. *Remote Sensing Applications: Society and Environment*, v. 24, 2021.
- WANG, L. et al. Hyperspectral imaging for crop physiology and carbon-related trait estimation: a review. *Agronomy*, v. 11, n. 9, 2021.
- WHITTEMORE, R.; KNAFL, K. The integrative review: updated methodology. *Journal of Advanced Nursing*, v. 52, n. 5, p. 546-553, 2005. DOI: 10.1111/j.1365-2648.2005.03621.x.
- WILKINSON, M. D. et al. The FAIR Guiding Principles for scientific data management and stewardship. *Scientific Data*, v. 3, p. 160018, 2016. Disponível em: <https://doi.org/10.1038/sdata.2016.18>. Acesso em: 28 mar. 2026.

- WILKS, D. S. Statistical Methods in the Atmospheric Sciences. [S.l.]: Academic Press, 2006.
- XU, D. et al. Red-edge spectral indices for monitoring chlorophyll and canopy nitrogen status in crops. *International Journal of Applied Earth Observation and Geoinformation*, v. 82, 2019.
- XUE, J.; SU, B. Significant remote sensing vegetation indices: a review of developments and applications. *Journal of Sensors*, v. 2017, 2017.
- ZHANG, Y. et al. Remote sensing-based estimation of crop carbon fluxes using machine learning and environmental covariates. *Ecological Indicators*, v. 98, p. 476-488, 2019.
- ZHANG, C. et al. Monitoring of Cropland CO₂ Fluxes Using UAV Hyperspectral Imagery and a Data-Driven Approach. *Remote Sensing*, v. 12, n. 19, 2020, p. 1985. Disponível em: <https://doi.org/10.3390/rs12121985>. Acesso em: 28 mar. 2026.
- ZHANG, H. et al. Integrating hyperspectral and meteorological data for improved estimation of agricultural CO₂ exchange. *Science of the Total Environment*, v. 776, 2021.
- ZHAO, M.; RUNNING, S. W. Drought-induced reduction in global terrestrial net primary production from 2000 through 2009. *Science*, v. 329, n. 5994, p. 940-943, 2010. DOI: 10.1126/science.1192666.
- ZHU, J.; BOEHM, A. B.; REN, Z. J. Environmental Machine Learning, Baseline Reporting, and Comprehensive Evaluation: The EMBRACE Checklist. *Environmental Science & Technology*, v. 58, n. 45, p. 19909-19912, 2024.
- ZOCCA, G. S. D. S. P. R.; VALENTINO. Python Deep Learning: Next-generation techniques to revolutionize computing. 1. ed. Birmingham: Packt Publishing, 2017.

APÊNDICE A — Repositório computacional, rastreabilidade e reprodutibilidade da pesquisa

Este apêndice apresenta a organização geral dos materiais computacionais utilizados na elaboração desta tese. Os códigos-fonte, scripts de processamento, registros de execução, arquivos intermediários e artefatos gerados ao longo da pesquisa foram organizados e versionados em repositório Git, com o objetivo de assegurar rastreabilidade, transparência metodológica e reprodutibilidade dos procedimentos descritos nos capítulos de metodologia e resultados.

O repositório computacional reúne os scripts responsáveis pelo pré-processamento dos dados hiperespectrais, geração da máscara de soja, integração com variáveis meteorológicas, cálculo dos índices espectrais, execução do modelo biofísico reduzido, treinamento do modelo de aprendizado de máquina, avaliação estatística e geração dos produtos finais utilizados na análise.

A organização dos arquivos no repositório permite relacionar cada etapa metodológica da tese aos respectivos scripts, logs e produtos computacionais. Dessa forma, evita-se a reprodução integral de códigos extensos no corpo do documento, preservando a clareza textual da tese e mantendo os materiais técnicos completos em ambiente próprio de versionamento.

Repositório principal da pesquisa: https://github.com/ProfMacielDavid/PROJETO_2025_TESE

Versão de referência: Commit 6c4bda1 correspondente à versão final da tese.

Principais grupos de artefatos disponíveis no repositório:

- scripts de pré-processamento e validação dos dados hiperespectrais;
- rotinas de recorte espacial e aplicação da máscara de soja;
- scripts de cálculo dos índices espectrais;
- rotinas de integração com variáveis meteorológicas;
- scripts de execução do modelo biofísico reduzido;
- rotinas de treinamento e validação do modelo híbrido com inteligência artificial;
- logs de execução e arquivos de controle de qualidade;

- tabelas, figuras e produtos derivados utilizados nos capítulos de resultados.

Assim, este apêndice cumpre a função de registrar a existência, a localização e a organização dos materiais computacionais da pesquisa, enquanto o repositório Git mantém a íntegra dos códigos, arquivos auxiliares e evidências de processamento.

APÊNDICE B — Publicações da Tese

Este apêndice reúne, em caráter documental, a produção bibliográfica vinculada ao desenvolvimento desta tese, contemplando artigos publicados em periódicos e capítulos de livros. O registro tem função complementar e permite situar a trajetória científica do autor em diálogo com as áreas de modelagem ambiental, inteligência artificial, sensoriamento remoto, inovação tecnológica, educação, engenharia, gestão e desenvolvimento regional.

B.1 Artigos em periódicos

MACIEL, David Lopes; ALMEIDA, Fabrício Moraes de; MACIEL, Natiele Vieira de Oliveira; SANTOS, Airton Ribeiro dos; REIS, Rafael Vicente Martins dos; HELFENSTEIN, Aline Cristina; CANDIDO, Lenilson Sergio; GUIMARÃES, Jéssica Silva. Possibilidades de otimização com o método PRIA: processo de revisão integrado com inteligência artificial. *InterSciencePlace*, [S. l.], v. 21, art. 03, 2026. DOI: 10.6020/1679-9844/v21a03. Disponível em: <https://www.interscienceplace.org/index.php/isp/article/view/1000>. Acesso em: 28 abr. 2026.

MACIEL, David Lopes; MACIEL, Natiele Vieira de Oliveira; ALMEIDA, Fabrício Moraes de. Integrating deep neural networks and fuzzy logic for a clinical decision support system in digital mammogram. *Journal of Engineering and Technology Management*, [S. l.], v. 78, n. 1, p. 583-598, 2025. DOI: 10.5281/zenodo.17642152.

COROVIL, Gustavo Igor Alves Buzaglo; MELO, Nayah Ferreira; SÃO PEDRO FILHO, Flávio de; SOUZA, Éliton da Silva; PARAGUASSU-CHAVES, Carlos Alberto; MACIEL, David Lopes; SILVA, Dalza Gomes da; ALMEIDA, Fabrício Moraes de. Analysis of cost accounting in business control. *InterSciencePlace*, [S. l.], v. 19, art. 04, p. 76-90, 2024. DOI: 10.6020/1679-9844/v19a4. Disponível em: <https://www.interscienceplace.org/index.php/isp/article/view/716>. Acesso em: 28 abr. 2026.

SANTOS, Airton Ribeiro dos; MACIEL, David Lopes; ALMEIDA, Fabrício Moraes de. Prevenção de ocorrências aeronáuticas e política pública de gestão de resíduos sólidos urbanos em Porto Velho-RO. *InterSciencePlace*, [S. l.], v. 19, art. 12, p. 218-240, 2024. DOI: 10.6020/1679-9844/v19a12. Disponível em: <https://www.interscienceplace.org/index.php/isp/article/view/733>. Acesso em: 28 abr. 2026.

MACIEL, David Lopes; ALMEIDA, Fabrício Moraes de. Tutores digitais: uma nova era na educação do século XXI. *SODEBRÁS*, [S. l.], v. 18, p. 71-80, 2023.

SILVA, Gizele Ferreira da; MACIEL, David Lopes; PARAGUASSU-CHAVES, Carlos Alberto; ALMEIDA, Fabrício Moraes de. Bibliometric study: machine learning applied in agriculture. *InterSciencePlace*, [S. l.], v. 18, n. 3, art. 01, p. 1-15, 2023. DOI: 10.6020/1679-9844/v18n3a1. Disponível em: <https://www.interscienceplace.org/index.php/isp/article/view/612>. Acesso em:

28 abr. 2026.

MARQUES, Cláudia Brazil; SANTOS, Carlos Honorato Schuch; ALMEIDA, Fabrício Moraes de; PARAGUASSU-CHAVES, Carlos Alberto; AZNAR, Simão Dolezel; SOUZA, Levi Pereira Granja de; TRINDADE, Carlos Alberto Dolezel; PEREIRA, Carlos Eugênio; GUANABARA, Ricardo; MACIEL, David Lopes. Rural tourism: an analysis throught the assumptions of the new institutional economy. *International Journal for Innovation Education and Research*, [S. l.], v. 10, n. 1, p. 137-144, 2022. DOI: 10.31686/ijer.vol10.iss1.3599. Disponível em: <https://scholarsjournal.net/ijer/article/view/3599>. Acesso em: 28 abr. 2026.

SANTOS, Carlos Honorato Schuch; MARQUES, Cláudia Brazil; LETIZIA, Ricardo Garcia; ALMEIDA, Fabrício Moraes de; PARAGUASSU-CHAVES, Carlos Alberto; TRINDADE, Carla Dolezel; AZNAR FILHO, Simão; SMITH, Ruy Drummont; AZNAR, Simão Dolezel; UCHÔA, Marcélio Rodrigues; MACIEL, David Lopes; UCHÔA, Márcia Maria Rodrigues; SANTOS, Reinaldo Rosa dos. Governance, sustainability and collaboration analysis model. *International Journal of Advanced Engineering Research and Science*, [S. l.], v. 9, n. 5, p. 276-282, 2022. DOI: 10.22161/ijaers.95.27. Disponível em: <https://ijaers.com/detail/governance-sustainability-and-collaboration-analysis-model/>. Acesso em: 28 abr. 2026.

MACIEL, David Lopes; ALMEIDA, Fabrício Moraes de. Cenário tecnológico, transformação digital e o professor no século XXI. *InterSciencePlace*, [S. l.], v. 17, n. 1, art. 06, p. 88-103, 2022. DOI: 10.6020/1679-9844/v17n1a6. Disponível em: <https://www.interscienceplace.org/index.php/isp/article/view/321>. Acesso em: 28 abr. 2026.

MARQUES, Cláudia Brazil; ALMEIDA, Fabrício Moraes de; PARAGUASSU-CHAVES, Carlos Alberto; XAVIER, Delson Fernando Barcellos; MACIEL, David Lopes; TRINDADE, Carla Dolezel; AZNAR FILHO, Simão; AZNAR, Simão Dolezel; TRINDADE, Carlos Alberto Dolezel. Environmental sustainability and biodynamic cultivation of *Vitis viniferas* grapes in the Serra Gaúcha region, Brazil. *International Journal of Advanced Engineering Research and Science*, [S. l.], v. 8, n. 6, p. 349-359, 2021. DOI: 10.22161/ijaers.86.43. Disponível em: <https://ijaers.com/detail/environmental-sustainability-and-biodynamic-cultivation-of-vitis-viniferas-grapes-in-the-serra-ga-cha-region-brazil/>. Acesso em: 28 abr. 2026.

PARAGUASSU-CHAVES, Carlos Alberto; CAVALCANTE, Fabio Robson Casara; BARROS FILHO, Allan Kardec Duailibe; ALMEIDA, Fabrício Moraes de; DANTAS, Lenita Rodrigues Moreira; MACIEIRA, Carlos de Andrade; FONSECA NETO, João Viana; BARATA, Charlles da Silva; SIQUEIRA, Sorin Melgar Maciel; CAVALCANTE, Ana Maria Morais da Fonseca; NETTO, Edmundo Machado. Factor analysis applied in the construction of the socio-environmental performance index (IDRSA) in the Guajará-Mirim Free Trade Area, Brazil/Bolivia Border. *International Journal of Advanced Engineering Research and Science*, [S. l.], v. 7, n. 4, p. 312-324, 2020. DOI: 10.22161/ijaers.74.40.

B.2 Capítulos de livros

MACIEL, David Lopes; OLIVEIRA, Natiele Vieira de; ALMEIDA, Bruna Rafaela Barros de; ALMEIDA, Fabrício Moraes de. Desenvolvimento de protocolo inventário florestal com HSI e

LiDAR para projetos REDD+: abordagem integrada com blockchain. In: *Engenharia de Produção e a gestão de sistemas produtivos*. 1. ed. Ponta Grossa: Atena Editora, 2026. p. 31-65. DOI: 10.22533/at.ed.185112624023.

MACIEL, David Lopes; MACIEL, Natiele Vieira de Oliveira; MIKOS, Aline; ALMEIDA, Bruna Rafaela Barros de; OLIVEIRA, Paulo de Tarso Carvalho de; FRANÇA NETO, Adjalma Campos de; ROMANHOLO, Rafael Augusto; XAVIER, Delson Fernando Barcellos; CAVALCANTE, Fabio Robson Casara; ALMEIDA, Fabrício Moraes de. Artificial intelligence and optimization with the method review process integrated. In: *Engenharia de Computação aplicada a sistemas, dados e inovação*. Ponta Grossa: Atena Editora, 2026. DOI: 10.22533/at.ed.394122608015.

MACIEL, David Lopes; MACIEL, Natiele Vieira de Oliveira; ALMEIDA, Bruna Rafaela Barros de; ALMEIDA, Fabrício Moraes de. Estudo bibliométrico sobre enzimas microbianas na biotecnologia industrial. In: *Open Science Research XXIII*. 1. ed. [S. l.]: Editora Científica Digital, 2026. v. 23. DOI: 10.37885/260221195.

MACIEL, David Lopes; MACIEL, Natiele Vieira de Oliveira; ALMEIDA, Fabrício Moraes de. Sistema de apoio à decisão clínica em mamografia digital usando inteligência artificial. In: *Ciências Médicas e Saúde: avanços do diagnóstico à prática clínica 4*. Ponta Grossa: Atena Editora, 2025. DOI: 10.22533/at.ed.3421425201110.

FERREIRA, Murylo Pereira da Silva; MACIEL, David Lopes; MIKOS, Aline; SANTOS, Aírton Ribeiro dos; OLIVEIRA, Geraldo de Magela Carvalho de; FRANÇA NETO, Adjalma Campos de; ALMEIDA, Fabrício Moraes de. Uso IoT e inteligência artificial na agricultura. In: *Avanços interdisciplinares nas ciências exatas e seus impactos tecnológicos*. Ponta Grossa: Atena Editora, 2025. DOI: 10.22533/at.ed.2412502041.

OLIVEIRA, Paulo de Tarso Carvalho de; MACIEL, David Lopes; OLIVEIRA, Geraldo de Magela Carvalho de; ALMEIDA, Fabrício Moraes de. Previsão da demanda de energia elétrica utilizando lógica fuzzy e função de autocorrelação estendida. In: *O universo das ciências exatas e da terra: teoria e aplicações*. Ponta Grossa: Atena Editora, 2024. DOI: 10.22533/at.ed.4162407031.

SASANO, Thiago Eiji; MACIEL, David Lopes; ALMEIDA, Fabrício Moraes de. Controle de drenagem com CLP. In: *Coletânea de estudos em engenharia e automação*. Ponta Grossa: Atena Editora, 2024.

SILVA, Gizele Ferreira da; MACIEL, David Lopes; ALMEIDA, Fabrício Moraes de. Fomento à inovação na Amazônia. In: *Coletânea de estudos em inovação e desenvolvimento regional*. Ponta Grossa: Atena Editora, 2024.

SOUZA, Francisco Cledson de; MACIEL, David Lopes; ALMEIDA, Fabrício Moraes de. Manutenção de radar TA-10SST. In: *Coletânea de estudos em tecnologia e manutenção*. Ponta Grossa: Atena Editora, 2024.

MACIEL, David Lopes; ALMEIDA, Fabrício Moraes de; FERREIRA, Murylo Pereira da Silva; SANTOS, Aírton Ribeiro dos. IA generativa na agricultura. In: *Coletânea de estudos em inteligência artificial e agricultura*. Ponta Grossa: Atena Editora, 2024.

SANTOS, Aírton Ribeiro dos; MACIEL, David Lopes; ALMEIDA, Fabrício Moraes de. Gestão

de resíduos e acidentes aéreos. In: *Coletânea de estudos em gestão, segurança e sustentabilidade*. Ponta Grossa: Atena Editora, 2024.

SILVA, Francisco José Ferreira da; MACIEL, David Lopes; ALMEIDA, Fabrício Moraes de. Accountability em projetos públicos. In: *Coletânea de estudos em gestão pública e accountability*. Ponta Grossa: Atena Editora, 2024.

CHAVES, Igor Daniel; MACIEL, David Lopes; ALMEIDA, Fabrício Moraes de. Dispositivo de resgate subaquático autônomo. In: *Coletânea de estudos em engenharia e inovação tecnológica*. Ponta Grossa: Atena Editora, 2024.

GONÇALVES FILHO, Elmir Marques; MACIEL, David Lopes; SANTOS, Aírton Ribeiro dos; MONTEIRO, Paulo Roberto Meloni; ALMEIDA, Fabrício Moraes de. Modelagem quantitativa, desenvolvimento regional e as hidrelétricas do Rio Madeira - RO. In: *O universo das ciências exatas e da terra: teoria e aplicações*. Ponta Grossa: Atena Editora, 2024. DOI: 10.22533/at.ed.0322427121.

MACIEL, David Lopes; ALMEIDA, Fabrício Moraes de. Transformação digital e educação. In: *Coletânea de estudos em educação e tecnologias digitais*. Ponta Grossa: Atena Editora, 2023.

SILVA, Gizele Ferreira da; MACIEL, David Lopes; ALMEIDA, Fabrício Moraes de. Estudo bibliométrico: ML aplicada na agricultura. In: *Coletânea de estudos em aprendizado de máquina e agricultura*. Ponta Grossa: Atena Editora, 2023. p. 51-63.

PARAGUASSU-CHAVES, Carlos Alberto; MACIEL, David Lopes; ALMEIDA, Fabrício Moraes de. Índice de desenvolvimento sustentável por bacia. In: *Coletânea de estudos em desenvolvimento sustentável*. [S. l.]: Stricto Sensu, 2023.

CALDERARO, Isabel Cristina Nunes; MACIEL, David Lopes; ALMEIDA, Fabrício Moraes de. Modelagem para tomada de decisão regional. In: *Coletânea de estudos em modelagem e desenvolvimento regional*. Ponta Grossa: Atena Editora, 2023.

PARAGUASSU-CHAVES, Carlos Alberto; MACIEL, David Lopes; ALMEIDA, Fabrício Moraes de. Modelagem espacial do desmatamento e malária. In: *Coletânea de estudos em modelagem espacial, saúde e ambiente*. Ponta Grossa: Atena Editora, 2023.

MACIEL, David Lopes; ALMEIDA, Fabrício Moraes de; PARAGUASSU-CHAVES, Carlos Alberto; SILVA, Elizangélica Fernandes da; SERAPIÃO, Eduardo Lucas Jorge; OLIVEIRA, Geraldo de Magela Carvalho de; SOUZA, Carlos Henrique Medeiros de. Digital tutors using artificial intelligence and education in the 21st century. In: *Engenharia de Computação: conceitos fundamentais e aplicações práticas*. Ponta Grossa: Atena Editora, 2023. DOI: 10.22533/at.ed.9072322124.